



دانشگاه تهران
پردیس فارابی
دانشکده مهندسی
گروه مهندسی کامپیوتر

تشخیص زبان در داده‌های گفتاری چندزبانه

نگارش:

آوا شهاب الدین

استاد راهنما:

دکتر حسین آقابابا

گزارش پروژه برای دریافت درجه کارشناسی
در رشته مهندسی کامپیوتر

شهریور ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

چکیده^۱

امروزه با افزایش حجم داده‌های متنی و صوتی، شناسایی خودکار زبان به یکی از مسائل مهم در حوزه پردازش زبان طبیعی، پردازش گفتار و یادگیری ماشین تبدیل شده است. هدف این پروژه، طراحی و پیاده‌سازی سیستمی برای شناسایی زبان از متن و گفتار و بررسی عملکرد روش‌های مختلف یادگیری ماشین در مسائل طبقه‌بندی و خوشه‌بندی است.

در بخش متنی، داده‌های چند زبان مختلف پس از پاک‌سازی و پیش‌پردازش مورد بررسی قرار گرفته و ویژگی‌های مناسب از آن‌ها استخراج شده‌اند. سپس چند الگوریتم طبقه‌بندی برای تشخیص زبان و چند روش خوشه‌بندی برای بررسی ساختار طبیعی داده‌ها مورد استفاده قرار گرفته‌اند.

در بخش گفتار نیز مجموعه‌ای از نمونه‌های صوتی چند زبان پس از انجام مراحل پیش‌پردازش، به مجموعه‌ای از ویژگی‌های صوتی تبدیل شده است. سپس از الگوریتم‌های مختلف طبقه‌بندی و خوشه‌بندی برای شناسایی و تفکیک زبان‌ها استفاده شده و عملکرد آن‌ها با معیارهای ارزیابی مناسب بررسی شده است.

نتایج این پروژه نشان می‌دهد که استفاده از ویژگی‌های مناسب در کنار روش‌های یادگیری ماشین می‌تواند عملکرد مطلوبی در شناسایی زبان‌های مختلف از داده‌های متنی و صوتی ایجاد کند. این پروژه همچنین می‌تواند مبنایی برای توسعه روش‌های پیشرفته‌تر در زمینه شناسایی خودکار زبان در آینده باشد.

کلمات کلیدی: شناسایی زبان، پردازش زبان طبیعی، پردازش گفتار، یادگیری ماشین، طبقه‌بندی، خوشه‌بندی

فهرست مطالب

۱	کلیات پروژه	۱
۲	مقدمه	۱.۱
۲	بیان مسئله	۲.۱
۴	محدوده داده‌های پروژه	۳.۱
۴	مجموعه داده متنی	۱.۳.۱
۵	مجموعه داده گفتاری	۲.۳.۱
۵	اهداف پروژه	۴.۱
۶	کاربردهای شناسایی زبان	۵.۱
۷	ابزارها و فناوری‌های مورد استفاده	۶.۱
۹	نمای کلی معماری سیستم	۷.۱
۹	نمای کلی روند اجرای پروژه	۸.۱
۹	روند اجرای مسیر متن	۱.۸.۱
۱۰	روند اجرای مسیر گفتار	۲.۸.۱
۱۰	روند ارزیابی	۳.۸.۱
۱۲	مبانی نظری و مفاهیم پایه	۲
۱۳	مقدمه	۱.۲
۱۳	شناسایی زبان از متن و گفتار	۲.۲
۱۳	شناسایی زبان از متن	۱.۲.۲
۱۴	شناسایی زبان از گفتار	۲.۲.۲
۱۴	یادگیری ماشین در مسئله شناسایی زبان	۳.۲
۱۴	یادگیری نظارت شده	۱.۳.۲
۱۵	یادگیری بدون نظارت	۲.۳.۲
۱۵	استخراج ویژگی از داده‌های متنی	۴.۲

۱۵	 مفهوم N-Gram	۱.۴.۲	
۱۶	 روش TF-IDF	۲.۴.۲	
۱۷	 ترکیب ویژگی‌های کاراکتری و کلمه‌ای	۳.۴.۲	
۱۸	 انتخاب ویژگی با Chi-Square	۴.۴.۲	
۱۸	 استخراج ویژگی از داده‌های صوتی	۵.۲	
۱۸	 ضرایب MFCC	۱.۵.۲	
۲۰	 Delta-Delta MFCC و Delta MFCC	۲.۵.۲	
۲۰	 Zero Crossing Rate	۳.۵.۲	
۲۰	 ویژگی‌های طیفی	۴.۵.۲	
۲۱	 RMS Energy	۵.۵.۲	
۲۲	 مدت زمان فایل صوتی	۶.۵.۲	
۲۲	 الگوریتم‌های طبقه‌بندی	۶.۲	
۲۲	 Logistic Regression	۱.۶.۲	
۲۳	 Multinomial Naive Bayes	۲.۶.۲	
۲۳	 Decision Tree	۳.۶.۲	
۲۳	 Support Vector Machine	۴.۶.۲	
۲۴	 K-Nearest Neighbors	۵.۶.۲	
۲۵	 Random Forest	۶.۶.۲	
۲۵	 الگوریتم‌های خوشه‌بندی	۷.۲	
۲۵	 K-Means	۱.۷.۲	
۲۶	 Hierarchical Clustering	۲.۷.۲	
۲۶	 Gaussian Mixture Model	۳.۷.۲	
۲۷	 DBSCAN	۴.۷.۲	
۲۷	 آماده‌سازی و کاهش ابعاد ویژگی‌ها	۸.۲	
۲۷	 استانداردسازی ویژگی‌ها	۱.۸.۲	
۲۸	 Principal Component Analysis	۲.۸.۲	
۲۸	 Truncated SVD	۳.۸.۲	
۲۹	 تنظیم و اعتبارسنجی مدل	۹.۲	
۲۹	 Cross Validation	۱.۹.۲	
۲۹	 Grid Search	۲.۹.۲	
۲۹	 معیارهای ارزیابی طبقه‌بندی	۱۰.۲	

۲۹	 Accuracy	۱.۱۰.۲
۳۰	 Precision	۲.۱۰.۲
۳۰	 Recall	۳.۱۰.۲
۳۰	 F1-Score	۴.۱۰.۲
۳۰	 میانگین‌های Macro و Weighted	۵.۱۰.۲
۳۱	 Confusion Matrix	۶.۱۰.۲
۳۱	 معیارهای ارزیابی خوشه‌بندی	۱۱.۲
۳۲	 Silhouette Score	۱.۱۱.۲
۳۲	 Calinski-Harabasz Index	۲.۱۱.۲
۳۲	 Davies-Bouldin Index	۳.۱۱.۲
۳۲	 Cluster Purity	۴.۱۱.۲
۳۳	 Adjusted Rand Index	۵.۱۱.۲
۳۳	 Normalized Mutual Information	۶.۱۱.۲
۳۴	 خلاصه و جمع‌بندی	۱۲.۲

۳۵	۳ داده‌ها و پیش‌پردازش	
۳۶	 مقدمه	۱.۳
۳۶	 ساختار کلی داده‌های پروژه	۲.۳
۳۷	 آماده‌سازی داده‌های متنی	۳.۳
۳۷	 ساختار و توزیع داده‌های متنی	۱.۳.۳
۳۷	 بارگذاری و برچسب‌گذاری داده‌های متنی	۲.۳.۳
۳۸	 پاک‌سازی متون	۳.۳.۳
۳۹	 تبدیل متون به فضای ویژگی	۴.۳.۳
۴۰	 آماده‌سازی برچسب‌ها و انتخاب ویژگی	۵.۳.۳
۴۱	 جلوگیری از نشت اطلاعات در بخش متن	۶.۳.۳
۴۱	 خروجی‌های مرحله آماده‌سازی متن	۷.۳.۳
۴۲	 آماده‌سازی داده‌های گفتاری	۴.۳
۴۲	 ساختار و توزیع داده‌های صوتی	۱.۴.۳
۴۳	 استانداردسازی فایل‌های صوتی	۲.۴.۳
۴۴	 ایجاد فایل فراداده	۳.۴.۳
۴۴	 پیاده‌سازی استخراج ویژگی‌های صوتی	۴.۴.۳
۴۵	 کنترل کیفیت ویژگی‌های صوتی	۵.۴.۳

۴۶	 بررسی مدت زمان نمونه‌های صوتی	۶.۴.۳
۴۷	 داده‌های نهایی آماده برای مدل‌سازی	۵.۳
۴۹	 خلاصه و جمع‌بندی	۶.۳

۴ پیاده‌سازی و نتایج

۵۱	 پیاده‌سازی بخش شناسایی زبان از متن	۱.۴
۵۱	 معماری خط لوله پردازش متن	۱.۱.۴
۵۱	 بارگذاری و آماده‌سازی داده‌های متنی	۲.۱.۴
۵۲	 پیش‌پردازش داده‌های متنی	۳.۱.۴
۵۳	 استخراج ویژگی‌های متنی	۴.۱.۴
۵۴	 انتخاب ویژگی در مسیر طبقه‌بندی	۵.۱.۴
۵۴	 تقسیم داده‌ها و اعتبارسنجی	۶.۱.۴
۵۵	 آماده‌سازی داده برای الگوریتم‌های یادگیری	۷.۱.۴
۵۶	 طبقه‌بندی داده‌های متنی	۲.۴
۵۶	 طراحی فرایند آموزش مدل	۱.۲.۴
۵۷	 مدل‌های طبقه‌بندی بررسی شده	۲.۲.۴
۵۸	 تنظیم ابرپارامترها و انتخاب مدل نهایی	۳.۲.۴
۵۸	 ارزیابی مدل‌ها روی مجموعه آزمون	۴.۲.۴
۵۹	 ارزیابی مدل منتخب روی مجموعه آزمون	۵.۲.۴
۶۰	 تحلیل ماتریس‌های درهم‌ریختگی مدل‌های طبقه‌بندی	۶.۲.۴
۶۴	 ذخیره‌سازی مدل نهایی و پیش‌بینی	۷.۲.۴
۶۴	 خوشه‌بندی داده‌های متنی	۳.۴
۶۵	 طراحی فرایند خوشه‌بندی متن	۱.۳.۴
۶۶	 پیاده‌سازی الگوریتم‌های خوشه‌بندی	۲.۳.۴
۶۷	 نتایج ارزیابی الگوریتم‌های خوشه‌بندی متن	۳.۳.۴
۶۸	 تحلیل نمودارهای خوشه‌بندی متن	۴.۳.۴
۷۲	 جمع‌بندی خوشه‌بندی داده‌های متنی	۵.۳.۴
۷۳	 پیاده‌سازی بخش شناسایی زبان از گفتار	۴.۴
۷۳	 معماری خط لوله پردازش گفتار	۱.۴.۴
۷۴	 بارگذاری و آماده‌سازی داده‌های گفتاری	۲.۴.۴
۷۵	 اعتبارسنجی و پیش‌پردازش داده‌های صوتی	۳.۴.۴
۷۵	 ویژگی‌های صوتی استفاده شده	۴.۴.۴

۷۶	استانداردسازی و آماده‌سازی ویژگی‌ها	۵.۴.۴
۷۷	تقسیم داده‌ها و اعتبارسنجی	۶.۴.۴
۷۷	آماده‌سازی داده برای الگوریتم‌های یادگیری	۷.۴.۴
۷۸	طبقه‌بندی گفتار	۵.۴
۷۸	طراحی فرآیند آموزش مدل طبقه‌بندی گفتار	۱.۵.۴
۷۹	مدل‌های طبقه‌بندی بررسی شده	۲.۵.۴
۸۱	تنظیم ابرپارامترها و انتخاب مدل نهایی	۳.۵.۴
۸۱	مقایسه عملکرد مدل‌های طبقه‌بندی گفتار	۴.۵.۴
۸۲	ارزیابی مدل منتخب روی داده آزمون	۵.۵.۴
۸۳	تحلیل ماتریس درهم‌ریختگی	۶.۵.۴
۸۳	ذخیره‌سازی مدل و فرآیند پیش‌بینی	۷.۵.۴
۸۴	جمع‌بندی بخش طبقه‌بندی گفتار	۸.۵.۴
۸۴	خوشه‌بندی گفتار	۶.۴
۸۴	طراحی فرآیند خوشه‌بندی گفتار	۱.۶.۴
۸۵	آماده‌سازی ویژگی‌های صوتی برای خوشه‌بندی	۲.۶.۴
۸۶	پیاده‌سازی الگوریتم‌های خوشه‌بندی	۳.۶.۴
۸۸	مقایسه نتایج الگوریتم‌های خوشه‌بندی گفتار	۴.۶.۴
۸۹	تحلیل نمودارهای خوشه‌بندی	۵.۶.۴
۹۲	تحلیل نهایی خوشه‌بندی گفتار	۶.۶.۴
۹۳	ارزیابی و مقایسه نتایج	۷.۴
۹۴	تحلیل نتایج نهایی	۸.۴
۹۶	نتیجه‌گیری و پیشنهادها	۵
۹۷	جمع‌بندی پروژه	۱.۵
۹۷	مهم‌ترین نتایج	۲.۵
۹۹	محدودیت‌های پروژه	۳.۵
۱۰۰	پیشنهاد برای توسعه آینده	۴.۵
۱۰۲	مراجع	۶

فهرست تصاویر

۳	نمای مفهومی مسئله تشخیص خودکار زبان در دو مسیر مستقل متن و گفتار . .	۱.۱
۶۰	ماتریس درهم‌ریختگی مدل Logistic Regression	۱.۴
۶۱	ماتریس درهم‌ریختگی مدل K-Nearest Neighbours	۲.۴
۶۲	ماتریس درهم‌ریختگی مدل Decision Tree	۳.۴
۶۳	ماتریس درهم‌ریختگی مدل Multinomial Naive Bayes	۴.۴
۶۹	نمایش خوشه‌های ایجادشده توسط الگوریتم K-Means	۵.۴
۷۰	نمایش خوشه‌های ایجادشده توسط الگوریتم DBSCAN	۶.۴
۷۱	نمایش خوشه‌های ایجادشده توسط الگوریتم Agglomerative Clustering	۷.۴
۷۲	نمایش خوشه‌های ایجادشده توسط الگوریتم Gaussian Mixture	۸.۴
۸۳	ماتریس درهم‌ریختگی مدل KNN	۹.۴
۸۹	نمایش خوشه‌های ایجادشده توسط الگوریتم K-Means در داده‌های گفتاری . . .	۱۰.۴
۹۰	نمایش خوشه‌های ایجادشده توسط الگوریتم DBSCAN در داده‌های گفتاری . .	۱۱.۴
	نمایش خوشه‌های ایجادشده توسط الگوریتم Agglomerative Clustering در	۱۲.۴
۹۱	داده‌های گفتاری	
	نمایش خوشه‌های ایجادشده توسط الگوریتم Gaussian Mixture در داده‌های	۱۳.۴
۹۲	گفتاری	

فهرست جداول

۱۰.۳	توزیع نمونه‌های مجموعه داده متنی	۳۷
۲.۳	ابعاد فضای ویژگی متنی	۴۰
۳.۳	توزیع نمونه‌های صوتی براساس زبان	۴۲
۴.۳	توزیع نمونه‌های صوتی براساس جنسیت گوینده	۴۳
۵.۳	ساختار ویژگی‌های استخراج‌شده از هر فایل صوتی	۴۵
۶.۳	آمار مدت زمان نمونه‌های صوتی	۴۷
۱.۴	نگاشت کد پوشه منبع به برچسب نهایی زبان	۵۲
۲.۴	فضای جست‌وجو و بهترین ابرپارامتر طبقه‌بندهای متن	۵۷
۳.۴	مقایسه طبقه‌بندهای متن بر اساس اعتبارسنجی متقاطع گروه‌آگاه	۵۸
۴.۴	مقایسه عملکرد طبقه‌بندهای متن روی مجموعه آزمون نهایی	۵۸
۵.۴	نتایج تجمیعی مدل Logistic Regression روی مجموعه آزمون	۵۹
۶.۴	گزارش طبقه‌بندی مدل Logistic Regression برای هر زبان	۵۹
۷.۴	مقایسه نتایج الگوریتم‌های خوشه‌بندی داده‌های متنی	۶۸
۸.۴	مشخصات مجموعه‌داده گفتاری مورد استفاده در مدل‌سازی	۷۴
۹.۴	نتایج اعتبارسنجی متقاطع مدل‌های طبقه‌بندی گفتار	۸۱
۱۰.۴	مقایسه عملکرد مدل‌های طبقه‌بندی گفتار روی مجموعه آزمون	۸۱
۱۱.۴	نتایج کلی مدل منتخب طبقه‌بندی گفتار	۸۲
۱۲.۴	گزارش طبقه‌بندی مدل KNN به تفکیک زبان	۸۲
۱۳.۴	مشخصات داده ورودی خوشه‌بندی گفتار	۸۶
۱۴.۴	مقایسه نتایج الگوریتم‌های خوشه‌بندی گفتار	۸۸
۱۵.۴	خلاصه طبقه‌بند منتخب در هر مجموعه داده مستقل	۹۳
۱۶.۴	تفاوت انتخاب داخلی و تطابق خارجی در خوشه‌بندی	۹۳

فصل ۱

کلیات پروژه

در این فصل، مسئله شناسایی خودکار زبان در دو حوزه مستقل متن و گفتار معرفی می‌شود. ابتدا تعریف مسئله و ضرورت شناسایی زبان بیان شده، سپس اهداف، کاربردها، ابزارهای مورد استفاده و محدوده پروژه توضیح داده می‌شوند. در پایان نیز نمایی کلی از معماری و مراحل اجرای دو مسیر مستقل پروژه ارائه خواهد شد.

۱.۱ مقدمه

با گسترش سامانه‌های دیجیتال و چندزبانه، حجم زیادی از اطلاعات به صورت متن و صوت تولید و ذخیره می‌شود. پردازش خودکار این داده‌ها در بسیاری از کاربردهای هوشمند ضروری است و یکی از مراحل پایه در چنین سامانه‌هایی، تشخیص زبان ورودی است.

شناسایی زبان یا **Language Identification** به فرایندی گفته می‌شود که در آن زبان یک نمونه متنی یا گفتاری به صورت خودکار تعیین می‌شود. این فرایند معمولاً به عنوان یکی از مراحل ابتدایی در سامانه‌های پردازش زبان طبیعی، پردازش گفتار و بازیابی اطلاعات چندزبانه مورد استفاده قرار می‌گیرد. برای مثال، یک سامانه چندزبانه می‌تواند ابتدا زبان ورودی کاربر را تشخیص دهد و سپس مدل مناسب برای ترجمه، تبدیل گفتار به متن، تحلیل محتوا یا سایر عملیات پردازشی را انتخاب کند. بنابراین، عملکرد مرحله شناسایی زبان می‌تواند بر کیفیت مراحل بعدی سامانه اثر مستقیم داشته باشد.

در این پروژه، شناسایی زبان در دو مسیر مستقل بررسی شده است:

- شناسایی زبان از داده‌های متنی؛
- شناسایی زبان از ویژگی‌های عددی استخراج شده از گفتار.

داده‌های متنی در زبان‌های مشترک تبدیل شده داده‌های گفتاری به متن می‌باشند با این تفاوت که از نظر اندازه کاراکترها بالانس شده‌اند. اما داده‌های متنی به زبان‌های دیگر نمونه‌هایی هستند که برای ارزیابی بهتر قرار گرفته‌اند و فایل‌های متنی به صورت فایل‌های صوتی به صورت فرمت MP3 می‌باشند.

در مسیر متن، فایل‌های متنی خام کشف، اعتبارسنجی و پاک‌سازی شده و سپس با استفاده از ویژگی‌های مبتنی بر TF-IDF به نمایش عددی تبدیل می‌شوند.

در مسیر گفتار، نقطه شروع پروژه جدول ویژگی‌های عددی از پیش استخراج شده است. این جدول به عنوان ورودی فقط خواندنی در نظر گرفته شده و استخراج مجدد ویژگی از فایل‌های صوتی، بخشی از مراحل الزامی این پروژه نیست.

در هر دو مسیر، روش‌های طبقه‌بندی نظارت شده برای پیش‌بینی زبان و روش‌های خوشه‌بندی بدون نظارت برای بررسی ساختار طبیعی داده‌ها اجرا و ارزیابی شده‌اند.

۲.۱ بیان مسئله

زبان‌های مختلف دارای الگوهای نوشتاری و گفتاری متفاوتی هستند. این تفاوت‌ها در داده‌های متنی می‌توانند در ترکیب کاراکترها، ساختار کلمات، فراوانی واژه‌ها، نشانه‌گذاری و الگوهای محلی متن ظاهر شوند.

در داده‌های گفتاری نیز تفاوت زبان‌ها می‌تواند در الگوهای طیفی، ساختار آوایی، ریتم، انرژی و ویژگی‌های وابسته به نحوه تلفظ مشاهده شود. در پروژه حاضر، این اطلاعات گفتاری از طریق

ویژگی‌های عددی از پیش استخراج‌شده، مانند ضرایب MFCC و آمارهای مربوط به آن‌ها، در اختیار مدل‌های یادگیری ماشین قرار می‌گیرند.


انسان در صورت آشنایی با یک زبان معمولاً می‌تواند با مشاهده چند کلمه یا شنیدن بخشی از یک مکالمه، زبان مورد استفاده را تشخیص دهد. انجام خودکار این فرایند مستلزم آن است که اطلاعات موجود در ورودی به یک نمایش عددی مناسب تبدیل شوند و الگوریتم یادگیری ماشین بتواند الگوهای متمایزکننده زبان‌ها را از آن نمایش استخراج کند.

بنابراین، مسئله اصلی این پروژه را می‌توان به صورت زیر بیان کرد:

چگونه می‌توان با استفاده از ویژگی‌های متنی و ویژگی‌های عددی استخراج‌شده از گفتار، زبان نمونه‌های مستقل متنی و گفتاری را به صورت خودکار شناسایی کرد؟

برای پاسخ به این مسئله، پروژه در دو مسیر جداگانه پیاده‌سازی شده است. در مسیر متن، فرایند از فایل‌های متنی خام آغاز می‌شود و شامل کشف داده، اعتبارسنجی، پاک‌سازی، استخراج ویژگی، طبقه‌بندی، خوشه‌بندی و ارزیابی است.

نمای کلی مسئله و ارتباط میان ورودی‌های متنی و گفتاری، مراحل استخراج ویژگی و روش‌های یادگیری ماشین در شکل ۱.۱ نشان داده شده است.



شکل ۱.۱: نمای مفهومی مسئله تشخیص خودکار زبان در دو مسیر مستقل متن و گفتار

در مسیر گفتار، فرایند مدل‌سازی از جدول features.csv آغاز می‌شود. این جدول شامل

ویژگی‌های عددی استخراج‌شده از نمونه‌های گفتاری است. بنابراین، پردازش فایل صوتی خام یا اجرای مجدد استخراج ویژگی، بخشی از خط لوله اصلی مدل‌سازی گفتار محسوب نمی‌شود.

در هر مسیر، چهار خانواده مستقل از الگوریتم‌های طبقه‌بندی و چهار خانواده مستقل از الگوریتم‌های خوشه‌بندی اجرا می‌شوند. تغییر یک پارامتر از یک الگوریتم به‌عنوان یک خانواده جدید در نظر گرفته نشده است.

در بخش طبقه‌بندی، مدل‌ها با استفاده از داده‌های برچسب‌دار آموزش داده می‌شوند. انتخاب مدل و تنظیم پارامترها فقط با استفاده از داده‌های آموزشی و اعتبارسنجی متقابل انجام می‌شود و داده آزمون نهایی در فرایند تنظیم مدل دخالت ندارد.

در بخش خوشه‌بندی، برچسب زبان هنگام برآزش مدل‌ها مورد استفاده قرار نمی‌گیرد. برچسب‌ها تنها پس از تشکیل خوشه‌ها و برای محاسبه معیارهای خارجی و تفسیر نتایج به کار می‌روند. جزئیات نظری ویژگی‌ها، الگوریتم‌ها و معیارهای ارزیابی در فصل دوم و جزئیات پیاده‌سازی و نتایج در فصل‌های بعدی ارائه خواهند شد.

۳.۱ محدوده داده‌های پروژه

این پروژه از دو مجموعه داده مستقل استفاده می‌کند که هر کدام دارای ساختار و کلاس‌های مخصوص خود هستند.

۱.۳.۱ مجموعه داده متنی

مجموعه داده متنی شامل 608 سند مستقل با کدگذاری UTF-8 است. این اسناد به شش زبان تعلق دارند:

- آلمانی؛
- ایتالیایی؛
- ژاپنی؛
- کره‌ای؛
- پرتغالی؛
- اسپانیایی.

برچسب زبان از ساختار پوشه‌های مجموعه داده استخراج می‌شود. محتوای کامل هر فایل به‌عنوان متن نمونه در نظر گرفته شده است. پاک‌سازی متن به شکلی انجام می‌شود که نوع خط، حروف، نشانه‌گذاری، اعداد و علائم زبانی حفظ شوند.

۲.۳.۱ مجموعه داده گفتاری

مجموعه داده گفتاری شامل 720 نمونه و 133 ویژگی عددی پیش‌بین است. این مجموعه چهار زبان را پوشش می‌دهد:

- آلمانی؛
- اسپانیایی؛
- ایتالیایی؛
- کره‌ای.

برای هر زبان 180 نمونه وجود دارد؛ بنابراین مجموعه داده گفتاری از نظر تعداد نمونه‌های هر کلاس متوازن است.

ویژگی‌های گفتاری در یک مرحله مستقل و پیش از شروع مدل‌سازی استخراج شده‌اند. پروژه حاضر این جدول ویژگی را اعتبارسنجی کرده و سپس برای تقسیم داده، پیش‌پردازش، آموزش مدل و ارزیابی استفاده می‌کند.

شناسه فایل، جنسیت و برچسب زبان به‌عنوان ویژگی پیش‌بین وارد مدل نمی‌شوند. همچنین، گروه‌های مرتبط با گوینده یا منبع داده در تقسیم آموزش و آزمون از یکدیگر جدا نگه داشته می‌شوند تا احتمال نشت اطلاعات کاهش یابد.

۴.۱ اهداف پروژه

هدف اصلی پروژه، طراحی و پیاده‌سازی یک چارچوب قابل تکرار برای شناسایی خودکار زبان از دو مجموعه داده مستقل متنی و گفتاری با استفاده از روش‌های یادگیری ماشین است. برای دستیابی به این هدف، اهداف فرعی زیر در نظر گرفته شده‌اند:

- کشف و اعتبارسنجی ساختار واقعی مجموعه داده متنی؛
- پاک‌سازی متن بدون حذف اطلاعات زبانی مهم مانند نوع خط، اعراب، نشانه‌ها و حروف خاص؛
- استخراج ویژگی‌های کاراکتری و واژگانی از متن با استفاده از TF-IDF؛
- اعتبارسنجی جدول ویژگی‌های گفتاری بدون تغییر در فایل‌های ورودی؛
- جلوگیری از ورود شناسه‌ها، اطلاعات جانبی و برچسب زبان به ویژگی‌های پیش‌بین؛
- ایجاد تقسیم آموزش و آزمون به‌صورت گروه‌آگاه برای کاهش نشت اطلاعات؛
- آموزش، تنظیم و مقایسه دقیقاً چهار خانواده الگوریتم طبقه‌بندی برای هر مسیر؛

- اجرای دقیقاً چهار خانواده الگوریتم خوشه‌بندی برای هر مسیر؛
 - انجام اعتبارسنجی متقابل و تنظیم ابرپارامترها فقط روی داده‌های آموزشی؛
 - نگهداری داده آزمون نهایی خارج از فرایند انتخاب و تنظیم مدل؛
 - ارزیابی طبقه‌بندی با استفاده از معیارهای Accuracy, Precision, Recall و F1-score؛
 - تولید ماتریس درهم‌ریختگی و گزارش کامل طبقه‌بندی برای هر مدل؛
 - ارزیابی خوشه‌بندی با معیارهای داخلی و معیارهای خارجی پس از برازش؛
 - ذخیره مدل‌های آموزش دیده، پیش‌بینی‌ها، معیارها، نمودارها و تخصیص خوشه‌ها؛
 - فراهم کردن امکان استنتاج زبان برای ورودی‌های جدید؛
 - ایجاد یک روند اجرایی قابل تکرار با استفاده از محیط مدیریت شده Poetry.
- در مسیر متنی، هدف اصلی بررسی میزان توانایی الگوهای کاراکتری و واژگانی در تفکیک شش زبان موجود در مجموعه داده است.
- در مسیر گفتاری نیز هدف بررسی میزان توانایی ویژگی‌های عددی استخراج شده از سیگنال صوتی در تفکیک چهار زبان آلمانی، اسپانیایی، ایتالیایی و کره‌ای است.
- علاوه بر پیش‌بینی نظارت شده زبان، روش‌های بدون نظارت نیز بررسی می‌شوند تا مشخص شود آیا نمونه‌ها بدون استفاده از برچسب زبان در مرحله برازش، ساختار خوشه‌ای معناداری ایجاد می‌کنند یا خیر.

۵.۱ کاربردهای شناسایی زبان

سامانه‌های شناسایی خودکار زبان در بسیاری از حوزه‌های پردازش متن و گفتار کاربرد دارند. یکی از مهم‌ترین کاربردهای آن‌ها، استفاده به عنوان مرحله اولیه در سامانه‌های چندزبانه است.

برای مثال، در یک سامانه ترجمه ماشینی ممکن است کاربر متنی را بدون مشخص کردن زبان آن وارد کند. در چنین شرایطی، سامانه می‌تواند ابتدا زبان متن را شناسایی کرده و سپس مدل ترجمه مناسب را انتخاب کند.

در سامانه‌های پردازش گفتار نیز می‌توان پیش از اجرای مدل تبدیل گفتار به متن، زبان گوینده را تشخیص داد و مدل متناسب با آن زبان را فعال کرد.

از دیگر کاربردهای شناسایی خودکار زبان می‌توان به موارد زیر اشاره کرد:

- سامانه‌های ترجمه ماشینی؛
- سامانه‌های تبدیل گفتار به متن؛

- دستیارهای صوتی چندزبانه؛
- دسته‌بندی خودکار اسناد و متون؛
- مسیریابی درخواست‌ها در سامانه‌های چندزبانه؛
- جست‌وجو و بازیابی اطلاعات چندزبانه؛
- تحلیل محتوای شبکه‌های اجتماعی؛
- مراکز تماس و سامانه‌های پاسخ‌گویی خودکار؛
- مدیریت مجموعه‌های بزرگ فایل‌های متنی و گفتاری؛
- تفکیک خودکار محتوای متعلق به زبان‌های مختلف.

در بسیاری از این کاربردها، شناسایی زبان تنها یک خروجی مستقل نیست، بلکه مرحله‌ای مقدماتی برای انتخاب روش پردازش مناسب در مراحل بعدی محسوب می‌شود. بنابراین، خطا در تشخیص زبان می‌تواند به انتخاب مدل نامناسب و کاهش کیفیت کل سامانه منجر شود.

۶.۱ ابزارها و فناوری‌های مورد استفاده

پیاده‌سازی پروژه با استفاده از زبان برنامه‌نویسی **Python 3.12** انجام شده است. پایتون به دلیل برخورداری از کتابخانه‌های مناسب برای پردازش داده، یادگیری ماشین و پیاده‌سازی آزمایش‌های قابل تکرار، زبان اصلی این پروژه است.

مدیریت محیط و وابستگی‌های پروژه با استفاده از **Poetry** انجام شده است. نسخه کتابخانه‌ها در فایل `poetry.lock` ثبت شده‌اند تا اجرای مجدد پروژه در یک محیط مشابه امکان‌پذیر باشد. کدهای قابل استفاده مجدد در ساختار `src/` قرار دارند. اسکریپت‌های اجرایی در پوشه `scripts/` مسئول اجرای مراحل مختلف خط لوله هستند و نوت‌بوک‌های **Jupyter** برای توضیح مراحل، اجرای تحلیل‌ها و نمایش خروجی‌ها استفاده می‌شوند. کتابخانه‌ها و ابزارهای اصلی پروژه عبارت‌اند از:

Pandas

کتابخانه **Pandas** برای خواندن، مدیریت، پاک‌سازی، تبدیل و ذخیره داده‌های جدولی مورد استفاده قرار گرفته است.

NumPy

کتابخانه **NumPy** برای انجام محاسبات عددی و کار با آرایه‌ها و ماتریس‌ها استفاده شده است.

Scikit-learn

کتابخانه Scikit-learn برای پیاده‌سازی مراحل استخراج ویژگی متن، انتخاب ویژگی، پیش‌پردازش، تقسیم گروه‌آگاه داده، اعتبارسنجی متقابل، تنظیم ابرپارامترها، طبقه‌بندی، خوشه‌بندی، کاهش ابعاد و ارزیابی نتایج مورد استفاده قرار گرفته است.

SciPy

کتابخانه SciPy برای پشتیبانی از محاسبات علمی و عملیات مرتبط با نمایش‌های عددی و تنک مورد استفاده قرار گرفته است.

Matplotlib

کتابخانه Matplotlib برای تولید ماتریس‌های درهم‌ریختگی، نمودارهای مقایسه مدل‌ها و نمایش دوبعدی نتایج خوشه‌بندی استفاده شده است.

Jupyter Notebook

نوت‌بوک‌های Jupyter برای اجرای مرحله‌به‌مرحله خط لوله، نمایش جداول و نمودارها و مستندسازی نتایج استفاده شده‌اند. منطق اصلی و قابل استفاده مجدد پروژه در ماژول‌های پوشه src/ قرار دارد و نوت‌بوک‌ها از این ماژول‌ها استفاده می‌کنند.

Joblib

کتابخانه Joblib برای ذخیره و بارگذاری مدل‌های آموزش‌دیده، ابزارهای پیش‌پردازش و بسته‌های مورد نیاز برای استنتاج استفاده شده است.

PyYAML

کتابخانه PyYAML برای خواندن تنظیمات متمرکز پروژه از فایل‌های پیکربندی استفاده شده است.

Pytest

ابزار Pytest برای اجرای آزمون‌های خودکار مربوط به داده، تقسیم‌بندی، استخراج ویژگی، شمارش خانواده‌های مدل و استنتاج مورد استفاده قرار گرفته است.

پروژه به‌صورت محلی و روی CPU قابل اجرا است و برای خط پایه آن نیازی به GPU یا سرویس‌های ابری و پولی وجود ندارد. همچنین، چون مسیر گفتار از جدول ویژگی‌های از پیش استخراج‌شده آغاز می‌شود، Librosa و FFmpeg جزو وابستگی‌های الزامی خط لوله فعلی نیستند.

۷.۱ نمای کلی معماری سیستم

معماری پروژه به گونه‌ای طراحی شده است که منطق پردازش داده، آموزش مدل و ارزیابی از نوت‌بوک‌ها و اسکریپت‌های اجرایی جدا باشد.

اجزای اصلی پروژه عبارت‌اند از:

- پوشه `src/` برای نگهداری منطق اصلی و توابع قابل استفاده مجدد؛
- پوشه `scripts/` برای اجرای مراحل مختلف پروژه از طریق خط فرمان؛
- پوشه `notebooks/` برای توضیح، اجرای مرحله‌ای و نمایش نتایج؛
- پوشه `configs/` برای نگهداری مسیرها، پارامترها و تنظیمات قابل تکرار؛
- پوشه `artifacts/` برای ذخیره مدل‌ها، معیارها، جداول، پیش‌بینی‌ها، تخصیص خوشه‌ها و نمودارهای تولیدشده؛
- پوشه `tests/` برای آزمون‌های خودکار پروژه.

این جداسازی باعث می‌شود که منطق اصلی پروژه فقط به اجرای یک نوت‌بوک خاص وابسته نباشد و مراحل مختلف بتوانند از طریق اسکریپت‌ها یا نوت‌بوک‌ها اجرا شوند.

۸.۱ نمای کلی روند اجرای پروژه

پروژه از دو خط لوله مستقل تشکیل شده است. اگرچه هر دو مسیر در نهایت به طبقه‌بندی و خوشه‌بندی منتهی می‌شوند، ورودی و مراحل آماده‌سازی آن‌ها متفاوت است.

۱.۸.۱ روند اجرای مسیر متن

روند کلی مسیر متن به صورت زیر است:

فایل‌های متنی خام ← کشف و اعتبارسنجی داده ← پاک‌سازی متن ← استخراج ویژگی ← طبقه‌بندی و خوشه‌بندی ← ارزیابی و ذخیره نتایج

در مرحله نخست، فایل‌های متنی و ساختار پوشه‌ها بررسی می‌شوند. سپس متن‌ها با حفظ اطلاعات زبانی پاک‌سازی می‌شوند.

در مسیر طبقه‌بندی، نمایش متنی با ترکیب ویژگی‌های کاراکتری و واژگانی TF-IDF ساخته می‌شود. پس از آن، ویژگی‌های مناسب با استفاده از روش Chi-square انتخاب شده و چهار خانواده طبقه‌بندی با اعتبارسنجی متقابل گروه‌آگاه تنظیم و مقایسه می‌شوند.

در مسیر خوشه‌بندی، ویژگی‌های متنی بدون استفاده از برجسب زبان ساخته می‌شوند. سپس برای ایجاد یک نمایش فشرده‌تر از Truncated SVD استفاده شده و چهار الگوریتم K-Means، DBSCAN، Agglomerative Clustering و Gaussian Mixture روی داده‌ها اجرا می‌شوند.

۲.۸.۱ روند اجرای مسیر گفتار

روند کلی مسیر گفتار به صورت زیر است:

جدول ویژگی‌های گفتاری ← اعتبارسنجی داده و طرح‌واره ← تقسیم گروه آگاه ←
پیش‌پردازش عددی ← طبقه‌بندی و خوشه‌بندی ← ارزیابی و ذخیره نتایج

در این مسیر، جدول ویژگی‌های از پیش استخراج‌شده بدون تغییر مورد استفاده قرار می‌گیرد. ابتدا ساختار جدول، مقادیر گم‌شده، مقادیر نامتناهی، ستون هدف، شناسه‌ها و ویژگی‌های عددی بررسی می‌شوند.

پس از اعتبارسنجی، داده‌ها با حفظ استقلال گروه‌های مربوط به گوینده یا منبع، به بخش‌های آموزش و آزمون تقسیم می‌شوند. پیش‌پردازش نظارت‌شده درون خط لوله آموزش مدل قرار می‌گیرد تا اطلاعات داده آزمون وارد فرایند یادگیری نشود.

برای خوشه‌بندی گفتار نیز برجسب زبان هنگام پیش‌پردازش، کاهش ابعاد، انتخاب پارامتر یا برازش الگوریتم استفاده نمی‌شود.

۳.۸.۱ روند ارزیابی

در بخش طبقه‌بندی، مدل‌ها با استفاده از معیارهای زیر ارزیابی می‌شوند:

- Accuracy؛
- Macro Precision؛
- Macro Recall؛
- Macro F1-score؛
- Weighted F1-score؛
- ماتریس درهم‌ریختگی؛
- گزارش کامل طبقه‌بندی برای هر کلاس.

در بخش خوشه‌بندی، معیارهای داخلی مانند Calinski–Harabasz، Davies–Bouldin و Silhouette Score بدون نیاز به برجسب زبان محاسبه می‌شوند.

پس از برآزش، از معیارهای ARI، NMI و خلوص خوشه‌ها برای تفسیر میزان انطباق خوشه‌ها با زبان‌های واقعی استفاده می‌شود. این معیارهای خارجی در آموزش مدل یا انتخاب پارامترهای خوشه‌بندی دخالت ندارند.

در پایان، مدل‌های برتر، پیش‌پردازش‌های مورد نیاز برای استنتاج، جداول مقایسه، نمودارها و نتایج ماشین‌خوان ذخیره می‌شوند.

به این ترتیب، فصل حاضر تصویری کلی از مسئله، اهداف، محدوده داده‌ها، ابزارها و معماری پروژه ارائه داد. مبانی نظری ویژگی‌ها، الگوریتم‌ها و معیارهای ارزیابی در فصل دوم بررسی شده و جزئیات داده‌ها، پیاده‌سازی و نتایج آزمایش‌ها در فصل‌های بعد ارائه خواهند شد.

فصل ۲

مبانی نظری و مفاهیم پایه

در این فصل مفاهیم نظری و پیش‌زمینه‌های مورد نیاز برای درک روش‌های استفاده‌شده در پروژه بررسی می‌شوند. ابتدا مسئله شناسایی زبان از متن و گفتار معرفی شده و سپس مفاهیم یادگیری نظارت‌شده و بدون نظارت، روش‌های استخراج ویژگی از متن و صوت، الگوریتم‌های طبقه‌بندی و خوشه‌بندی، روش‌های کاهش ابعاد و در نهایت معیارهای ارزیابی مورد استفاده تشریح می‌شوند.

۱.۲ مقدمه

شناسایی خودکار زبان یکی از مسائل مهم در حوزه پردازش زبان طبیعی و پردازش گفتار محسوب می‌شود. هدف اصلی در این مسئله، تعیین زبان یک نمونه ورودی براساس ویژگی‌های قابل استخراج از آن است. ورودی سیستم می‌تواند یک متن یا یک فایل صوتی باشد. اگر مجموعه زبان‌های موجود به صورت

$$L = \{L_1, L_2, \dots, L_K\} \quad (۱.۲)$$

تعریف شود، هدف سیستم یافتن تابعی است که برای یک نمونه ورودی x ، یکی از زبان‌های مجموعه L را انتخاب کند:

$$f(x) \leftarrow L_i \quad (۲.۲)$$

در این پروژه مسئله شناسایی زبان در دو حوزه متن و گفتار بررسی شده است. اگرچه هدف نهایی در هر دو بخش یکسان است، اما نوع داده و نحوه استخراج ویژگی در آن‌ها متفاوت است. در ادامه این فصل، مفاهیم و روش‌هایی که مستقیماً در پیاده‌سازی پروژه استفاده شده‌اند مورد بررسی قرار می‌گیرند.

۲.۲ شناسایی زبان از متن و گفتار

۱.۲.۲ شناسایی زبان از متن

در شناسایی زبان مبتنی بر متن^۱، هدف تعیین زبان یک متن براساس ساختار نوشتاری آن است. زبان‌های مختلف از نظر نوع حروف، ساختار واژگان، ترکیب کاراکترها، فراوانی کلمات و ترتیب آن‌ها دارای الگوهای متفاوتی هستند.

حتی زبان‌هایی که از الفبای مشابه استفاده می‌کنند، معمولاً در نحوه قرارگیری حروف و ساختار کلمات تفاوت‌هایی دارند. به همین دلیل می‌توان با استخراج الگوهای آماری از متن، زبان آن را تشخیص داد.

در این پروژه برای نمایش عددی متون از ترکیب ویژگی‌های سطح کلمه و سطح کاراکتر استفاده شده است. این ویژگی‌ها با استفاده از روش TF-IDF استخراج می‌شوند.

^۱Text Language Identification

۲.۲.۲ شناسایی زبان از گفتار

در شناسایی زبان از گفتار^۲، ورودی سیستم یک سیگنال صوتی است. یک سیگنال صوتی دیجیتال را می‌توان به صورت دنباله‌ای از نمونه‌ها نمایش داد:

$$x[n], \quad n = 0, 1, \dots, N - 1 \quad (۳.۲)$$

که در آن $x[n]$ مقدار دامنه سیگنال در نمونه n است.

استفاده مستقیم از تمام نمونه‌های سیگنال به عنوان ورودی مدل‌های کلاسیک یادگیری ماشین مناسب نیست؛ زیرا هر فایل ممکن است شامل تعداد بسیار زیادی نمونه باشد و همچنین طول فایل‌ها نیز یکسان نباشد.

بنابراین لازم است هر فایل صوتی به یک بردار ویژگی با طول ثابت تبدیل شود. در این پروژه این کار با استخراج مجموعه‌ای از ویژگی‌های طیفی، زمانی و انرژی انجام شده است.

۳.۲ یادگیری ماشین در مسئله شناسایی زبان

یادگیری ماشین را می‌توان به روش‌های مختلف تقسیم‌بندی کرد. در این پروژه از دو رویکرد اصلی استفاده شده است:

- یادگیری نظارت‌شده؛

- یادگیری بدون نظارت.

۱.۳.۲ یادگیری نظارت‌شده

در یادگیری نظارت‌شده^۳، برای هر نمونه ورودی یک برچسب صحیح مشخص است. مجموعه داده آموزشی را می‌توان به صورت زیر نمایش داد:

$$D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\} \quad (۴.۲)$$

که در آن:

- x_i بردار ویژگی نمونه i

^۲Spoken Language Identification
^۳Supervised Learning

• y_i برچسب زبان نمونه؛

• N تعداد نمونه‌ها است.

مدل با استفاده از این داده‌ها رابطه میان ویژگی‌ها و زبان واقعی را یاد گرفته و سپس زبان نمونه‌های جدید را پیش‌بینی می‌کند.

مسئله طبقه‌بندی^۴ مورد استفاده در این پروژه در این گروه قرار می‌گیرد.

۲.۳.۲ یادگیری بدون نظارت

در یادگیری بدون نظارت^۵، برچسب واقعی نمونه‌ها در اختیار الگوریتم قرار نمی‌گیرد. در این حالت مجموعه داده به صورت

$$D = \{x_1, x_2, \dots, x_N\} \quad (۵.۲)$$

تعریف می‌شود.

الگوریتم تلاش می‌کند نمونه‌های مشابه را براساس ساختار ویژگی‌های آن‌ها در گروه‌هایی قرار دهد. این فرایند در مسئله خوشه‌بندی^۶ مورد استفاده قرار می‌گیرد.

در این پروژه، خوشه‌بندی برای بررسی این موضوع انجام شده است که آیا نمونه‌های متعلق به یک زبان، بدون در اختیار داشتن برچسب زبان، به صورت طبیعی در کنار یکدیگر قرار می‌گیرند یا خیر.

۴.۲ استخراج ویژگی از داده‌های متنی

الگوریتم‌های کلاسیک یادگیری ماشین نمی‌توانند متن خام را مستقیماً پردازش کنند. بنابراین لازم است متن به یک نمایش عددی تبدیل شود.

در این پروژه از روش TF-IDF در کنار Word N-Gram و Character N-Gram استفاده شده است.

۱.۴.۲ مفهوم N-Gram

N-Gram به دنباله‌ای شامل n عنصر متوالی گفته می‌شود. این عناصر می‌توانند کلمه یا کاراکتر باشند. برای مثال، در کلمه

^۴Classification

^۵Unsupervised Learning

^۶Clustering

language

برخی Character Bigram ها عبارت‌اند از:

la, an, ng, gu, ua, ag, ge

همچنین برای جمله

this is a language

برخی Word Bigram ها شامل موارد زیر هستند:

this is, is a, a language

در پروژه حاضر از ویژگی‌های زیر استفاده شده است:

- Character N-Gram با مرتبه‌های ۲ تا ۴؛

- Word N-Gram با مرتبه‌های ۱ تا ۲.

استفاده هم‌زمان از این دو نوع ویژگی باعث می‌شود هم اطلاعات مربوط به ساختار کلمات و هم الگوهای موجود در ترکیب حروف در اختیار مدل قرار گیرد.

۲.۴.۲ روش TF-IDF

روش TF-IDF^۷ یکی از روش‌های متداول برای تبدیل متن به نمایش عددی است. این روش از دو مؤلفه اصلی تشکیل شده است.

Term Frequency

مؤلفه Term Frequency میزان تکرار یک ویژگی t در سند d را اندازه‌گیری می‌کند. در حالت ساده می‌توان نوشت:

$$TF(t, d) = \text{count}(t, d) \quad (۶.۲)$$

در پروژه حاضر از Sublinear TF استفاده شده است. در این حالت برای فراوانی‌های غیرصفر داریم:

^۷Term Frequency–Inverse Document Frequency

$$TF(t, d) = 1 + \log(\text{count}(t, d)) \quad (۷.۲)$$

استفاده از لگاریتم باعث می‌شود تکرار بسیار زیاد یک ویژگی، اثر بیش از حدی بر مدل ایجاد نکند.

Inverse Document Frequency

مؤلفه IDF نشان می‌دهد یک ویژگی در مجموعه اسناد تا چه اندازه خاص یا عمومی است. فرم هموارشده آن را می‌توان به صورت زیر نمایش داد:

$$IDF(t) = \log\left(\frac{1 + N}{1 + df(t)}\right) + 1 \quad (۸.۲)$$

که در آن:

- N تعداد کل اسناد؛
- $df(t)$ تعداد اسنادی است که ویژگی t در آن‌ها وجود دارد.

در نهایت مقدار TF-IDF از رابطه زیر به دست می‌آید:

$$TFIDF(t, d) = TF(t, d) \times IDF(t) \quad (۹.۲)$$

بنابراین ویژگی‌هایی که در یک متن اهمیت زیادی دارند ولی در تمام متون به شکل گسترده تکرار نمی‌شوند، وزن بیشتری دریافت می‌کنند.

۳.۴.۲ ترکیب ویژگی‌های کاراکتری و کلمه‌ای

در پروژه، ویژگی‌های استخراج‌شده در سطح کاراکتر و کلمه با یکدیگر ترکیب شده‌اند. اگر ماتریس ویژگی‌های کاراکتری را با X_c و ماتریس ویژگی‌های واژگانی را با X_w نمایش دهیم، نمایش ترکیبی به صورت زیر خواهد بود:

$$X = [X_c \quad X_w] \quad (۱۰.۲)$$

این ترکیب باعث می‌شود اطلاعات مربوط به ساختار کلمات و الگوهای موجود در توالی کاراکترها به صورت هم‌زمان در اختیار مدل قرار گیرد. تنظیمات دقیق بردار سازهای کاراکتری و واژگانی در فصل سوم ارائه خواهند شد.

۴.۴.۲ انتخاب ویژگی با Chi-Square

برای انتخاب ویژگی‌های مناسب در بخش طبقه‌بندی متن از آزمون Chi-Square استفاده شده است. رابطه کلی آزمون کای دو به صورت زیر تعریف می‌شود:

$$\chi^2 = \sum \frac{(O - E)^2}{E} \quad (۱۱.۲)$$

که در آن:

• O مقدار مشاهده شده؛

• E مقدار مورد انتظار است.

هرچه مقدار χ^2 برای یک ویژگی بیشتر باشد، وابستگی آماری آن ویژگی به برچسب زبان بیشتر است.

از آنجاکه آزمون Chi-Square به برچسب زبان نیاز دارد، این مرحله فقط در مسیر طبقه‌بندی متن استفاده شده و در خوشه‌بندی متن به کار نرفته است.

برای جلوگیری از نشت اطلاعات، انتخاب ویژگی باید فقط با استفاده از بخش آموزشی انجام شود. تعداد دقیق ویژگی‌های انتخاب شده و نحوه اجرای این مرحله در فصل سوم تشریح خواهند شد.

۵.۲ استخراج ویژگی از داده‌های صوتی

هدف از استخراج ویژگی صوتی، تبدیل سیگنال خام با طول متغیر به یک بردار عددی با طول ثابت است.

خانواده ویژگی‌های صوتی مورد استفاده در ادامه معرفی می‌شوند و تعداد و ساختار دقیق ویژگی‌های نسخه نهایی در فصل سوم ارائه خواهد شد.

۱.۵.۲ ضرایب MFCC

یکی از مهم‌ترین ویژگی‌های مورد استفاده در پردازش گفتار، MFCC^A است.

^AMel-Frequency Cepstral Coefficients

مقیاس Mel برای نزدیک کردن نمایش فرکانس به نحوه درک انسان از صوت مورد استفاده قرار می‌گیرد.

تبدیل تقریبی فرکانس معمولی به مقیاس Mel به صورت زیر است:

$$Mel(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (12.2)$$

پس از محاسبه طیف و عبور آن از بانک فیلترهای Mel، از لگاریتم انرژی فیلترها و سپس تبدیل کسینوسی گسسته استفاده می‌شود.

یک فرم کلی برای محاسبه ضریب MFCC به صورت زیر است:

$$c_n = \sum_{k=1}^K \log(M_k) \cos \left[\frac{\pi n}{K} \left(k - \frac{1}{2} \right) \right] \quad (13.2)$$

که در آن:

- M_k انرژی فیلتر Mel شماره k ؛
- K تعداد فیلترها؛
- c_n ضریب MFCC است.

از آنجا که MFCC برای فریم‌های مختلف سیگنال محاسبه می‌شود، برای تبدیل آن به ویژگی با طول ثابت، میانگین و انحراف معیار هر ضریب استخراج شده است. میانگین ضریب i برابر است با:

$$\mu_i = \frac{1}{T} \sum_{t=1}^T c_i(t) \quad (14.2)$$

و انحراف معیار آن برابر است با:

$$\sigma_i = \sqrt{\frac{1}{T} \sum_{t=1}^T (c_i(t) - \mu_i)^2} \quad (15.2)$$

۲.۵.۲ Delta-Delta MFCC و Delta MFCC

MFCC وضعیت طیفی سیگنال را در هر لحظه نمایش می‌دهد، اما نحوه تغییر این ضرایب در طول زمان نیز می‌تواند اطلاعات مهمی در مورد گفتار ارائه دهد. برای ثبت تغییرات زمانی از ویژگی‌های Delta MFCC و Delta-Delta MFCC استفاده شده است. یک تقریب متداول برای Delta به صورت زیر است:

$$\Delta c_t = \frac{\sum_{n=1}^N n(c_{t+n} - c_{t-n})}{2 \sum_{n=1}^N n^2} \quad (۱۶.۲)$$

Delta بیانگر سرعت تغییر MFCC و Delta-Delta بیانگر تغییرات مرتبه دوم یا شتاب تغییر ضرایب است. برای ضرایب Delta و Delta-Delta نیز میانگین و انحراف معیار محاسبه شده است.

۳.۵.۲ Zero Crossing Rate

نرخ عبور از صفر یا Zero Crossing Rate تعداد دفعاتی را اندازه‌گیری می‌کند که علامت سیگنال در طول زمان تغییر می‌کند. رابطه آن را می‌توان به صورت زیر نمایش داد:

$$ZCR = \frac{1}{2(N-1)} \sum_{n=1}^{N-1} |\text{sgn}(x[n]) - \text{sgn}(x[n-1])| \quad (۱۷.۲)$$

برای ساخت یک نمایش با طول ثابت می‌توان از میانگین و انحراف معیار ZCR در فریم‌های مختلف استفاده کرد.

۴.۵.۲ ویژگی‌های طیفی

علاوه بر MFCC، تعدادی ویژگی برای توصیف شکل و توزیع انرژی طیف استخراج شده‌اند.

Spectral Centroid

Spectral Centroid مرکز جرم طیف فرکانسی را نشان می‌دهد:

$$SC = \frac{\sum_k f_k S_k}{\sum_k S_k} \quad (۱۸.۲)$$

که f_k فرکانس و S_k مقدار طیفی متناظر با آن است. مقادیر بالاتر این ویژگی به معنی تمرکز بیشتر انرژی در فرکانس‌های بالاتر است.

Spectral Rolloff

Spectral Rolloff فرکانسی است که درصد مشخصی از انرژی کل طیف در زیر آن قرار دارد. اگر f_r فرکانس Rolloff باشد:

$$\sum_{f_k \leq f_r} S_k \geq \alpha \sum_k S_k \quad (19.2)$$

که α نسبت مشخصی از انرژی کل طیف است.

Spectral Bandwidth

Spectral Bandwidth میزان پراکندگی طیف در اطراف Spectral Centroid را مشخص می‌کند:

$$BW = \sqrt{\frac{\sum_k S_k (f_k - SC)^2}{\sum_k S_k}} \quad (20.2)$$

Spectral Flatness

Spectral Flatness میزان تخت یا قله‌دار بودن طیف را اندازه‌گیری می‌کند. این معیار از نسبت میانگین هندسی به میانگین حسابی طیف به دست می‌آید:

$$SF = \frac{\left(\prod_{k=1}^K S_k\right)^{1/K}}{\frac{1}{K} \sum_{k=1}^K S_k} \quad (21.2)$$

این ویژگی می‌تواند اطلاعاتی درباره میزان نویزگونه یا ساختاریافته بودن طیف ارائه دهد.

۵.۵.۲ RMS Energy

انرژی RMS یا Root Mean Square Energy برای اندازه‌گیری سطح انرژی سیگنال استفاده می‌شود. رابطه آن به صورت زیر است:

$$RMS = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (22.2)$$

برای ساخت ویژگی‌های سطح فایل می‌توان از میانگین و انحراف معیار RMS استفاده کرد.

۶.۵.۲ مدت زمان فایل صوتی

مدت زمان فایل صوتی نیز به عنوان یک ویژگی در نظر گرفته شده است. اگر تعداد نمونه‌های سیگنال برابر N و نرخ نمونه‌برداری برابر f_s باشد، مدت زمان از رابطه زیر به دست می‌آید:

$$Duration = \frac{N}{f_s} \quad (23.2)$$

۶.۲ الگوریتم‌های طبقه‌بندی

در مسیر متن، الگوریتم‌های K-Nearest Neighbors، Decision Tree، Logistic Regression و Multi-nomial Naive Bayes بررسی شده‌اند. در مسیر گفتار نیز الگوریتم‌های Logistic Regression، Support Vector Machine، Random Forest و K-Nearest Neighbors مورد استفاده قرار گرفته‌اند. جزئیات تنظیمات و ابرپارامترهای این مدل‌ها در فصل چهارم ارائه خواهند شد.

۱.۶.۲ Logistic Regression

رگرسیون لجستیک^۹ با وجود نام آن، یکی از الگوریتم‌های متداول برای طبقه‌بندی است. در مسئله چندکلاسه، احتمال تعلق نمونه x به کلاس k را می‌توان با تابع Softmax نمایش داد:

$$P(y = k|x) = \frac{e^{w_k^T x + b_k}}{\sum_{j=1}^K e^{w_j^T x + b_j}} \quad (24.2)$$

کلاس دارای بیشترین احتمال به عنوان خروجی مدل انتخاب می‌شود:

$$\hat{y} = \arg \max_k P(y = k|x) \quad (25.2)$$

^۹Logistic Regression

در هر دو مسیر متن و گفتار، Logistic Regression به‌عنوان یک طبقه‌بند خطی مورد بررسی قرار گرفته است. منظم‌سازی برای کنترل پیچیدگی مدل و کاهش بیش‌برازش به کار می‌رود.

۲.۶.۲ Multinomial Naive Bayes

روش Naive Bayes یک الگوریتم احتمالاتی مبتنی بر قضیه بیز است:

$$P(C|X) = \frac{P(X|C)P(C)}{P(X)} \quad (۲۶.۲)$$

مدل Multinomial Naive Bayes به‌ویژه برای داده‌های متنی و ویژگی‌های مبتنی بر فراوانی یا TF-IDF کاربرد دارد.

در این روش از پارامتر هموارسازی α برای جلوگیری از صفر شدن احتمال برخی ویژگی‌ها استفاده می‌شود.

این الگوریتم در پروژه برای طبقه‌بندی داده‌های متنی استفاده شده است.

۳.۶.۲ Decision Tree

درخت تصمیم^{۱۰} با تقسیم پایایی فضای ویژگی‌ها، نمونه‌ها را به گروه‌های خالص‌تر تقسیم می‌کند. یکی از معیارهای رایج برای محاسبه ناخالصی یک گره، Gini Impurity است:

$$Gini = 1 - \sum_{k=1}^K p_k^2 \quad (۲۷.۲)$$

که p_k نسبت نمونه‌های کلاس k در گره مورد نظر است.

این الگوریتم در پروژه برای طبقه‌بندی متن استفاده شده است. کنترل پیچیدگی درخت می‌تواند احتمال بیش‌برازش را کاهش دهد.

۴.۶.۲ Support Vector Machine

ماشین بردار پشتیبان یا SVM^{۱۱} یکی از الگوریتم‌های اصلی مورد استفاده در بخش گفتار است. در حالت خطی، تابع تصمیم به صورت زیر تعریف می‌شود:

^{۱۰} Decision Tree

^{۱۱} Support Vector Machine

$$f(x) = w^T x + b \quad (28.2)$$

هدف SVM یافتن مرزی است که فاصله میان نزدیک‌ترین نمونه‌های کلاس‌ها و مرز تصمیم را بیشینه کند.

برای داده‌هایی که کاملاً جداسدنی نیستند، از مفهوم حاشیه نرم استفاده می‌شود. تابع هدف آن را می‌توان به صورت زیر نوشت:

$$\min_{w,b,\xi} \left(\frac{1}{2} \|w\|_2^2 + C \sum_{i=1}^N \xi_i \right) \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (29.2)$$

پارامتر C تعادل میان بزرگ‌بودن حاشیه و جریمه خطاهای آموزشی را کنترل می‌کند. برای جداسازی غیرخطی می‌توان از تابع کرنل استفاده کرد. کرنل مورد استفاده در این پروژه، RBF است:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|_2^2) \quad (30.2)$$

پارامتر γ محدوده اثر هر نمونه را کنترل می‌کند. مقادیر بررسی‌شده برای C و γ در فصل چهارم ارائه خواهند شد.

۵.۶.۲ K-Nearest Neighbors

الگوریتم KNN^{12} کلاس نمونه جدید را براساس نزدیک‌ترین نمونه‌های آموزشی مشخص می‌کند. یکی از معیارهای فاصله، فاصله اقلیدسی است:

$$d(x_i, x_j) = \sqrt{\sum_{m=1}^p (x_{im} - x_{jm})^2} \quad (31.2)$$

پس از محاسبه فاصله، K نزدیک‌ترین همسایه انتخاب شده و کلاس براساس رأی آن‌ها تعیین می‌شود.

برای نمایش‌های متنی می‌توان از فاصله کسینوسی استفاده کرد:

¹²K-Nearest Neighbors

$$d_{\text{cosine}}(x_i, x_j) = 1 - \frac{x_i^\top x_j}{\|x_i\|_2 \|x_j\|_2} \quad (32.2)$$

معیار فاصله و نحوه وزن‌دهی همسایه‌ها باید متناسب با نوع نمایش داده انتخاب شوند. جزئیات انتخاب‌های انجام‌شده در دو مسیر در فصل چهارم بیان خواهند شد.

۶.۶.۲ Random Forest

جنگل تصادفی^{۱۳} یک روش Ensemble است که از مجموعه‌ای از درخت‌های تصمیم استفاده می‌کند. خروجی نهایی در مسئله طبقه‌بندی از رأی اکثریت درخت‌ها به دست می‌آید:

$$\hat{y} = \text{mode}\{h_1(x), h_2(x), \dots, h_M(x)\} \quad (33.2)$$

استفاده از چندین درخت باعث کاهش حساسیت مدل به نویز و کاهش احتمال بیش‌برازش نسبت به یک درخت منفرد می‌شود. این الگوریتم در پروژه برای طبقه‌بندی ویژگی‌های گفتاری استفاده شده است.

۷.۲ الگوریتم‌های خوشه‌بندی

در فرآیند خوشه‌بندی، برچسب واقعی زبان‌ها در مرحله آموزش الگوریتم‌ها استفاده نشده و این برچسب‌ها تنها پس از تشکیل خوشه‌ها برای ارزیابی کیفیت تفکیک زبان‌ها به کار گرفته شده‌اند.

۱.۷.۲ K-Means

الگوریتم K-Means داده‌ها را به K خوشه تقسیم می‌کند و تلاش می‌کند فاصله نمونه‌ها از مرکز خوشه مربوط به خود را حداقل کند. تابع هدف به صورت زیر است:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \quad (34.2)$$

که در آن:

^{۱۳}Random Forest

- C_k خوشه شماره k ؛

- μ_k مرکز خوشه است.

۲.۷.۲ Hierarchical Clustering

در Agglomerative Hierarchical Clustering ابتدا هر نمونه به عنوان یک خوشه مستقل در نظر گرفته می‌شود.

سپس در هر مرحله دو خوشه نزدیک‌تر با یکدیگر ادغام می‌شوند تا در نهایت تعداد مورد نظر خوشه‌ها حاصل شود.

در روش Ward Linkage ادغامی انتخاب می‌شود که کمترین افزایش را در واریانس داخل خوشه‌ها ایجاد کند.

۳.۷.۲ Gaussian Mixture Model

در بخش متنی و گفتاری پروژه از Gaussian Mixture Model نیز استفاده شده است. در این روش فرض می‌شود توزیع داده از ترکیب چند توزیع Gaussian تشکیل شده باشد:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k) \quad (۳۵.۲)$$

که در آن:

- π_k وزن مؤلفه k ؛

- μ_k بردار میانگین؛

- Σ_k ماتریس کوواریانس است.

این روش برخلاف K-Means امکان محاسبه احتمال تعلق هر نمونه به خوشه‌های مختلف را فراهم می‌کند.

یکی از معیارهای قابل استفاده برای انتخاب پیچیدگی مدل مخلوط گاوسی، معیار اطلاعات بیزی یا BIC^{۱۴} است:

$$BIC = -2 \log(\hat{\mathcal{L}}) + q \log(N) \quad (۳۶.۲)$$

^{۱۴}Bayesian Information Criterion

که در آن $\hat{L}$ بیشینه درست‌نمایی و q تعداد پارامترهای مدل است. مقدار کمتر این معیار نشان‌دهنده تعادل مناسب‌تر میان برازش و پیچیدگی مدل است.

۴.۷.۲ DBSCAN

الگوریتم DBSCAN^{۱۵} یک روش خوشه‌بندی مبتنی بر چگالی است. دو پارامتر اصلی آن عبارت‌اند از:

- ϵ یا شعاع همسایگی؛
 - min_samples یا حداقل تعداد نقاط همسایه.
- یک نقطه در صورتی نقطه مرکزی محسوب می‌شود که:

$$|N_\epsilon(x)| \geq \text{MinPts} \quad (۳۷.۲)$$

یکی از مزایای مهم DBSCAN قابلیت تشخیص نمونه‌های نویزی است که معمولاً با برچسب 1- مشخص می‌شوند.

۸.۲ آماده‌سازی و کاهش ابعاد ویژگی‌ها

۱.۸.۲ استانداردسازی ویژگی‌ها

ویژگی‌های صوتی دارای مقیاس‌های عددی متفاوت هستند. این موضوع می‌تواند به‌ویژه بر الگوریتم‌های مبتنی بر فاصله اثرگذار باشد. استانداردسازی یک ویژگی به‌صورت زیر تعریف می‌شود:

$$z = \frac{x - \mu}{\sigma} \quad (۳۸.۲)$$

که در آن:

- μ میانگین ویژگی؛
- σ انحراف معیار ویژگی است.

^{۱۵}Density-Based Spatial Clustering of Applications with Noise

پس از استانداردسازی، ویژگی‌ها دارای میانگین تقریباً صفر و انحراف معیار تقریباً یک خواهند بود.

۲.۸.۲ Principal Component Analysis

روش PCA^{۱۶} برای کاهش ابعاد و حذف هم‌بستگی میان ویژگی‌ها استفاده می‌شود. اگر ماتریس کوواریانس داده را با Σ نمایش دهیم:

$$\Sigma v_i = \lambda_i v_i \quad (۳۹.۲)$$

که در آن:

- v_i بردار ویژه؛
- λ_i مقدار ویژه متناظر است.

مؤلفه‌هایی که مقدار ویژه بزرگ‌تری دارند، بخش بیشتری از واریانس داده را توضیح می‌دهند. در پروژه حاضر، این روش برای ایجاد نمایش کم‌بعد ویژگی‌های گفتاری در مسیر خوشه‌بندی استفاده شده است. تعداد مؤلفه‌ها و جزئیات اجرا در فصل سوم ارائه خواهند شد.

۳.۸.۲ Truncated SVD

ماتریس TF-IDF معمولاً دارای تعداد ابعاد بالا و ساختاری Sparse است. در خوشه‌بندی متن از Truncated SVD برای کاهش ابعاد فضای ویژگی استفاده شده است. تجزیه SVD به صورت زیر تعریف می‌شود:

$$X = U \Sigma V^T \quad (۴۰.۲)$$

در نسخه Truncated تنها تعداد محدودی از مؤلفه‌ها نگه داشته می‌شوند:

$$X \approx U_r \Sigma_r V_r^T \quad (۴۱.۲)$$

این روش امکان کاهش ابعاد ماتریس TF-IDF را بدون تبدیل مستقیم آن به یک ماتریس Dense فراهم می‌کند.

^{۱۶}Principal Component Analysis

در پروژه حاضر، این روش برای ایجاد نمایش کم بعد متن در مسیر خوشه بندی استفاده شده است. تعداد مؤلفه ها و نحوه نرمال سازی نمایش نهایی در فصل سوم بیان خواهند شد.

۹.۲ تنظیم و اعتبارسنجی مدل

۱.۹.۲ Cross Validation

برای ارزیابی قابل اعتمادتر مدل، از Cross Validation استفاده شده است. در این پروژه برای جلوگیری از قرار گرفتن نمونه های وابسته به یک منبع مشترک در بخش های مختلف آموزش و ارزیابی، از روش Stratified Group K-Fold استفاده شده است. در این روش علاوه بر حفظ نسبت نمونه های کلاس های مختلف در Fold ها، نمونه های متعلق به یک گروه مشترک در یک بخش قرار می گیرند. اگر امتیاز هر Fold برابر S_i باشد، امتیاز میانگین به صورت زیر محاسبه می شود:

$$CV = \frac{1}{K} \sum_{i=1}^K S_i \quad (۴۲.۲)$$

۲.۹.۲ Grid Search

برای انتخاب بهترین مقادیر ابرپارامترها می توان از روش Grid Search استفاده کرد. این روش ترکیب های مختلف پارامترهای تعیین شده را آزمایش کرده و هر ترکیب را با استفاده از Cross Validation ارزیابی می کند. در این پروژه، معیارهایی مانند Macro F1 برای مقایسه مدل ها و انتخاب تنظیمات مناسب مورد استفاده قرار گرفته اند. تعداد بخش های اعتبارسنجی و شبکه ابرپارامترهای هر مدل در فصل چهارم ارائه خواهند شد.

۱۰.۲ معیارهای ارزیابی طبقه بندی

۱.۱۰.۲ Accuracy

دقت کلی یا Accuracy نسبت تعداد پیش بینی های صحیح به کل پیش بینی ها است. در حالت چند کلاسه می توان نوشت:

$$Accuracy = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i) \quad (43.2)$$

۲.۱۰.۲ Precision

معیار Precision مشخص می‌کند از میان نمونه‌هایی که مدل به یک کلاس نسبت داده است، چه نسبتی واقعاً متعلق به آن کلاس بوده‌اند:

$$Precision = \frac{TP}{TP + FP} \quad (44.2)$$

۳.۱۰.۲ Recall

Recall نشان می‌دهد چه نسبتی از نمونه‌های واقعی یک کلاس به درستی تشخیص داده شده‌اند:

$$Recall = \frac{TP}{TP + FN} \quad (45.2)$$

۴.۱۰.۲ F1-Score

معیار F1-Score میانگین هارمونیک Precision و Recall است:

$$F1 = 2 \frac{Precision \times Recall}{Precision + Recall} \quad (46.2)$$

۵.۱۰.۲ میانگین‌های Macro و Weighted

در میانگین Macro، معیار برای هر کلاس به صورت مستقل محاسبه می‌شود و تمام کلاس‌ها وزن یکسانی دارند:

$$MacroPrecision = \frac{1}{K} \sum_{k=1}^K Precision_k \quad (47.2)$$

$$MacroRecall = \frac{1}{K} \sum_{k=1}^K Recall_k \quad (۴۸.۲)$$

$$MacroF1 = \frac{1}{K} \sum_{k=1}^K F1_k \quad (۴۹.۲)$$

در میانگین وزنی، سهم هر کلاس متناسب با تعداد نمونه‌های واقعی آن است. برای مثال:

$$WeightedF1 = \sum_{k=1}^K \frac{n_k}{N} F1_k \quad (۵۰.۲)$$

که در آن n_k تعداد نمونه‌های کلاس k و N تعداد کل نمونه‌ها است.

۶.۱۰.۲ Confusion Matrix

ماتریس درهم‌ریختگی^{۱۷} زبان واقعی نمونه‌ها را با زبان پیش‌بینی شده مقایسه می‌کند. اگر C_{ij} عضو سطر i و ستون j باشد:

$$C_{ij} = \text{نسبت داده شده‌اند } j \text{ که به کلاس } i \text{ تعداد نمونه‌های کلاس واقعی} \quad (۵۱.۲)$$

مقادیر روی قطر اصلی نشان‌دهنده پیش‌بینی‌های صحیح و مقادیر خارج از قطر بیانگر خطاهای مدل هستند.

۱۱.۲ معیارهای ارزیابی خوشه‌بندی

معیارهای خوشه‌بندی به دو دسته داخلی و خارجی تقسیم می‌شوند. معیارهای داخلی فقط از ویژگی‌ها و تخصیص خوشه‌ها استفاده می‌کنند. معیارهای خارجی، مانند ARI، NMI و Purity، فقط پس از تشکیل خوشه‌ها و برای مقایسه با برچسب‌های واقعی به کار می‌روند.

^{۱۷}Confusion Matrix

Silhouette Score ۱.۱۱.۲

معیار Silhouette Score برای بررسی انسجام داخل خوشه‌ها و میزان جدایی میان خوشه‌های مختلف استفاده می‌شود.

برای نمونه i :

- $a(i)$ میانگین فاصله نمونه با اعضای خوشه خودش؛
- $b(i)$ کمترین میانگین فاصله نمونه با یک خوشه دیگر است.

در نتیجه:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (۵۲.۲)$$

و داریم:

$$-1 \leq s(i) \leq 1 \quad (۵۳.۲)$$

مقادیر نزدیک به ۱ بیانگر کیفیت بهتر خوشه‌بندی هستند.

Calinski-Harabasz Index ۲.۱۱.۲

معیار Calinski-Harabasz نسبت پراکندگی بین خوشه‌ها به پراکندگی درون خوشه‌ها را اندازه‌گیری می‌کند.

مقدار بالاتر این معیار نشان‌دهنده جدایی بهتر خوشه‌ها و فشردگی بیشتر نمونه‌های داخل هر خوشه است.

Davies-Bouldin Index ۳.۱۱.۲

معیار Davies-Bouldin میزان شباهت میان هر خوشه و نزدیک‌ترین خوشه دیگر را بررسی می‌کند. مقدار کمتر این معیار نشان‌دهنده کیفیت بهتر خوشه‌بندی است.

Cluster Purity ۴.۱۱.۲

معیار Purity بررسی می‌کند اعضای هر خوشه تا چه اندازه به یک کلاس واقعی تعلق دارند. اگر مجموعه خوشه‌ها برابر

$$\Omega = \{\omega_1, \dots, \omega_K\} \quad (54.2)$$

باشد، Purity به صورت زیر تعریف می‌شود:

$$Purity(\Omega, C) = \frac{1}{N} \sum_k \max_j |\omega_k \cap c_j| \quad (55.2)$$

مقدار بیشتر Purity نشان‌دهنده تطابق بیشتر خوشه‌ها با زبان‌های واقعی است. این معیار به تعداد خوشه‌ها حساس است و ممکن است با تشکیل خوشه‌های کوچک‌تر افزایش یابد؛ بنابراین باید در کنار معیارهای دیگر تفسیر شود.

۵.۱۱.۲ Adjusted Rand Index

در بخش خوشه‌بندی، از Adjusted Rand Index برای مقایسه ساختار خوشه‌های ایجادشده با برچسب‌های واقعی استفاده شده است.

فرم کلی این معیار به صورت زیر است:

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]} \quad (56.2)$$

مقدار نزدیک به ۱ بیانگر تطابق بالا میان خوشه‌بندی و برچسب‌های واقعی است. مقدار یک نشان‌دهنده انطباق کامل، مقدار نزدیک به صفر نشان‌دهنده توافق مشابه حالت تصادفی و مقدار منفی نشان‌دهنده توافق کمتر از انتظار تصادفی است.

۶.۱۱.۲ Normalized Mutual Information

معیار NMI^{18} میزان اطلاعات مشترک میان تخصیص خوشه‌ها و برچسب‌های واقعی را اندازه‌گیری می‌کند. در نرمال‌سازی حسابی می‌توان نوشت:

$$NMI(C, Y) = \frac{2I(C; Y)}{H(C) + H(Y)} \quad (57.2)$$

که در آن $I(C; Y)$ اطلاعات متقابل و $H(C)$ و $H(Y)$ آنترپی خوشه‌ها و برچسب‌های واقعی

^{۱۸} Normalized Mutual Information

هستند. مقدار این معیار در بازه صفر تا یک قرار می‌گیرد و مقدار بزرگ‌تر نشان‌دهنده انطباق بیشتر است.

۱۲.۲ خلاصه و جمع‌بندی

در این فصل مفاهیم نظری مورد نیاز برای درک مراحل پیاده‌سازی پروژه بررسی شدند. ابتدا مسئله شناسایی زبان از متن و گفتار و تفاوت میان یادگیری نظارت‌شده و بدون نظارت معرفی شد.

در بخش متن، روش‌های استخراج ویژگی شامل TF-IDF، Word N-Gram، Character N-Gram و انتخاب ویژگی با Chi-Square تشریح شدند. در بخش گفتار نیز نحوه استخراج ویژگی‌های MFCC، Delta MFCC، Delta-Delta MFCC، ویژگی‌های طیفی، انرژی و مدت زمان بررسی شدند. تعداد و ساختار دقیق ویژگی‌های نسخه نهایی در فصل سوم ارائه خواهند شد.

همچنین الگوریتم‌های طبقه‌بندی و خوشه‌بندی مورد استفاده، روش‌های استانداردسازی و کاهش ابعاد، Cross Validation، Grid Search و معیارهای ارزیابی معرفی شدند.

مفاهیم ارائه‌شده در این فصل، مبانی نظری مراحل آماده‌سازی داده، پیاده‌سازی مدل‌ها و تحلیل نتایج در فصل‌های بعدی خواهند بود.

فصل ۳

داده‌ها و پیش‌پردازش

در این فصل، دو مجموعه داده مستقل متنی و گفتاری پروژه معرفی شده و مراحل عملی آماده‌سازی آن‌ها تشریح می‌شود. ابتدا ساختار و توزیع داده‌های متنی، نحوه پاک‌سازی و تبدیل آن‌ها به فضای ویژگی بررسی شده و سپس فرایندی که برای استانداردسازی فایل‌های صوتی، تولید فراداده و استخراج ویژگی‌های گفتاری انجام شده است ارائه می‌شود. هدف این فصل، تشریح روند تبدیل داده‌های خام به ورودی‌های قابل استفاده برای مدل‌های یادگیری ماشین است.

۱.۳ مقدمه

کیفیت داده ورودی یکی از عوامل مهم در عملکرد مدل‌های یادگیری ماشین است. حتی در صورت انتخاب یک الگوریتم مناسب، وجود داده‌های ناسازگار، ناقص یا دارای ساختار نامناسب می‌تواند بر نتیجه نهایی تأثیر منفی بگذارد. به همین دلیل، پیش از مرحله آموزش مدل لازم است داده‌های خام بررسی، پاک‌سازی و به یک نمایش مناسب تبدیل شوند.

در پروژه حاضر، دو مجموعه داده با ساختارهای متفاوت مورد استفاده قرار گرفته است. بخش نخست شامل فایل‌های متنی در چند زبان مختلف و بخش دوم شامل داده‌های گفتاری است که پس از پاک‌سازی صوت و استخراج ویژگی در قالب جدول عددی ذخیره شده‌اند.

از آنجا که ماهیت این دو نوع داده متفاوت است، مراحل پیش‌پردازش آن‌ها نیز به صورت مستقل طراحی شده است. با این حال، در هر دو بخش هدف نهایی یکسان است: تبدیل داده خام به ساختاری عددی، منظم و قابل استفاده در الگوریتم‌های یادگیری ماشین.

مبانی نظری روش‌های استخراج ویژگی در فصل دوم تشریح شد؛ بنابراین در این فصل تمرکز اصلی بر داده‌های واقعی، نحوه پیاده‌سازی و پارامترهایی است که در نسخه نهایی پروژه مورد استفاده قرار گرفته‌اند. مراحل پاک‌سازی و استخراج ویژگی صوتی پیش‌تر توسط نگارنده اجرا و فایل‌های features.csv و metadata.csv تولید شده‌اند؛ خط لوله مدل‌سازی فعلی این دو فایل را به‌عنوان ورودی فقط خواندنی دریافت می‌کند و استخراج ویژگی صوتی را دوباره اجرا نمی‌کند.

۲.۳ ساختار کلی داده‌های پروژه

داده‌های پروژه در دو مجموعه مستقل سازمان‌دهی شده‌اند:

- یک مجموعه مستقل از فایل‌های متنی برای شناسایی زبان از متن؛
- یک مجموعه گفتاری مستقل که فایل‌های صوتی پاک‌سازی شده، فراداده و جدول ویژگی‌های استخراج شده را در بر می‌گیرد.

در بخش متن، هر نمونه شامل یک فایل متنی، برچسب زبان و فراداده اختیاری استخراج شده از ساختار مسیر است. پس از بارگذاری و پاک‌سازی، متن‌ها به بردارهای عددی تبدیل می‌شوند.

در بخش گفتار نیز هر سطر از جدول نهایی با یک فایل صوتی متناظر است و شامل مسیر فایل، برچسب زبان، اطلاعات جنسیت گوینده و ویژگی‌های عددی استخراج شده است.

دو مجموعه داده به صورت مستقل پردازش شده‌اند. هیچ تطبیق سطر به سطر میان نمونه‌های متن و گفتار فرض نشده و هیچ ترکیب مستقیمی میان ویژگی‌های دو بخش در مرحله مدل‌سازی انجام نشده است؛ بنابراین نتایج آن‌ها نیز به‌عنوان یک آزمایش زوج شده تفسیر نمی‌شوند.

۳.۳ آماده‌سازی داده‌های متنی

۱.۳.۳ ساختار و توزیع داده‌های متنی

مجموعه داده متنی نهایی شامل ۶۰۸ نمونه از شش زبان آلمانی، اسپانیایی، ایتالیایی، کره‌ای، پرتهالی و ژاپنی است.

ساختار پوشه‌های داده به شکلی طراحی شده است که هر زبان دارای یک کد اختصاصی باشد. نگاشت مورد استفاده در پروژه در جدول زیر ارائه شده است.

جدول ۱.۳: توزیع نمونه‌های مجموعه داده متنی

زبان	کد پوشه	تعداد نمونه	میانگین طول متن
آلمانی	de	104	313.5
اسپانیایی	es	100	313.8
ایتالیایی	it	106	313.0
کره‌ای	ko	98	318.3
پرتهالی	po	100	314.9
ژاپنی	ja	100	315.0
مجموع	–	608	–

همان‌طور که جدول ۱.۳ نشان می‌دهد، تعداد نمونه‌ها بین زبان‌های مختلف تقریباً متوازن است و اختلاف تعداد نمونه‌های کلاس‌ها محدود است.

میانگین طول متن در این جدول پس از یکسان‌سازی فاصله‌ها و برحسب تعداد کاراکتر محاسبه شده است.

این ویژگی اهمیت دارد، زیرا عدم توازن شدید میان کلاس‌ها می‌تواند باعث شود مدل در فرایند آموزش به سمت زبان‌هایی که تعداد نمونه بیشتری دارند متمایل شود.

۲.۳.۳ بارگذاری و برچسب‌گذاری داده‌های متنی

برای بارگذاری داده‌ها از مسیر `data/raw/text` استفاده شده است. تمام فایل‌های دارای پسوند `.txt` به صورت بازگشتی از شش پوشه زبانی تعریف‌شده در فایل تنظیمات خوانده شده‌اند. نام پوشه نخست، کد زبان را مشخص می‌کند و سپس این کد به نام کامل زبان نگاشت می‌شود.

هر فایل متنی با کدگذاری UTF-8 و به صورت سخت‌گیرانه خوانده شده است؛ بنابراین در صورت

رخ‌دادن خطای رمزگشایی، اجرا با پیام خطا متوقف می‌شود و کاراکتر نامعتبر به صورت خاموش حذف نمی‌شود. در اجرای نهایی، هر ۶۰۸ فایل با موفقیت رمزگشایی شدند و هیچ کاراکتر جایگزین یونیکد در متن پاک‌سازی شده مشاهده نشد.

برای هر نمونه اطلاعات زیر ذخیره شده است:

- شناسه نمونه شامل مسیر نسبی فایل؛
- زبان نمونه؛
- اطلاعات جنسیت استخراج شده از پوشه دوم، در صورت وجود؛
- متن خام و متن پاک‌سازی شده؛
- شناسه گروه مربوط به گوینده یا منبع نمونه.

۳.۳.۳ پاک‌سازی متون

هدف اصلی مرحله پاک‌سازی، ایجاد یک نمایش یکنواخت از متن بدون حذف اطلاعاتی است که ممکن است برای تشخیص زبان مفید باشند.

پاک‌سازی مورد استفاده در این پروژه به صورت کنترل شده و حداقلی انجام شده است. در این مرحله، تمام فاصله‌ها، خطوط جدید و Tab های متوالی به یک فاصله واحد تبدیل شده و فاصله‌های ابتدا و انتهای متن حذف شده‌اند.

به صورت مفهومی عملیات انجام شده را می‌توان به شکل زیر نمایش داد:

Single Space ← Multiple Whitespaces

برخلاف برخی مسائل پردازش متن، در این پروژه کاراکترهای خاص زبان‌ها حذف نشده‌اند. همچنین علائم نگارشی، اعداد، حروف دارای Accent، Umlaut و کاراکترهای زبان‌های کره‌ای و ژاپنی حفظ شده‌اند.

در این مرحله، تبدیل حروف به حالت کوچک، ریشه‌یابی، بن‌واژه‌سازی، نویسه‌گردانی یا توکن‌سازی ویژه زبان انگلیسی انجام نشده است. تبدیل حروف لاتین به حالت کوچک بعداً درون بردارسازهای TF-IDF اعمال می‌شود.

دلیل این تصمیم آن است که برخی از این کاراکترها می‌توانند اطلاعات ارزشمندی درباره زبان یک نمونه در اختیار سیستم قرار دهند.

پس از انجام پاک‌سازی، طول متن‌ها نیز برحسب تعداد کاراکتر محاسبه شده است.

در مرحله کنترل کیفیت مشخص شد که هیچ نمونه‌ای پس از پاک‌سازی خالی نشده است؛ بنابراین:

تعداد نمونه قبل از پاک‌سازی = ۶۰۸

و

تعداد نمونه بعد از پاک‌سازی = ۶۰۸

یکسان‌سازی فاصله‌ها محتوای ۱۴ نمونه را تغییر داد. سیاست پروژه برای متن‌های کاملاً تکراری این است که پس از یکسان‌سازی فاصله‌ها، اولین مسیر براساس ترتیب واژگانی نگهداری و موارد بعدی حذف شوند؛ با این حال، در اجرای نهایی هیچ متن کاملاً تکراری حذف نشد.

۴.۳.۳ تبدیل متون به فضای ویژگی

پس از پاک‌سازی، متون به بردارهای عددی تبدیل شده‌اند. همان‌طور که در فصل دوم تشریح شد، برای استخراج اطلاعات از دو سطح متفاوت متن، دو بردارساز مستقل در نظر گرفته شده است. برای بخش کاراکتری تنظیمات زیر مورد استفاده قرار گرفته‌اند:

- نوع تحلیل: char_wb
 - بازه N-Gram: ۲ تا ۴
 - حداکثر تعداد ویژگی: ۳۰۰۰
 - sublinear_tf=True
 - min_df=1
 - تبدیل حروف لاتین به حالت کوچک با lowercase=True.
- برای ویژگی‌های سطح کلمه نیز تنظیمات زیر استفاده شده‌اند:

- نوع تحلیل: word
- بازه N-Gram: ۱ تا ۲
- حداکثر تعداد ویژگی: ۲۰۰۰
- sublinear_tf=True
- min_df=1
- lowercase=True

دو مجموعه ویژگی با استفاده از FeatureUnion با یکدیگر ترکیب شده‌اند. در مسیر طبقه‌بندی، بردارسازها فقط روی بخش آموزشی برازش شده‌اند. در اجرای نهایی، واژگان حاصل شامل ۵۰۰۰ ویژگی بوده است که از سقف ۳۰۰۰ ویژگی کاراکتری و ۲۰۰۰ ویژگی واژگانی تشکیل می‌شود. ابعاد ماتریس‌های واقعی تولیدشده برای مسیر طبقه‌بندی به صورت زیر بوده است:

جدول ۲.۳: ابعاد فضای ویژگی متنی

ابعاد ماتریس	فضای ویژگی
397×5000	ترکیب ویژگی‌های آموزشی پیش از انتخاب ویژگی
211×5000	ترکیب ویژگی‌های آزمون پیش از انتخاب ویژگی
397×50	ویژگی‌های آموزشی پس از انتخاب ویژگی
211×50	ویژگی‌های آزمون پس از انتخاب ویژگی

برای مسیر خوشه‌بندی، انتخاب ویژگی نظارت‌شده Chi-Square استفاده نشده است. بردارسازی روی هر ۶۰۸ متن بدون استفاده از برچسب زبان انجام شده و سپس با Truncated SVD به ۵۰ مؤلفه کاهش یافته است. در پایان نیز هر بردار با نرم L2 نرمال‌سازی شده و ماتریسی با ابعاد 608×50 برای خوشه‌بندی ایجاد شده است.

۵.۳.۳ آماده‌سازی برچسب‌ها و انتخاب ویژگی

برچسب زبان‌ها در مسیر طبقه‌بندی متن به صورت رشته‌ای نگهداری شده‌اند و مدل‌های scikit-learn مستقیماً با همین برچسب‌ها آموزش می‌بینند؛ بنابراین در نسخه نهایی بخش متن، مرحله جداگانه‌ای برای LabelEncoder وجود ندارد. کلاس‌های نهایی عبارت‌اند از:

german, italian, japanese, korean, portuguese, spanish

در مرحله بعد، فضای ترکیبی شامل ۵۰۰۰ ویژگی با استفاده از SelectKBest و معیار Chi-Square کاهش یافته است. تعداد ویژگی‌های انتخاب‌شده برابر با:

$$K_{\text{best}} = 50 \quad (۱.۳)$$

این انتخاب‌گر فقط روی بخش آموزشی برازش شده است. در نتیجه، ماتریس‌های نهایی آموزش و آزمون دارای ابعاد زیر هستند:

$$X_{\text{text,train}} \in \mathbb{R}^{397 \times 50}, \quad X_{\text{text,test}} \in \mathbb{R}^{211 \times 50} \quad (۲.۳)$$

این کاهش ابعاد باعث می‌شود تنها ویژگی‌هایی که در داده آموزشی ارتباط بیشتری با برچسب زبان دارند برای طبقه‌بندی نگهداری شوند. به دلیل وابستگی این روش به برچسب، ۵۰ ویژگی منتخب در خوشه‌بندی متن استفاده نشده‌اند.

۶.۳.۳ جلوگیری از نشت اطلاعات در بخش متن

یکی از نکات مهم در فرایند ارزیابی مدل، جلوگیری از Data Leakage است. اگر بردار ساز TF-IDF یا روش انتخاب ویژگی پیش از تقسیم داده‌های آموزش و آزمون روی کل مجموعه داده برآش شود، اطلاعات مربوط به داده آزمون می‌تواند به صورت غیرمستقیم وارد فرایند آموزش شود و نتیجه ارزیابی بیش از حد خوش‌بینانه باشد. برای تشکیل گروه‌ها، شناسه ۹ رقمی ابتدای نام فایل استخراج و با نام زبان ترکیب شده است. فایل‌هایی که نام آن‌ها با این الگو منطبق نیست، هر کدام یک گروه یکتا دریافت کرده‌اند. در داده نهایی ۲۸۴ گروه وجود داشت که ۴۴ گروه بیش از یک نمونه داشتند. سپس با استفاده از نخستین بخش یک تقسیم‌بندی سه‌قسمتی Stratified Group K-Fold، ۳۹۷ نمونه به مجموعه آموزش و ۲۱۱ نمونه به مجموعه آزمون اختصاص یافت. همه زبان‌ها در هر دو بخش حضور دارند و تعداد گروه‌های مشترک میان آموزش و آزمون صفر است. در بخش طبقه‌بندی، مراحل پاک‌سازی، استخراج TF-IDF و انتخاب ویژگی Chi-Square درون خط لوله مدل قرار گرفته‌اند. این اجزا در هر بار آموزش و هر دور اعتبارسنجی فقط روی داده آموزشی fit می‌شوند و برای داده اعتبارسنجی یا آزمون فقط transform انجام می‌شود. همچنین پیش از آموزش مدل، وجود متن‌های یکسان پس از نرمال‌سازی میان مجموعه آموزش و آزمون بررسی شد. تعداد متن‌های مشترک و نیز تعداد گروه‌های مشترک در اجرای نهایی هر دو برابر صفر بود.

۷.۳.۳ خروجی‌های مرحله آماده‌سازی متن

برای امکان استفاده مجدد از نتایج، خروجی‌های اصلی مرحله پیش‌پردازش و استخراج ویژگی ذخیره شده‌اند.

مهم‌ترین آن‌ها عبارت‌اند از:

- `artifacts/text/audit/text_audit.json` برای خلاصه کشف داده، کنترل کیفیت، توزیع کلاس‌ها و اطلاعات تقسیم داده؛
- `artifacts/text/audit/class_distribution.csv` برای توزیع زبان‌ها؛

- `artifacts/text/preprocessing/cleaning_counts.csv` برای تعداد نمونه‌ها در مراحل پاک‌سازی؛
- `artifacts/text/splits/holdout_split.csv` برای ثبت گروه و بخش هر نمونه؛
- `artifacts/text/features/training_vectorizer.joblib` و بردارسازی برازش‌شده روی داده آموزشی؛
- `artifacts/text/features/training_feature_selector.joblib` برای انتخاب‌گر ۵۰ ویژگی برازش‌شده روی داده آموزشی؛
- `artifacts/text/features/feature_statistics.json` برای تنظیمات و ابعاد واقعی ماتریس‌ها.

در نسخه نهایی، ماتریس‌های TF-IDF کل داده به صورت فایل‌های مستقل NPZ ذخیره نشده‌اند؛ زیرا برای طبقه‌بندی باید درون هر خط لوله و فقط از داده آموزشی ساخته شوند. نمایش بدون برچسب مخصوص خوشه‌بندی نیز همراه با مدل کاهش ابعاد در بخش مصنوعات خوشه‌بندی ذخیره شده است.

۴.۳ آماده‌سازی داده‌های گفتاری

۱.۴.۳ ساختار و توزیع داده‌های صوتی

مجموعه داده گفتاری نهایی شامل ۷۲۰ فایل صوتی از چهار زبان آلمانی، اسپانیایی، ایتالیایی و کره‌ای است.

تعداد نمونه‌های هر زبان کاملاً برابر بوده و برای هر زبان ۱۸۰ فایل در نظر گرفته شده است.

جدول ۳.۳: توزیع نمونه‌های صوتی براساس زبان

زبان	برچسب	تعداد نمونه
آلمانی	de	180
اسپانیایی	es	180
ایتالیایی	it	180
کره‌ای	ko	180
مجموع	—	720

داده‌ها از نظر جنسیت گوینده نیز متوازن هستند:

جدول ۴.۳: توزیع نمونه‌های صوتی براساس جنسیت گوینده

جنسیت	تعداد نمونه
Female	360
Male	360
مجموع	720

توازن کامل کلاس‌های زبان باعث می‌شود مقایسه عملکرد مدل روی زبان‌های مختلف تحت تأثیر اختلاف شدید تعداد نمونه‌ها قرار نگیرد.

۲.۴.۳ استانداردسازی فایل‌های صوتی

فایل‌های صوتی خام در زمان آماده‌سازی داده گفتار، در مسیر `data/raw` نسبت به پوشه اسکریپت پاک‌سازی قرار دارد و عمدتاً دارای قالب MP3 هستند.

برای ایجاد یک ساختار صوتی یکسان، اسکریپت PowerShell تمام فایل‌های صوتی را به صورت بازگشتی پیمایش کرده و با استفاده از FFmpeg نسخه استاندارد آن‌ها را در مسیر `data/clean` تولید کرده است.

ساختار نسبی پوشه‌ها نیز در این فرایند حفظ شده است.

تنظیمات فعال مورد استفاده در تبدیل فایل‌های صوتی شامل موارد زیر است:

- تبدیل فایل‌ها از MP3 به WAV؛
- تبدیل صدا به حالت تک‌کاناله با "1 -ac"؛
- بازنمونه‌برداری با نرخ 16 kHz؛
- استفاده از کدگذاری "pcm_s16le"؛
- نرمال‌سازی شدت صوت با فیلتر `loudnorm`.

پارامترهای نرمال‌سازی شدت صوت در نسخه نهایی به صورت زیر تنظیم شده‌اند:

$$I=-16, TP=-1.5, LRA=11$$

که هدف از آن کاهش اختلاف شدید سطح صوت میان فایل‌های مختلف و ایجاد شرایط یکنواخت‌تر برای استخراج ویژگی است.

مراحل اصلی پیش‌پردازش شامل تبدیل قالب، تک‌کاناله‌سازی، بازنمونه‌برداری و نرمال‌سازی شدت صوت هستند.

این عملیات مرحله ایجاد داده بوده است و در خط لوله جاری آموزش مدل دوباره اجرا نمی‌شود؛ ورودی بخش گفتار از فایل ویژگی از پیش‌استخراج‌شده آغاز می‌شود.

۳.۴.۳ ایجاد فایل فراداده

پس از آماده‌سازی فایل‌های صوتی، برای مدیریت سیستماتیک نمونه‌ها یک فایل Metadata ایجاد شده است.

ساختار مسیر فایل‌ها به صورت کلی مشابه الگوی زیر است:

`data/clean/<language>/<gender>/<file>.wav`

اسکرپت تولید فراداده، زبان و جنسیت را مستقیماً از ساختار مسیر استخراج کرده و برای هر نمونه سه ستون زیر ایجاد می‌کند:

• `filepath`: مسیر نسبی فایل صوتی؛

• `lang`: برچسب زبان؛

• `gender`: جنسیت گوینده.

فایل نهایی `metadata.csv` دارای ۷۲۰ سطر و ۳ ستون است و هیچ مقدار گم‌شده‌ای در آن مشاهده نشده است.

استفاده از مسیر نسبی به جای مسیر کامل سیستم نیز باعث می‌شود ساختار پروژه قابلیت جابه‌جایی بیشتری میان سیستم‌های مختلف داشته باشد.

هنگام بارگذاری داده در خط لوله فعلی، فراداده براساس ستون `filepath` با `features.csv` هم‌تراز می‌شود و برابری مقادیر مشترک کنترل می‌گردد؛ بنابراین اتصال دو فایل به ترتیب تصادفی سطرها وابسته نیست.

۴.۴.۳ پیاده‌سازی استخراج ویژگی‌های صوتی

پس از تولید فراداده، در دفترچه استخراج ویژگی هر فایل صوتی با استفاده از کتابخانه Librosa خوانده شده است.

تنظیمات اصلی مرحله بارگذاری عبارت‌اند از:

• نرخ نمونه‌برداری: 16000 Hz؛

• تبدیل به سیگنال تک‌کاناله: `mono=True`

• تعداد ضرایب پایه MFCC: 20.

برای تبدیل ویژگی‌های وابسته به زمان به یک بردار با طول ثابت، میانگین و انحراف معیار آن‌ها در طول فریم‌های فایل صوتی محاسبه شده است. ویژگی‌های نهایی از گروه‌های زیر تشکیل شده‌اند:

جدول ۵.۳: ساختار ویژگی‌های استخراج‌شده از هر فایل صوتی

تعداد ویژگی نهایی	گروه ویژگی
40	MFCC
40	Delta MFCC
40	Delta-Delta MFCC
2	Zero Crossing Rate
2	Spectral Centroid
2	Spectral Rolloff
2	Spectral Bandwidth
2	Spectral Flatness
2	RMS Energy
1	Duration
133	مجموع

بنابراین برای هر فایل صوتی یک بردار شامل ۱۳۳ مقدار عددی ایجاد شده است. پس از اضافه شدن سه ستون توصیفی `filepath`، `lang` و `gender`، فایل نهایی دارای ۱۳۶ ستون است. این فایل با نام `features.csv` ذخیره شده و نقطه شروع بخش گفتار در خط لوله آزمایش‌های فعلی است.

۵.۴.۳ کنترل کیفیت ویژگی‌های صوتی

استخراج ویژگی روی تمام ۷۲۰ نمونه صوتی انجام شده است. کد استخراج ویژگی به شکلی طراحی شده است که در صورت بروز خطا برای یک فایل، مسیر آن فایل و متن خطا ذخیره شده و نمونه معیوب از مجموعه نهایی حذف شود.

در اجرای نهایی پروژه:

- تعداد فایل‌های ورودی برابر ۷۲۰ بود؛
 - تعداد فایل‌های پردازش‌شده موفق برابر ۷۲۰ بود؛
 - هیچ نمونه‌ای به علت خطای استخراج ویژگی حذف نشد؛
 - تعداد مقادیر NaN در فایل نهایی برابر صفر بود.
 - تعداد مقادیر بی‌نهایت، سطرهای کاملاً تکراری و شناسه‌های فایل تکراری برابر صفر بود؛
 - هیچ ویژگی ثابت یا ویژگی نزدیک به ثابت با آستانه ۹۹ درصد مشاهده نشد.
- در نتیجه ابعاد فایل ویژگی نهایی برابر است با:

$$720 \times 136 \quad (۳.۳)$$

که ۱۳۳ ستون آن ویژگی عددی هستند.

برای کنترل وابستگی نمونه‌های یک گوینده یا منبع، شناسه گروه از ۹ رقم ابتدای نام فایل استخراج شد. هر ۷۲۰ مسیر با این الگو منطبق بودند و در مجموع ۷۸ گروه به دست آمد. تقسیم نگه‌داشته‌شده با نخستین بخش یک Stratified Group K-Fold پنج‌قسمتی انجام شد و شامل ۵۷۲ نمونه آموزشی و ۱۴۸ نمونه آزمون بود؛ هیچ گروه مشترکی میان دو بخش وجود نداشت.

۶.۴.۳ بررسی مدت زمان نمونه‌های صوتی

از آنجا که طول فایل‌های صوتی یکسان نیست، مدت زمان هر فایل نیز محاسبه و به عنوان یکی از ویژگی‌های مجموعه داده ذخیره شده است.

آمار کلی مدت زمان فایل‌ها در جدول زیر ارائه شده است.

جدول ۶.۳: آمار مدت زمان نمونه‌های صوتی

شاخص	مدت زمان برحسب ثانیه
تعداد نمونه	720
میانگین	63.19
انحراف معیار	55.22
کمینه	39.00
میانه	60.68
چارک اول	58.00
چارک سوم	63.91
بیشینه	1534.25

اکثر فایل‌های مجموعه داده دارای مدت زمانی در حدود یک دقیقه هستند. با این حال، یک نمونه از زبان ایتالیایی دارای مدت زمان تقریباً ۱۵۳۴ ثانیه است که نسبت به سایر نمونه‌ها بسیار طولانی‌تر محسوب می‌شود.

این نمونه در روند فعلی پروژه حذف نشده و در مجموعه نهایی باقی مانده است. از آنجا که مدت زمان نیز یکی از ویژگی‌های ورودی مدل محسوب می‌شود، وجود چنین مقدار دورافتاده‌ای باید هنگام تحلیل نتایج و اثر استانداردسازی ویژگی‌ها مورد توجه قرار گیرد.

ثبت و گزارش این مورد به عنوان بخشی از کنترل کیفیت داده، امکان تفسیر دقیق‌تر نتایج مدل را فراهم می‌کند.

۵.۳ داده‌های نهایی آماده برای مدل‌سازی

پس از تکمیل مراحل پیش‌پردازش، دو مجموعه داده نهایی برای بخش متن و گفتار ایجاد شده‌اند. در بخش متنی، مجموعه داده پاک‌سازی شده شامل ۶۰۸ نمونه از شش زبان است. برای ارزیابی طبقه‌بندی، ۳۹۷ نمونه در بخش آموزش و ۲۱۱ نمونه در بخش آزمون گروه‌ناهم‌پوشان قرار گرفته‌اند. فضای ویژگی TF-IDF که فقط روی داده آموزشی برازش شده، ۵۰۰۰ بعد دارد و با انتخاب ویژگی Chi-Square به ۵۰ بعد کاهش یافته است.

بنابراین ورودی‌های مسیر طبقه‌بندی متن به صورت زیر قابل نمایش هستند:

$$X_{\text{text,train}} \in \mathbb{R}^{397 \times 50}, \quad X_{\text{text,test}} \in \mathbb{R}^{211 \times 50} \quad (۴.۳)$$

در مسیر خوشه‌بندی متن، هر ۶۰۸ نمونه بدون استفاده از برجسب زبان بردارسازی شده و پس از Truncated SVD و نرمال‌سازی L2 نمایشی با ابعاد زیر ایجاد شده است:

$$X_{\text{text,cluster}} \in \mathbb{R}^{608 \times 50} \quad (۵.۳)$$

در بخش گفتار، فایل ویژگی دارای ۷۲۰ نمونه و ۱۳۶ ستون است.
سه ستون

gender, lang, filepath

به عنوان اطلاعات توصیفی در نظر گرفته می‌شوند.
برای تشکیل ورودی مدل، این سه ستون از ماتریس ویژگی حذف شده و ۱۳۳ ستون عددی باقی می‌مانند:

$$X_{\text{speech}} \in \mathbb{R}^{720 \times 133} \quad (۶.۳)$$

برجسب هدف در بخش گفتار از ستون lang استخراج می‌شود.
ستون gender به عنوان ویژگی ورودی مدل استفاده نشده است و تنها برای توصیف و بررسی توازن مجموعه داده نگهداری می‌شود.
در ارزیابی طبقه‌بندی گفتار، ۵۷۲ نمونه برای آموزش و ۱۴۸ نمونه برای آزمون گروه‌ناهم‌پوشان استفاده شده‌اند. جایگزینی احتمالی مقادیر گمشده و استانداردسازی برای مدل‌های حساس به مقیاس در داخل خط لوله و فقط با داده آموزشی برازش می‌شوند. هرچند در جدول نهایی مقدار گمشده‌ای وجود ندارد، مرحله جایگزینی میانه به صورت دفاعی در خط لوله حفظ شده است.
برای خوشه‌بندی گفتار، هر ۷۲۰ نمونه بدون استفاده از برجسب زبان پس از جایگزینی میانه، استانداردسازی و PCA به ۳۰ مؤلفه کاهش یافته‌اند:

$$X_{\text{speech,cluster}} \in \mathbb{R}^{720 \times 30} \quad (۷.۳)$$

به این ترتیب، در پایان مرحله پیش‌پردازش، هر دو مجموعه داده به فرم مناسب برای ورود به مراحل طبقه‌بندی و خوشه‌بندی تبدیل شده‌اند.

۶.۳ خلاصه و جمع‌بندی

در این فصل، مراحل عملی آماده‌سازی داده‌های متنی و گفتاری تشریح شد. در بخش متن، ۶۰۸ نمونه از شش زبان بارگذاری و پس از یک پاک‌سازی حداقلی، با استفاده از ویژگی‌های سطح کلمه و کاراکتر به فضای عددی تبدیل شدند. برای طبقه‌بندی، فضای ترکیبی ۵۰۰۰ بعدی فقط روی داده آموزشی برازش و با انتخاب ویژگی به ۵۰ بعد کاهش یافت. برای خوشه‌بندی نیز یک نمایش ۵۰ بعدی مستقل با Truncated SVD و بدون استفاده از برچسب ساخته شد. تقسیم گروه‌آگاه و قرارگرفتن تمام مراحل وابسته به داده درون زنجیره آموزش، از ورود اطلاعات بخش آزمون به فرایند برازش جلوگیری می‌کند.

در بخش گفتار، ۷۲۰ نمونه از چهار زبان به صورت کاملاً متوازن مورد استفاده قرار گرفتند. نگارنده فایل‌های صوتی را به قالب استاندارد تک‌کاناله با نرخ نمونه‌برداری ۱۶ کیلوهرتز تبدیل و شدت آن‌ها را نرمال‌سازی کرده و سپس برای هر نمونه ۱۳۳ ویژگی عددی استخراج کرده است. بررسی نهایی نشان داد که هیچ فایل نامعتبر، مقدار گمشده یا مقدار بی‌نهایتی در داده نهایی وجود ندارد. خط لوله آزمایش فعلی از همین جدول استخراج‌شده آغاز می‌شود و برای جداسازی آموزش و آزمون از گروه‌های گوینده یا منبع استفاده می‌کند.

خروجی مراحل این فصل، دو مجموعه داده مستقل و آماده برای ورود به الگوریتم‌های یادگیری ماشین است. نحوه آموزش مدل‌های طبقه‌بندی و خوشه‌بندی، تنظیم پارامترها و نتایج حاصل از اجرای آن‌ها در فصل بعد بررسی خواهد شد.

فصل ۴

پیاده‌سازی و نتایج

در این فصل، نحوه پیاده‌سازی مسیرهای طبقه‌بندی و خوشه‌بندی برای دو مجموعه داده مستقل متن و گفتار ارائه می‌شود. تمام نتایج گزارش شده از اجرای نهایی پروژه و مصنوعات ذخیره شده آن استخراج شده‌اند. مدل منتخب متن، Logistic Regression، به دقت ۰.۹۹۵۳ و مدل منتخب گفتار، KNN، به دقت ۰.۹۹۳۲ روی آزمون نهایی رسیده‌اند. خوشه‌بندی متن جدایی بسیار قوی زبان‌ها را نشان داد، اما در خوشه‌بندی گفتار بهترین ساختار داخلی الزاماً با زبان واقعی منطبق نبود. برای انتخاب طبقه‌بندها از میانگین Macro F1 در اعتبارسنجی متقاطع گروه‌آگاه روی داده آموزشی استفاده شده و مجموعه آزمون نهایی در تنظیم ابرپارامتر یا انتخاب مدل نقشی نداشته است. در خوشه‌بندی نیز برچسب زبان هنگام ساخت نمایش ویژگی، برازش مدل و انتخاب پارامترها استفاده نشده و معیارهای خارجی تنها پس از تشکیل خوشه‌ها محاسبه شده‌اند.

۱.۴ پیاده‌سازی بخش شناسایی زبان از متن

در این بخش، فرایند پیاده‌سازی مسیر شناسایی زبان از متن ارائه می‌شود. ورودی این بخش، فایل‌های متنی خام با کدگذاری UTF-8 است. پس از بارگذاری داده‌ها، دو مسیر مستقل برای طبقه‌بندی و خوشه‌بندی ساخته می‌شود. در مسیر طبقه‌بندی، مراحل پاک‌سازی، استخراج ویژگی و انتخاب ویژگی در قالب یک خط لوله یکپارچه قرار گرفته‌اند تا از نشت اطلاعات میان داده‌های آموزش، اعتبارسنجی و آزمون جلوگیری شود. برای مسیر خوشه‌بندی نیز یک نمایش ویژگی مستقل و بدون استفاده از برچسب زبان ساخته شده است.

۱.۱.۴ معماری خط لوله پردازش متن

خط لوله پیاده‌سازی مسیر طبقه‌بندی متن مطابق ساختار زیر طراحی شده است:

Raw Text ← Whitespace Cleaning ← Character/Word TF-IDF ← Chi-Square Top-50
Classifier ←

در این معماری، داده خام ابتدا توسط ماژول پاک‌سازی متن پردازش می‌شود. سپس ویژگی‌های متنی با استفاده از دو روش Character N-Gram و Word N-Gram استخراج می‌شوند. پس از تشکیل فضای ویژگی، ۵۰ ویژگی برتر با استفاده از آزمون Chi-Square انتخاب شده و در نهایت به مدل طبقه‌بندی ارسال می‌شوند.

تمام مراحل پاک‌سازی، استخراج ویژگی و انتخاب ویژگی داخل خط لوله طبقه‌بندی قرار گرفته‌اند. بنابراین در هر دور اعتبارسنجی متقاطع، بردارهای TF-IDF و انتخاب‌گر ویژگی فقط روی بخش آموزشی همان دور برازش می‌شوند و داده اعتبارسنجی در یادگیری واژگان یا انتخاب ویژگی‌ها نقشی ندارد.

مسیر خوشه‌بندی از همان تنظیمات پایه ویژگی‌های کاراکتری و واژگانی استفاده می‌کند، اما به دلیل بدون ناظر بودن این مسیر، انتخاب ویژگی نظارت‌شده Chi-Square در آن به کار نمی‌رود. نمایش ویژگی مخصوص خوشه‌بندی در انتهای این بخش توضیح داده شده است.

۲.۱.۴ بارگذاری و آماده‌سازی داده‌های متنی

داده‌های متنی از مسیر تعریف‌شده در فایل پیکربندی text.yaml خوانده می‌شوند. مسیر داده خام، الگوی جست‌وجوی فایل‌ها و کدگذاری متن به صورت زیر تعریف شده‌اند:

```
raw_source: data/raw/text
glob: '**/*.txt'
encoding: utf-8
```

ساختار منبع به صورت یک پوشه مستقل برای هر زبان است. برای هر فایل، کد پوشه اول مسیر به برچسب کامل زبان نگاشت می‌شود. نگاشت استفاده شده در پروژه در جدول ۱.۴ ارائه شده است.

جدول ۱.۴: نگاشت کد پوشه منبع به برچسب نهایی زبان

کد پوشه منبع برچسب نهایی زبان	
german	de
spanish	es
italian	it
korean	ko
portuguese	po
japanese	ja

محتوای کامل هر فایل به عنوان متن نمونه، مسیر نسبی فایل به عنوان شناسه نمونه و نام پوشه دوم، در صورت وجود، به عنوان فراداده جنسیت ثبت می‌شود. پس از رمزگشایی فایل‌ها، نمونه‌های خالی و متن‌های کاملاً تکراری پس از نرمال‌سازی فاصله‌ها بررسی می‌شوند. در اجرای نهایی، هر ۶۰۸ فایل با موفقیت خوانده شد و هیچ نمونه خالی یا متن تکراری حذف نشد.

برای ایجاد گروه‌های داده، شناسه ۹ رقمی ابتدای نام فایل، در صورت وجود، استخراج شده و همراه با نام زبان به عنوان شناسه گروه در نظر گرفته شده است. فایل‌هایی که با این الگو مطابقت نداشته‌اند، بر اساس زبان و مسیر فایل یک گروه یکتا دریافت کرده‌اند. سپس تقسیم آموزش و آزمون به صورت گروه‌آگاه انجام شده است؛ به طوری که تمام نمونه‌های یک گروه فقط در یکی از دو بخش آموزش یا آزمون قرار گرفته‌اند.

در اجرای نهایی، ۲۸۴ گروه شناسایی شد که ۴۴ گروه دارای بیش از یک نمونه بودند. تعداد گروه‌های مشترک میان آموزش و آزمون و همچنین تعداد متن‌های نرمال‌سازی شده مشترک میان این دو بخش برابر صفر بوده است.

۳.۱.۴ پیش‌پردازش داده‌های متنی

پیش‌پردازش متن در فایل cleaning.py پیاده‌سازی شده است. در این مرحله از یک پاک‌سازی محافظه‌کارانه استفاده شده تا ساختار زبانی و نویسه‌های مهم متن حفظ شوند. عملیات انجام شده شامل موارد زیر است:

- تبدیل فاصله‌های متوالی، خطوط جدید و نویسه‌های Tab به یک فاصله؛
- حذف فاصله‌های ابتدا و انتهای متن؛

- حفظ علائم نگارشی، ارقام، بزرگی و کوچکی حروف، نویسه‌های خط‌های مختلف و نشانه‌های آوایی؛
- خودداری از ریشه‌یابی، بن‌واژه‌سازی، نویسه‌گردانی یا استفاده از روش‌های پردازش مخصوص زبان انگلیسی.

پاک‌ساز متن، بزرگی و کوچکی حروف را تغییر نمی‌دهد؛ با این حال، بردارسازهای TF-IDF در مرحله استخراج ویژگی با تنظیم `lowercase=true` متن را هنگام بردارسازی به حروف کوچک تبدیل می‌کنند.

خروجی این مرحله یک متن نرمال‌سازی‌شده از نظر فاصله‌ها است که مستقیماً وارد مرحله استخراج ویژگی می‌شود. در اجرای نهایی، این نرمال‌سازی باعث تغییر ۱۴ نمونه شد و هیچ نویسه جایگزین ناشی از خطای کدگذاری در داده‌ها مشاهده نشد.

۴.۱.۴ استخراج ویژگی‌های متنی

برای تبدیل متن خام به فضای عددی قابل استفاده برای الگوریتم‌های یادگیری ماشین، از روش TF-IDF استفاده شده است. در این پروژه دو نمایش از متن به کمک `FeatureUnion` با یکدیگر ترکیب می‌شوند:

۱. ویژگی‌های کاراکتری؛

۲. ویژگی‌های واژگانی.

استخراج ویژگی‌های کاراکتری

ویژگی‌های کاراکتری با استفاده از تنظیمات زیر ایجاد شده‌اند:

```
analyzer: char_wb
ngram_range: [2, 4]
min_df: 1
max_features: 3000
sublinear_tf: true
lowercase: true
```

در این روش، توالی‌های دو تا چهار کاراکتری در محدوده مرز واژه‌ها استخراج می‌شوند. استفاده از Character N-Gram به مدل امکان می‌دهد الگوهایی مانند ترکیب نویسه‌ها، پیشوندها، پسوندها و تفاوت خط‌های نوشتاری را در داده‌های آموزشی شناسایی کند.

استخراج ویژگی‌های واژگانی

ویژگی‌های واژگانی با تنظیمات زیر ایجاد شده‌اند:

```
analyzer: word
ngram_range: [1, 2]
min_df: 1
max_features: 2000
sublinear_tf: true
lowercase: true
```

در این بخش، تک‌واژه‌ها و ترکیب‌های دوواژه‌ای استخراج شده و وزن هر ویژگی با استفاده از معیار TF-IDF محاسبه می‌شود. ترکیب ویژگی‌های کاراکتری و واژگانی باعث می‌شود اطلاعات مربوط به الگوهای نوشتاری و ساختار واژگان به‌صورت هم‌زمان در اختیار مدل قرار گیرد.

۵.۱.۴ انتخاب ویژگی در مسیر طبقه‌بندی

پس از ترکیب دو بردار ویژگی در مسیر طبقه‌بندی، تعداد ویژگی‌ها با استفاده از روش SelectKBest کاهش داده می‌شود. مقدار تعیین‌شده در فایل تنظیمات پروژه برابر است با:

```
select_k_best: 50
```

معیار انتخاب ویژگی‌ها آزمون آماری Chi-Square است. این روش وابستگی هر ویژگی به برجسب زبان را روی داده آموزشی اندازه‌گیری کرده و ۵۰ ویژگی دارای بالاترین امتیاز را انتخاب می‌کند. در اجرای نهایی، ترکیب دو بردار ساز یک ماتریس با ۵۰۰۰ ستون برای داده آموزشی ایجاد کرد و SelectKBest آن را به ۵۰ ویژگی کاهش داد. هدف این مرحله کاهش ابعاد ورودی، کاهش هزینه آموزش و تمرکز طبقه‌بند بر ویژگی‌هایی است که وابستگی آماری بیشتری با برجسب زبان دارند. از آنجاکه Chi-Square یک روش نظارت‌شده است، انتخاب ویژگی درون خط لوله هر طبقه‌بند قرار گرفته است. بنابراین در هر دور اعتبارسنجی، این مرحله فقط با استفاده از متن‌ها و برجسب‌های بخش آموزشی همان دور برازش می‌شود.

۶.۱.۴ تقسیم داده‌ها و اعتبارسنجی

تقسیم داده‌های متنی با استفاده از روش طبقه‌بندی‌شده و گروه‌آگاه انجام شده است. در این روش، نمونه‌هایی که متعلق به یک گروه مشترک هستند میان داده‌های آموزش و آزمون تقسیم نمی‌شوند و تمام زبان‌ها نیز در هر دو بخش حضور دارند.

تنظیمات مربوط به نسبت آزمون و تعداد دوره‌های اعتبارسنجی متن به صورت زیر است:

```
test_size: 0.3333333333333333
```

```
cv_folds: 5
```

از مجموع ۶۰۸ نمونه متنی، ۳۹۷ نمونه برای آموزش و ۲۱۱ نمونه برای آزمون نهایی استفاده شده‌اند. تقسیم نهایی با استفاده از اولین دور یک StratifiedGroupKFold سه‌قسمتی، با درهم‌ریزی داده‌ها و مقدار تصادفی ثابت ۴۲، ایجاد شده است.

برای تنظیم ابرپارامترها و انتخاب مدل، اعتبارسنجی متقاطع طبقه‌بندی شده و گروه‌آگاه پنج‌قسمتی فقط روی ۳۹۷ نمونه آموزشی انجام شده است. معیار اصلی انتخاب مدل Macro F1 در نظر گرفته شد تا عملکرد زبان‌ها با وزن برابر در انتخاب مدل اثر داشته باشد. مجموعه آزمون نهایی در برازش ویژگی‌ها، تنظیم ابرپارامترها یا انتخاب مدل استفاده نشده است.

۷.۱.۴ آماده‌سازی داده برای الگوریتم‌های یادگیری

پس از بارگذاری و پاک‌سازی داده‌ها، دو نمایش مستقل برای طبقه‌بندی و خوشه‌بندی ساخته شده است. اگرچه هر دو مسیر از تنظیمات یکسان ویژگی‌های کاراکتری و واژگانی TF-IDF استفاده می‌کنند، مراحل نهایی آماده‌سازی و دامنه برازش آن‌ها متفاوت است. در مسیر طبقه‌بندی، ساختار پردازش به صورت زیر است:

Raw Text ← Whitespace Cleaning ← Character/Word TF-IDF ← Chi-Square Top-50 Classifier ←

در این مسیر، برچسب زبان برای انتخاب ۵۰ ویژگی برتر با معیار Chi-Square و آموزش طبقه‌بند استفاده می‌شود. پاک‌سازی، بردارسازی و انتخاب ویژگی داخل خط لوله مدل قرار دارند و در هر دور اعتبارسنجی فقط روی بخش آموزشی همان دور برازش می‌شوند. پس از انتخاب ابرپارامتر، بهترین خط لوله روی تمام ۳۹۷ نمونه آموزشی برازش و تنها یک بار روی ۲۱۱ نمونه آزمون نهایی ارزیابی می‌شود.

در مقابل، مسیر خوشه‌بندی دارای ساختار زیر است:

Raw Text ← Whitespace Cleaning ← Character/Word TF-IDF ← TruncatedSVD-50 Clustering Algorithm ← L2 Normalization ←

در مسیر خوشه‌بندی از Chi-Square استفاده نشده است؛ زیرا این روش برای انتخاب ویژگی به برچسب کلاس نیاز دارد. به جای آن، کاهش بُعد بدون ناظر با استفاده از TruncatedSVD و ۵۰ مؤلفه انجام شده و سپس بردارها با روش L2 نرمال‌سازی شده‌اند.

تمام ۶۰۸ نمونه متنی برای تحلیل خوشه‌بندی استفاده شده‌اند. برچسب زبان هنگام برازش TF-IDF، کاهش بُعد، نرمال‌سازی، تشکیل خوشه‌ها و انتخاب پارامترهای الگوریتم‌ها وارد مدل نشده

است. برچسب‌های واقعی فقط پس از پایان برازش و تشکیل خوشه‌ها برای محاسبه معیارهای خارجی مانند ARI، NMI و Purity به کار رفته‌اند.

بنابراین، طبقه‌بندی و خوشه‌بندی از داده خام یکسان و تنظیمات پایه مشابه TF-IDF استفاده می‌کنند، اما نمایش ویژگی نهایی و شیوه برازش آن‌ها مستقل است. نتایج اجرای این دو مسیر در بخش‌های بعدی همین فصل ارائه می‌شوند.

۲.۴ طبقه‌بندی داده‌های متنی

در این بخش، فرایند آموزش، تنظیم، انتخاب و ارزیابی مدل‌های طبقه‌بندی برای شناسایی زبان از داده‌های متنی ارائه می‌شود. پیاده‌سازی این بخش در فایل `text/classification.py` انجام شده و تابع اصلی اجرای آن `run_text_classification()` است.

در این مرحله، چهار خانواده مستقل از الگوریتم‌های طبقه‌بندی آموزش داده شده‌اند. عملکرد مدل‌ها برای انتخاب نهایی بر اساس میانگین Macro F1 در اعتبارسنجی متقاطع گروه‌آگاه بخش آموزشی مقایسه شده است.

فرایند کلی طبقه‌بندی متن به صورت زیر است:

Raw Text ← Whitespace Cleaning ← Character/Word TF-IDF ← Chi-Square Top-50
 Classifier Training ← Evaluation

مجموعه آزمون نهایی در برازش بردارها، انتخاب ویژگی، تنظیم ابرپارامترها یا انتخاب مدل نقشی نداشته است. پس از اتمام تنظیم ابرپارامترهای هر خانواده، بهترین تنظیم هر چهار مدل برای گزارش و مقایسه روی مجموعه آزمون ارزیابی شده است؛ باین‌حال، مدل نهایی صرفاً بر اساس نتیجه اعتبارسنجی متقاطع داده آموزشی انتخاب شده است.

۱.۲.۴ طراحی فرایند آموزش مدل

هر الگوریتم در قالب یک خط لوله مستقل پیاده‌سازی شده است. ساختار واقعی خط لوله شامل پاک‌سازی متن، استخراج ویژگی، انتخاب ویژگی و طبقه‌بند است:

```
Pipeline(
[
    ("cleaner", MultilingualTextCleaner()),
    ("features", FeatureUnion(...)),
    ("select", SelectKBest(chi2, k=50)),
    ("classifier", estimator)
])
)
```

در این ساختار، پاک‌سازی متن، بردارسازهای کاراکتری و واژگانی TF-IDF، انتخاب ۵۰ ویژگی برتر با معیار Chi-Square و مدل طبقه‌بندی بخشی از یک خط لوله واحد هستند. بنابراین در هر دور اعتبارسنجی متقاطع، تمام مراحل وابسته به داده فقط روی بخش آموزشی همان دور برازش می‌شوند. برای تنظیم ابرپارامترها از GridSearchCV و اعتبارسنجی متقاطع طبقه‌بندی‌شده و گروه‌آگاه پنج‌قسمتی استفاده شده است. معیار امتیازدهی fl_macro و قاعده انتخاب مدل، بیشترین میانگین Macro F1 روی بخش آموزشی بوده است. در صورت برابری دقیق امتیازها، ترتیب از پیش تعریف‌شده مدل‌ها به‌عنوان قاعده رفع تساوی به کار می‌رود.

۲.۲.۴ مدل‌های طبقه‌بندی بررسی‌شده

در بخش طبقه‌بندی داده‌های متنی، چهار خانواده مستقل یادگیری ماشین بررسی شده‌اند:

- K-Nearest Neighbours؛

- Decision Tree؛

- Logistic Regression؛

- Multinomial Naive Bayes.

برای هر خانواده، یک شبکه ابرپارامتر در کد تعریف و با استفاده از GridSearchCV بررسی شده است. مقادیر نامزد و بهترین مقدار انتخاب‌شده در جدول ۲.۴ ارائه شده‌اند.

جدول ۲.۴: فضای جست‌وجو و بهترین ابرپارامتر طبقه‌بندی‌های متن

مدل	اب‌پارامتر و مقادیر نامزد	مقدار منتخب
K-Nearest Neighbours	$n_neighbours$ {1, 3, 5, 10, 20, 30, 50, 75, 100, 150, 200, 250}	1
Decision Tree	max_depth {1, 2, 3, 4, 5, 6, 7, 8, 10, 12, 15, 20}	10
Logistic Regression	C {0.0001, 0.001, 0.01, 0.1, 0.5, 1, 2, 5, 10, 50, 100}	100
Multinomial Naive Bayes	α {0.001, 0.01, 0.1, 0.5, 1, 2, 5, 10, 20, 50, 100, 200}	0.001

در مدل K-Nearest Neighbours وزن همسایه‌ها یکنواخت، معیار فاصله Cosine و الگوریتم جست‌وجو Brute Force در نظر گرفته شده است. مدل Logistic Regression با وزن‌دهی متوازن کلاس‌ها و حداکثر ۱۰۰۰ تکرار اجرا شده و برای مدل‌های Decision Tree و Logistic Regression مقدار تصادفی ثابت ۴۲ استفاده شده است.

۳.۲.۴ تنظیم ابرپارامترها و انتخاب مدل نهایی

نتایج مقایسه مدل‌ها در فایل زیر ذخیره شده‌اند:

artifacts/text/classification/metrics/comparison.csv

جدول ۳.۴ نتایج اعتبارسنجی متقاطع بهترین تنظیم هر خانواده را نشان می‌دهد.

جدول ۳.۴: مقایسه طبقه‌بندی متن بر اساس اعتبارسنجی متقاطع گروه‌آگاه

مدل	میانگین Macro F1	انحراف معیار
Logistic Regression	0.99059	0.00498
K-Nearest Neighbours	0.97704	0.01496
Decision Tree	0.95371	0.02984
Multinomial Naive Bayes	0.88135	0.12126

بر اساس نتایج جدول ۳.۴، مدل Logistic Regression با میانگین Macro F1 برابر با ۰.۹۹۰۵۹ و انحراف معیار ۰.۰۰۴۹۸ بهترین نتیجه اعتبارسنجی را به دست آورده و به عنوان مدل نهایی انتخاب شده است. بهترین مقدار ابرپارامتر این مدل برابر با $C = 100$ است.

کمترین انحراف معیار نیز متعلق به همین مدل است که پایداری بیشتر آن را در تقسیم‌های اعتبارسنجی این مجموعه آموزشی نشان می‌دهد. در مقابل، مدل Multinomial Naive Bayes با انحراف معیار ۰.۱۲۱۲۶ بیشترین تغییرپذیری را میان دوره‌های اعتبارسنجی داشته است.

۴.۲.۴ ارزیابی مدل‌ها روی مجموعه آزمون

پس از اتمام تنظیم ابرپارامترها، بهترین تنظیم هر چهار خانواده روی مجموعه آزمون نهایی شامل ۲۱۱ نمونه ارزیابی شده است. نتایج این مقایسه در جدول ۴.۴ ارائه شده‌اند.

جدول ۴.۴: مقایسه عملکرد طبقه‌بندی متن روی مجموعه آزمون نهایی

مدل	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1
Logistic Regression	0.99526	0.99495	0.99444	0.99461	0.99526
K-Nearest Neighbours	0.98578	0.98510	0.98403	0.98434	0.98577
Decision Tree	0.98578	0.98415	0.98368	0.98383	0.98577
Multinomial Naive Bayes	0.98104	0.97768	0.97917	0.97734	0.98074

این جدول فقط برای گزارش عملکرد نهایی ارائه شده است و مقادیر آن در انتخاب مدل دخالت نداشته‌اند. انتخاب Logistic Regression مستقل از نتایج آزمون و بر اساس اعتبارسنجی متقاطع بخش آموزشی انجام شده است.

۵.۲.۴ ارزیابی مدل منتخب روی مجموعه آزمون

مدل منتخب Logistic Regression روی مجموعه آزمون به Accuracy برابر با ۰.۹۹۵۲۶ و Macro F1 برابر با ۰.۹۹۴۶۱۰ رسیده است. معیارهای تجمیعی این مدل در جدول ۵.۴ ارائه شده‌اند.

جدول ۵.۴: نتایج تجمیعی مدل Logistic Regression روی مجموعه آزمون

مقدار	معیار
0.99526	Accuracy
0.99495	Macro Precision
0.99444	Macro Recall
0.99461	Macro F1
0.99526	Weighted F1

برای بررسی عملکرد مدل در هر زبان، گزارش طبقه‌بندی کامل مدل منتخب در جدول ۶.۴ ارائه شده است.

جدول ۶.۴: گزارش طبقه‌بندی مدل Logistic Regression برای هر زبان

زبان	Precision	Recall	F1-score	Support
German	1.00000	1.00000	1.00000	52
Italian	1.00000	1.00000	1.00000	26
Japanese	1.00000	1.00000	1.00000	33
Korean	1.00000	1.00000	1.00000	38
Portuguese	0.96970	1.00000	0.98462	32
Spanish	1.00000	0.96667	0.98305	30
Macro Average	0.99495	0.99444	0.99461	211
Weighted Average	0.99540	0.99526	0.99526	211


مدل منتخب ۲۱۰ نمونه از ۲۱۱ نمونه آزمون را به‌درستی طبقه‌بندی کرده و تنها یک خطا داشته است. این نتیجه باید در محدوده همین مجموعه داده و تقسیم آزمون تفسیر شود و به‌تنهایی تعمیم عملکرد مدل به منابع متنی دیگر را اثبات نمی‌کند.

۶.۲.۴ تحلیل ماتریس‌های درهم‌ریختگی مدل‌های طبقه‌بندی

به‌منظور بررسی دقیق‌تر عملکرد مدل‌ها، علاوه بر معیارهای عددی، ماتریس درهم‌ریختگی Confusion Matrix برای هر چهار خانواده طبقه‌بندی تولید شده است. در این ماتریس‌ها، محور عمودی زبان واقعی و محور افقی زبان پیش‌بینی شده را نشان می‌دهد. مقادیر قطر اصلی تعداد پیش‌بینی‌های صحیح و مقادیر خارج از قطر خطاهای طبقه‌بندی هستند.

تحلیل ماتریس درهم‌ریختگی مدل Logistic Regression

ماتریس درهم‌ریختگی مدل Logistic Regression در شکل ۱.۴ نمایش داده شده است.




شکل ۱.۴: ماتریس درهم‌ریختگی مدل Logistic Regression

در کلاس‌های German, Italian, Japanese و Korean تمام نمونه‌ها به‌درستی تشخیص داده شده‌اند. هر ۳۲ نمونه واقعی Portuguese نیز درست شناسایی شده‌اند. از ۳۰ نمونه Spanish، تعداد ۲۹ نمونه صحیح بوده و یک نمونه به‌اشتباه Portuguese پیش‌بینی شده است.

این خطا با وجود شباهت‌های واژگانی میان زبان‌های اسپانیایی و پرتغالی قابل تفسیر است، اما آزمایش فعلی علت دقیق این پیش‌بینی اشتباه را به‌صورت مستقل بررسی نکرده است.

تحلیل ماتریس درهم‌ریختگی مدل K-Nearest Neighbours

ماتریس درهم‌ریختگی مدل K-Nearest Neighbours در شکل ۲.۴ نمایش داده شده است.




شکل ۲.۴: ماتریس درهم‌ریختگی مدل K-Nearest Neighbours

کلاس‌های German، Italian، Japanese و Korean بدون خطا تشخیص داده شده‌اند. از ۳۲ نمونه Portuguese، تعداد ۳۰ نمونه صحیح و دو نمونه به‌اشتباه Japanese پیش‌بینی شده‌اند. همچنین از ۳۰ نمونه Spanish، تعداد ۲۹ نمونه صحیح بوده و یک نمونه Portuguese پیش‌بینی شده است. این خطاها نشان می‌دهند که در نمایش ویژگی انتخاب‌شده، نزدیک‌ترین همسایه بعضی نمونه‌های آزمون متعلق به زبان دیگری بوده است. برای تعیین علت دقیق این نزدیکی، بررسی موردی متن‌ها و ویژگی‌های منتخب لازم است.

تحلیل ماتریس درهم‌ریختگی مدل Decision Tree

ماتریس درهم‌ریختگی مدل Decision Tree در شکل ۳.۴ ارائه شده است.




شکل ۳.۴: ماتریس درهم‌ریختگی مدل Decision Tree

چهار کلاس German, Italian, Japanese و Korean کاملاً بدون خطا شناسایی شده‌اند. در کلاس Portuguese، از ۳۲ نمونه، تعداد ۳۱ نمونه صحیح بوده و یک نمونه Spanish پیش‌بینی شده است. در کلاس Spanish نیز از ۳۰ نمونه، تعداد ۲۸ نمونه صحیح و دو نمونه Portuguese پیش‌بینی شده‌اند. تمام معیارهای آموزشی این مدل برابر با ۱.۰۰۰ بوده‌اند، درحالی‌که دقت آزمون آن ۰.۹۸۵۷۸ است. این اختلاف می‌تواند نشانه‌ای از تمایل درخت تصمیم به بیش‌برازش داده آموزشی باشد، هرچند عملکرد آزمون آن در این مجموعه همچنان بالا است.

تحلیل ماتریس درهم‌ریختگی مدل Multinomial Naive Bayes

ماتریس درهم‌ریختگی مدل Multinomial Naive Bayes در شکل ۴.۴ نمایش داده شده است.



شکل ۴.۴: ماتریس درهم‌ریختگی مدل Multinomial Naive Bayes

تمام نمونه‌های واقعی German، Italian، Japanese و Korean به درستی تشخیص داده شده‌اند. در کلاس Portuguese، تعداد ۲۸ نمونه صحیح، دو نمونه Italian و دو نمونه Spanish پیش‌بینی شده‌اند. تمام ۳۰ نمونه واقعی Spanish نیز به درستی شناسایی شده‌اند.

فرض استقلال شرطی ویژگی‌ها در Naive Bayes می‌تواند یکی از توضیح‌های احتمالی برای عملکرد ضعیف‌تر این مدل باشد؛ با این حال، علت خطاها در آزمایش فعلی به صورت جداگانه آزمون نشده است. انحراف معیار بالاتر اعتبارسنجی نیز نشان می‌دهد عملکرد این مدل نسبت به ترکیب گروه‌ها حساس‌تر بوده است.

مقایسه نهایی ماتریس‌های درهم‌ریختگی

مقایسه چهار ماتریس نشان می‌دهد هر چهار مدل تمام نمونه‌های واقعی زبان‌های German، Italian، Japanese و Korean را درست تشخیص داده‌اند. همه خطاهای مشاهده‌شده از نمونه‌های واقعی Portuguese یا Spanish آغاز شده‌اند؛ با این حال، مقصد خطاها همیشه یکی از این دو زبان نبوده و در مدل‌های K-Nearest Neighbours و Multinomial Naive Bayes به ترتیب پیش‌بینی‌های اشتباه Japanese و Italian نیز مشاهده شده است.

مدل Logistic Regression با یک خطا کمترین تعداد خطا را روی آزمون داشته است. مدل‌های K-Nearest Neighbours و Decision Tree هر کدام سه خطا و مدل Multinomial Naive Bayes چهار خطا داشته‌اند. این نتیجه با رتبه اول Logistic Regression در اعتبارسنجی متقاطع سازگار است، اما

قاعده انتخاب مدل همچنان فقط بر نتیجه اعتبارسنجی بخش آموزشی متکی بوده است. عملکرد مناسب مدل منتخب نشان می‌دهد ترکیب ویژگی‌های Word و Character N-Gram همراه با انتخاب ویژگی Chi-Square و یک طبقه‌بند خطی برای زبان‌ها و نمونه‌های موجود در این مجموعه داده مؤثر بوده است. تعمیم این نتیجه به مجموعه‌های متنی دیگر به ارزیابی مستقل نیاز دارد.

۷.۲.۴ ذخیره‌سازی مدل نهایی و پیش‌بینی

پس از انتخاب مدل نهایی، بسته مدل منتخب در مسیر زیر ذخیره شده است:

```
artifacts/text/classification/models/best_classifier.joblib
```

این بسته شامل خط لوله برازش شده و اطلاعات مربوط به مدل منتخب و قاعده انتخاب آن است. خط لوله ذخیره شده مراحل زیر را در بر می‌گیرد:

- پاک‌سازی محافظه کارانه متن؛
 - بردارهای کاراکتری و واژگانی TF-IDF؛
 - انتخاب ۵۰ ویژگی برتر با معیار Chi-Square؛
 - طبقه‌بند نهایی Logistic Regression.
- در مرحله استنتاج، ورودی بسته مدل یک متن خام Unicode است. تمام مراحل پاک‌سازی، استخراج ویژگی، انتخاب ویژگی و پیش‌بینی به صورت خودکار و با همان پارامترهای آموزش اجرا می‌شوند. آزمون استنتاج ذخیره شده نیز با موفقیت انجام شده است.

۳.۴ خوشه‌بندی داده‌های متنی

در این بخش، فرایند خوشه‌بندی داده‌های متنی بدون استفاده از برچسب‌های واقعی زبان بررسی می‌شود. هدف این مرحله، ارزیابی توانایی الگوریتم‌های یادگیری بدون ناظر در کشف ساختارهای موجود در داده‌های متنی است.

ابتدا متن‌ها با همان روش محافظه کارانه بخش طبقه‌بندی پاک‌سازی شده‌اند. سپس ویژگی‌های متنی با استفاده از ترکیب Character TF-IDF و Word TF-IDF استخراج شده‌اند. برای کاهش ابعاد، روش TruncatedSVD با ۵۰ مؤلفه اجرا شده و در پایان، بردارهای حاصل با نرم L2 نرمال‌سازی شده‌اند. خروجی این مرحله یک ماتریس با ابعاد 608×50 است.

تنظیمات پایه بردارهای TF-IDF در طبقه‌بندی و خوشه‌بندی یکسان است، اما نمایش ویژگی این دو مسیر به صورت مستقل برازش می‌شود. در خوشه‌بندی از انتخاب ویژگی Chi-Square استفاده نشده است؛ زیرا این روش برای انتخاب ویژگی به برچسب کلاس نیاز دارد.

در ساخت نمایش ویژگی، کاهش ابعاد، نرمال‌سازی، برازش الگوریتم‌ها و انتخاب پارامترها هیچ برچسب زبانی استفاده نشده است. برچسب‌های واقعی فقط پس از تشکیل خوشه‌ها برای محاسبه معیارهای خارجی NMI، ARI و Purity و تحلیل ترکیب زبانی خوشه‌ها وارد فرایند ارزیابی شده‌اند.

۱.۳.۴ طراحی فرایند خوشه‌بندی متن

خط لوله پیاده‌سازی خوشه‌بندی متن به صورت زیر طراحی شده است:

TruncatedSVD-50 ← Character/Word TF-IDF ← Whitespace Cleaning ← Raw Text
Post-fit Evaluation ← Clustering Algorithm ← L2 Normalization ←

چهار خانواده مستقل خوشه‌بندی در این بخش بررسی شده‌اند:

- K-Means

- DBSCAN

- Agglomerative Clustering

- Gaussian Mixture

برای انتخاب پارامترهای هر خانواده، از قواعد بدون برچسب زیر استفاده شده است:

- در K-Means، تعداد خوشه‌ها از ۲ تا ۸ بررسی و مقدار دارای بیشترین Silhouette انتخاب شده است؛

- در Agglomerative Clustering، تعداد خوشه‌های ۲ تا ۸ همراه با دو روش پیوند Ward و Average بررسی و بهترین حالت بر اساس بیشترین Silhouette انتخاب شده است؛

- در Gaussian Mixture، تعداد مؤلفه‌های ۲ تا ۸ بررسی و حالت دارای کمترین BIC انتخاب شده است؛

- در DBSCAN، مقادیر مختلف eps و min_samples بررسی و ابتدا بیشترین مقدار معتبر Silhouette و در صورت تساوی، نرخ نویز کمتر ملاک انتخاب قرار گرفته است.

پس از انتخاب بهترین تنظیم هر خانواده، مدل نهایی خوشه‌بندی متن با بیشترین مقدار معتبر Silhouette انتخاب شده است. معیارهای خارجی دارای برچسب در هیچ‌یک از این تصمیم‌ها نقش نداشته‌اند.

۲.۳.۴ پیاده‌سازی الگوریتم‌های خوشه‌بندی

پیاده‌سازی الگوریتم K-Means

الگوریتم K-Means با هدف تقسیم نمونه‌ها به خوشه‌هایی پیرامون مراکز آموخته‌شده اجرا شده است. در این خانواده، تعداد خوشه‌های ۲ تا ۸ آزمایش شد و مقدار ۶ بیشترین Silhouette را ایجاد کرد. تنظیم منتخب به صورت زیر است:

```
n_clusters = 6
n_init = 20
random_state = 42
```

پارامتر n_init تعداد اجرای الگوریتم با مقداردهی اولیه متفاوت را مشخص می‌کند. از میان این اجراها، راه‌حل دارای کمترین تابع هزینه درون‌خوشه‌ای نگهداری می‌شود. مقدار تصادفی ثابت ۴۲ نیز برای بازتولیدپذیری استفاده شده است.

مقدار ۶ بدون استفاده از تعداد زبان‌های واقعی و فقط بر اساس بیشترین Silhouette در فضای جست‌وجوی تعریف‌شده انتخاب شده است.

پیاده‌سازی الگوریتم DBSCAN

الگوریتم DBSCAN برای شناسایی نواحی متراکم و جداکردن نمونه‌های کم‌تراکم به‌عنوان نویز اجرا شده است. برخلاف روش‌هایی مانند K-Means، تعداد خوشه‌ها از پیش برای این الگوریتم تعیین نمی‌شود.

در فرایند جست‌وجو، مقادیر ۵ و ۱۰ برای min_samples بررسی شدند. مقادیر نامزد eps نیز از صدک‌های ۰.۷۰، ۰.۸۰، ۰.۹۰ و ۰.۹۵ فاصله تا همسایه k ام استخراج شدند. تنظیم منتخب به صورت زیر است:

```
eps = 0.63755167479975
min_samples = 5
```

پارامتر eps حداکثر فاصله همسایگی و پارامتر min_samples حداقل تعداد نمونه لازم برای تشکیل یک ناحیه متراکم را کنترل می‌کند. تنظیم نهایی بیشترین Silhouette معتبر را میان نامزدها به دست آورده است.

پیاده‌سازی الگوریتم Agglomerative Clustering

الگوریتم Agglomerative Clustering با رویکرد سلسله‌مراتبی پایین‌به‌بالا پیاده‌سازی شده است. در این روش، نمونه‌ها ابتدا خوشه‌های جداگانه محسوب می‌شوند و سپس خوشه‌های نزدیک به‌صورت مرحله‌ای با یکدیگر ادغام می‌شوند.

برای این خانواده، تعداد خوشه‌های ۲ تا ۸ و روش‌های پیوند Ward و Average بررسی شدند. تنظیم منتخب به صورت زیر است:

```
n_clusters = 6
linkage = ward
```

در روش Ward، ادغام خوشه‌ها با هدف کمینه‌کردن افزایش واریانس درون خوشه‌ای انجام می‌شود. ترکیب شش خوشه و پیوند Ward بیشترین مقدار Silhouette را میان نامزدهای این خانواده به دست آورده است.

پیاده‌سازی الگوریتم Gaussian Mixture

الگوریتم Gaussian Mixture داده‌ها را به صورت ترکیبی از چند توزیع گاوسی مدل‌سازی می‌کند و برای هر نمونه احتمال تعلق به مؤلفه‌های مختلف را برآورد می‌کند. برچسب خوشه نهایی از مؤلفه دارای بیشترین احتمال به دست می‌آید. در این خانواده، تعداد مؤلفه‌های ۲ تا ۸ با ساختار کوواریانس قطری بررسی شد. تنظیم منتخب به صورت زیر است:

```
n_components = 8
covariance_type = diag
n_init = 3
reg_covar = 1e-6
random_state = 42
```

تعداد مؤلفه‌ها بر اساس کمترین مقدار BIC انتخاب شده است. این معیار میان برآزش بهتر داده و پیچیدگی بیشتر مدل تعادل برقرار می‌کند. مقدار reg_covar نیز برای پایداری عددی ماتریس‌های کوواریانس استفاده شده است.

۳.۳.۴ نتایج ارزیابی الگوریتم‌های خوشه‌بندی متن

پس از اجرای الگوریتم‌ها، عملکرد هر خانواده با استفاده از معیارهای داخلی و خارجی ارزیابی شده است. معیارهای داخلی عبارت‌اند از:

- Silhouette

- Calinski-Harabasz

- Davies-Bouldin

معیارهای خارجی که فقط پس از پایان برآزش محاسبه شده‌اند عبارت‌اند از:

• Adjusted Rand Index (ARI)

• Normalized Mutual Information (NMI)

• Purity

برای DBSCAN، معیارهای داخلی فقط روی نمونه‌های غیرنویز محاسبه شده‌اند؛ زیرا برچسب 1- نشان‌دهنده نویز است و یک خوشه عادی محسوب نمی‌شود. در مقابل، معیارهای خارجی ARI، NMI و Purity با استفاده از تمام تخصیص‌ها، از جمله برچسب نویز، محاسبه شده‌اند. بنابراین مقایسه مقدار داخلی DBSCAN با معیارهای خارجی آن باید با توجه به این تفاوت انجام شود. نتایج نهایی در جدول ۷.۴ ارائه شده‌اند.

جدول ۷.۴: مقایسه نتایج الگوریتم‌های خوشه‌بندی داده‌های متنی

مدل	تعداد خوشه	نرخ نویز	Silhouette	Calinski-Harabasz	Davies-Bouldin	ARI	NMI	Purity
K-Means	6	0.00000	0.35108	152.61208	1.48446	1.00000	1.00000	1.00000
DBSCAN	13	0.23520	0.42650	80.97006	1.06145	0.80892	0.86734	0.88816
Agglomerative Clustering	6	0.00000	0.35108	152.61208	1.48446	1.00000	1.00000	1.00000
Gaussian Mixture	8	0.00000	0.25990	116.51180	1.75074	0.89420	0.94044	1.00000


مطابق جدول ۷.۴، الگوریتم DBSCAN با Silhouette برابر با ۰.۴۲۶۵۰ بیشترین معیار داخلی را به دست آورده و طبق قاعده بدون برچسب پروژه به‌عنوان مدل منتخب خوشه‌بندی متن ثبت شده است.

از نظر معیارهای خارجی پس از برازش، K-Means و Agglomerative Clustering هر شش زبان را به‌طور کامل بازیابی کرده‌اند و مقادیر ARI، NMI و Purity برای هر دو مدل برابر با ۱.۰۰۰۰۰ است. این تفاوت نشان می‌دهد بهترین معیار هندسی داخلی لزوماً بهترین تطابق معنایی با زبان واقعی را ایجاد نمی‌کند.

۴.۳.۴ تحلیل نمودارهای خوشه‌بندی متن

نمودارهای این بخش دو مؤلفه نخست از نمایش ۵۰ بعدی TruncatedSVD پس از نرمال‌سازی را نمایش می‌دهند و رنگ هر نقطه نشان‌دهنده شناسه خوشه پیش‌بینی شده است. الگوریتم‌های خوشه‌بندی و تمام معیارهای جدول ۷.۴ با استفاده از نمایش کامل ۵۰ بعدی محاسبه شده‌اند. بنابراین هم‌پوشانی یا جدایی نقاط در این نمودار دوبعدی به‌تنهایی برای قضاوت درباره عملکرد مدل کافی نیست.

تحلیل نمودار خوشه‌بندی K-Means




شکل ۵.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم K-Means

مطابق شکل ۵.۴، در تصویر دوبعدی یک گروه در بخش بالایی، چند گروه در بخش پایینی و تعداد کمی نقطه نزدیک مبدأ مشاهده می‌شوند. بعضی خوشه‌ها در دو مؤلفه اول به یکدیگر نزدیک یا هم‌پوشان هستند؛ بنابراین صرفاً از روی شکل نمی‌توان جداسازی کامل آن‌ها را نتیجه گرفت.

بالین حال، ارزیابی پس از برازش نشان می‌دهد هر یک از شش خوشه فقط شامل نمونه‌های یک زبان بوده است. تعداد نمونه‌های خوشه‌های متناظر با زبان‌های German، Italian، Japanese، Korean، Portuguese و Spanish به ترتیب برابر با ۱۰۴، ۱۰۶، ۱۰۰، ۹۸، ۱۰۰ و ۱۰۰ است. در نتیجه، مقادیر ARI، NMI و Purity برابر با ۱.۰۰۰۰۰ به دست آمده‌اند. این نتیجه بر اساس تخصیص‌های کامل ۵۰ بعدی است، نه فقط ظاهر نمودار دوبعدی.

تحلیل نمودار خوشه‌بندی DBSCAN




شکل ۶.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم DBSCAN

بر اساس شکل ۶.۴، الگوریتم DBSCAN چند ناحیه متراکم را شناسایی کرده و بخشی از نمونه‌ها را با برچسب 1- به عنوان نویز مشخص کرده است. این مدل در مجموع ۱۳ خوشه غیرنویز تشکیل داده و ۱۴۳ نمونه، معادل ۲۳.۵۲ درصد داده‌ها، را نویز در نظر گرفته است.

تحلیل ترکیب خوشه‌ها پس از برازش نشان می‌دهد تمام نمونه‌های Italian, Spanish, German و Korean هرکدام در یک خوشه مستقل قرار گرفته‌اند. در مقابل، بخشی از نمونه‌های Portuguese و Japanese به چند خوشه کوچک تقسیم شده و ۶۸ نمونه پرتغالی و ۷۵ نمونه ژاپنی در گروه نویز قرار گرفته‌اند.

اگرچه DBSCAN بالاترین Silhouette را به دست آورده است، تعداد زیاد خوشه‌ها و نرخ نویز ۰.۲۳۵۲۰ باعث شده تطابق خارجی آن با شش زبان واقعی از K-Means و Agglomerative Clustering کمتر باشد.


تحلیل نمودار خوشه‌بندی Agglomerative Clustering



شکل ۷.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم Agglomerative Clustering

شکل ۷.۴ نتیجه الگوریتم Agglomerative Clustering را در دو مؤلفه اول نمایش می‌دهد. مانند K-Means، یک گروه در بخش بالایی و چند گروه نزدیک‌تر در بخش پایینی دیده می‌شوند. نزدیکی بعضی رنگ‌ها در این تصویر نتیجه فشردگی نمایش ۵۰ بعدی به دو مؤلفه قابل مشاهده است. ارزیابی ترکیب خوشه‌ها نشان می‌دهد الگوریتم بدون استفاده از برچسب، نمونه‌ها را به شش خوشه کاملاً خالص تقسیم کرده و هر خوشه با یکی از شش زبان واقعی منطبق بوده است. در نتیجه، هر سه معیار ARI، NMI و Purity برابر با ۱.۰۰۰۰۰ هستند. شماره خوشه‌ها قراردادی است و ترتیب آن‌ها معنای زبانی خاصی ندارد.

تحلیل نمودار خوشه‌بندی Gaussian Mixture



شکل ۸.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم Gaussian Mixture

مطابق شکل ۸.۴، الگوریتم Gaussian Mixture هشت مؤلفه ایجاد کرده است؛ درحالی‌که داده شامل شش زبان است. تحلیل ترکیب مؤلفه‌ها پس از برازش نشان می‌دهد نمونه‌های German به دو گروه ۵۳ و ۵۱ نمونه‌ای و نمونه‌های Spanish به دو گروه ۶۳ و ۳۷ نمونه‌ای تقسیم شده‌اند. هر یک از چهار زبان دیگر در یک مؤلفه مستقل قرار گرفته‌اند.

مقدار Purity برابر با ۱.۰۰۰۰۰ نشان می‌دهد هر مؤلفه فقط شامل نمونه‌های یک زبان است؛ اما تقسیم دو زبان به چند مؤلفه باعث کاهش ARI به ۰.۸۹۴۲۰ و NMI به ۰.۹۴۰۴۴ شده است. هم‌پوشانی ظاهری بعضی رنگ‌ها در نمودار دوبعدی نیز نباید به‌عنوان اختلاط قطعی خوشه‌ها تفسیر شود؛ زیرا معیارها و تخصیص‌ها بر اساس فضای کامل ۵۰بعدی محاسبه شده‌اند.

۵.۳.۴ جمع‌بندی خوشه‌بندی داده‌های متنی

نتایج نشان می‌دهند نمایش ترکیبی ویژگی‌های Character TF-IDF و Word TF-IDF همراه با TruncatedSVD و نرمال‌سازی L2 برای زبان‌ها و نمونه‌های موجود در این مجموعه‌داده ساختار قابل تفکیکی ایجاد کرده است.

مدل‌های K-Means و Agglomerative Clustering بدون استفاده از برچسب هنگام برازش، شش خوشه کاملاً منطبق با شش زبان واقعی تشکیل داده‌اند. مدل Gaussian Mixture نیز خوشه‌های خالص ایجاد کرده، اما دو زبان را به زیرگروه‌های جدا تقسیم کرده است.

الگوریتم DBSCAN به دلیل بیشترین Silhouette به‌عنوان مدل منتخب بدون برچسب ثبت شده

است، اما ۱۳ خوشه و نرخ نویز ۲۳.۵۲ درصدی آن نشان می‌دهد بهترین معیار داخلی الزاماً بهترین بازیابی ساختار معنایی زبان را ایجاد نمی‌کند. به همین دلیل، معیار انتخاب بدون برچسب و معیارهای خارجی پس از برآزش باید جداگانه گزارش و تفسیر شوند.

در مجموع، خوشه‌بندی متن در این مجموعه داده شواهد قوی از جدایی طبیعی زبان‌ها ارائه می‌کند؛ با این حال، این نتیجه به داده‌ها و نمایش ویژگی فعلی محدود است و تعمیم آن به مجموعه‌های متنی دیگر به ارزیابی مستقل نیاز دارد.

۴.۴ پیاده‌سازی بخش شناسایی زبان از گفتار

در این بخش، فرایند پیاده‌سازی مسیر شناسایی زبان از گفتار ارائه می‌شود. پیش از مرحله مدل‌سازی، فایل‌های صوتی توسط نگارنده پاک‌سازی شده و ویژگی‌های صوتی آن‌ها استخراج شده‌اند. خروجی این فرایند در دو فایل features.csv و metadata.csv ذخیره شده است.

خط لوله آزمایش فعلی فایل‌های صوتی خام را دوباره پاک‌سازی نمی‌کند و مرحله استخراج ویژگی را نیز مجدداً اجرا نمی‌کند. این خط لوله منبع ویژگی‌های استخراج‌شده را به صورت فقط خواندنی دریافت کرده و آموزش و ارزیابی مدل‌ها را از جدول ۱۳۳ ویژگی عددی آغاز می‌کند.

بنابراین، فرایند گفتار از دو مرحله مجزا تشکیل شده است. مرحله نخست شامل پاک‌سازی صوت و استخراج ویژگی است که پیش‌تر توسط نگارنده انجام شده و مرحله دوم، یعنی پیاده‌سازی فعلی پروژه، شامل بارگذاری جدول ویژگی، اعتبارسنجی ساختار داده، تقسیم گروه آگاه، پیش‌پردازش و اجرای الگوریتم‌های طبقه‌بندی و خوشه‌بندی است.

۱.۴.۴ معماری خط لوله پردازش گفتار

مرحله آماده‌سازی اولیه داده گفتار به صورت زیر انجام شده است:

features.csv / ← Audio Feature Extraction ← Audio Cleaning ← Raw Audio
metadata.csv

این مرحله بخشی از آماده‌سازی داده توسط نگارنده است و در اجرای فعلی مدل‌ها دوباره اجرا نمی‌شود. خط لوله آزمایش و مدل‌سازی از ساختار زیر پیروی می‌کند:

133 Numeric ← Schema and Alignment Validation ← Extracted Feature Tables
← Classification or Clustering ← Model-specific Preprocessing ← Predictors
Evaluation

در این معماری، فایل ویژگی و فراداده بر اساس شناسه پایدار نمونه با یکدیگر هم‌تراز می‌شوند. سپس ستون شناسه، برچسب زبان و ستون فراداده از فضای پیش‌بین‌ها کنار گذاشته شده و فقط ۱۳۳ ستون عددی وارد مراحل مدل‌سازی می‌شوند.

پیش‌پردازش نهایی برای طبقه‌بندی و خوشه‌بندی یکسان نیست. در طبقه‌بندی، پیش‌پردازش متناسب با هر خانواده مدل داخل خط لوله نظارت‌شده قرار دارد؛ اما در خوشه‌بندی، یک نمایش بدون برچسب شامل جایگزینی مقادیر گم‌شده، استانداردسازی و کاهش بُعد با PCA ساخته می‌شود.

۲.۴.۴ بارگذاری و آماده‌سازی داده‌های گفتاری

مسیر منبع ویژگی‌های گفتار و نام فایل‌ها در speech.yaml به صورت زیر تعریف شده‌اند:

```
feature_source: Speech_Identification/clean data and data extraction
features_file: features.csv
metadata_file: metadata.csv
target_column: lang
identifier_column: filepath
metadata_columns:
  - gender
```

فایل features.csv شامل ویژگی‌های استخراج‌شده و شناسه نمونه است و فایل metadata.csv اطلاعات جانبی نمونه‌ها را نگهداری می‌کند. دو فایل بر اساس ستون filepath هم‌تراز می‌شوند و همسان‌بودن شناسه‌ها و ستون‌های مشترک آن‌ها بررسی می‌شود. وجود شناسه تکراری، شناسه گم‌شده یا ناهماهنگی میان دو فایل باعث توقف اجرای برنامه می‌شود و داده‌ها صرفاً بر اساس ترتیب سطرها به یکدیگر متصل نمی‌شوند.

مشخصات مجموعه‌داده گفتاری پس از هم‌ترازی در جدول ۸.۴ ارائه شده است.

جدول ۸.۴: مشخصات مجموعه‌داده گفتاری مورد استفاده در مدل‌سازی

ویژگی	مقدار
تعداد نمونه‌ها	720
تعداد زبان‌ها	4
تعداد نمونه هر زبان	180
تعداد کل ستون‌ها پس از هم‌ترازی	136
تعداد پیش‌بین‌های عددی	133
ستون هدف	lang
ستون شناسه	filepath
ستون فراداده	gender

چهار برچسب زبانی موجود در داده عبارت‌اند از ko، it، es، de و ko که هر کدام ۱۸۰ نمونه دارند. این مجموعه داده از داده متنی مستقل است و یکسان بودن نمونه‌ها، زبان‌ها یا شناسه‌های دو مسیر فرض نشده است.

برای ساخت ماتریس ورودی، ستون‌های filepath، lang و gender به‌طور صریح از پیش‌بین‌ها کنار گذاشته می‌شوند. سپس کد بررسی می‌کند که تمام ستون‌های باقی‌مانده عددی باشند. برخلاف حذف خودکار ستون‌های غیر عددی ناشناخته، وجود هر ستون غیر عددی پیش‌بینی نشده باعث ایجاد خطا می‌شود تا تغییرات احتمالی طرح داده پنهان نماند.

۳.۴.۴ اعتبارسنجی و پیش‌پردازش داده‌های صوتی

پیش‌پردازش در اجرای فعلی روی جدول ویژگی‌های استخراج شده انجام می‌شود. پیش از آموزش مدل‌ها، موارد زیر بررسی شده‌اند:

- خالی نبودن جدول ویژگی؛
- وجود ستون‌های ضروری filepath و lang؛
- نبود مقدار گمشده در شناسه و برچسب زبان؛
- یکتابودن شناسه‌های نمونه؛
- تطابق کامل شناسه‌ها میان فایل ویژگی و فراداده؛
- عددی بودن تمام ۱۳۳ پیش‌بین؛
- بررسی مقادیر گمشده و نامتناهی؛
- بررسی ویژگی‌های ثابت، نزدیک به ثابت و ستون‌های مشکوک به برچسب.

در اجرای نهایی، هیچ سطر تکراری، شناسه تکراری، مقدار گمشده، مقدار نامتناهی، ویژگی ثابت، ویژگی نزدیک به ثابت یا ستون عددی مشکوک به برچسب مشاهده نشد. با وجود این، جایگزینی مقادیر گمشده با میانه در خطوط لوله مدل حفظ شده است تا بسته مدل در برابر مقادیر گمشده احتمالی هنگام استفاده آینده مقاوم باشد.

خروجی این مرحله یک جدول عددی با ۷۲۰ سطر و ۱۳۳ ستون است. هر سطر نماینده یک فایل صوتی پردازش شده و هر ستون نماینده یکی از ویژگی‌های استخراج شده از آن فایل است.

۴.۴.۴ ویژگی‌های صوتی استفاده شده

استخراج ویژگی‌های صوتی پیش از مرحله مدل‌سازی و توسط نگارنده انجام شده است. در اجرای فعلی، تعریف این ویژگی‌ها از جدول نهایی خوانده می‌شود و استخراج مجدد آن‌ها از صوت خام بخشی از خط لوله الزامی آزمایش نیست.

برای هر نمونه، ۱۳۳ ویژگی عددی در دسترس است. این ویژگی‌ها خلاصه‌های آماری از محتوای زمانی، طیفی و انرژی فایل صوتی هستند و گروه‌های زیر را شامل می‌شوند:

- میانگین و انحراف معیار ۲۰ ضریب MFCC، در مجموع ۴۰ ویژگی؛
- میانگین و انحراف معیار ۲۰ ضریب تغییرات مرتبه اول MFCC Delta، در مجموع ۴۰ ویژگی؛
- میانگین و انحراف معیار ۲۰ ضریب تغییرات مرتبه دوم MFCC Delta-Delta، در مجموع ۴۰ ویژگی؛
- میانگین و انحراف معیار نرخ عبور از صفر Zero-Crossing Rate؛
- میانگین و انحراف معیار مرکز طیفی Spectral Centroid؛
- میانگین و انحراف معیار افت طیفی Spectral Rolloff؛
- میانگین و انحراف معیار پهنای باند طیفی Spectral Bandwidth؛
- میانگین و انحراف معیار تختی طیفی Spectral Flatness؛
- میانگین و انحراف معیار انرژی RMS؛
- مدت زمان فایل بر حسب ثانیه، شامل یک ویژگی.

سه گروه ۴۰ تایی مربوط به MFCC و تغییرات آن، ۱۲۰ ویژگی ایجاد می‌کنند. شش گروه دو ویژگی دیگر ۱۲ ویژگی و مدت زمان یک ویژگی ایجاد می‌کند؛ بنابراین تعداد کل پیش‌بین‌ها برابر با ۱۳۳ است.

تمام این ویژگی‌ها خلاصه‌هایی از کل فایل صوتی هستند. در نتیجه، ترتیب زمانی کامل فریم‌های صوتی در جدول نهایی حفظ نشده و هر فایل با مجموعه‌ای ثابت از مقادیر عددی نمایش داده می‌شود.

۵.۴.۴ استانداردسازی و آماده‌سازی ویژگی‌ها

از آنجاکه ویژگی‌های صوتی مقیاس‌های متفاوتی دارند، نحوه پیش‌پردازش متناسب با خانواده الگوریتم تعیین شده است. در طبقه‌بندی، مدل‌های Logistic Regression، RBF SVM و K-Nearest Neighbours از خط لوله زیر استفاده می‌کنند:

Classifier ← StandardScaler ← Median Imputation ← 133 Audio Features

مدل Random Forest به استانداردسازی مقیاس ویژگی‌ها نیاز ندارد؛ بنابراین خط لوله آن شامل جایگزینی مقادیر گم‌شده با میانه و سپس طبقه‌بند است:

Random Forest ← Median Imputation ← 133 Audio Features

قرارگرفتن جایگزینی مقادیر گم‌شده و استانداردسازی داخل خط لوله باعث می‌شود این مراحل در هر دور اعتبارسنجی فقط روی بخش آموزشی همان دور برآزش شوند و اطلاعات بخش اعتبارسنجی یا آزمون وارد محاسبه میانه و پارامترهای مقیاس‌بندی نشود. در مسیر خوشه‌بندی، تمام ۷۲۰ نمونه بدون استفاده از برچسب زبان وارد یک نمایش مستقل می‌شوند:

← PCA-30 ← StandardScaler ← Median Imputation ← 133 Audio Features
Clustering Algorithm

کاهش بُعد PCA به ۳۰ مؤلفه با مقدار تصادفی ثابت ۴۲ انجام شده است. برچسب زبان هنگام جایگزینی مقادیر، استانداردسازی، برآزش PCA یا تشکیل خوشه‌ها استفاده نمی‌شود.

۶.۴.۴ تقسیم داده‌ها و اعتبارسنجی

برای کاهش احتمال نشت اطلاعات، تقسیم آموزش و آزمون در مسیر طبقه‌بندی به صورت لایه‌بندی شده و گروه‌آگاه انجام شده است. شناسه گروه از الگوی ۹ رقمی ابتدای نام فایل استخراج می‌شود. تمام ۷۲۰ مسیر فایل با این الگو مطابقت داشته‌اند و در مجموع ۷۸ گروه ایجاد شده است.

نمونه‌های متعلق به یک گروه فقط در یکی از دو بخش آموزش یا آزمون قرار گرفته‌اند. تقسیم نهایی با استفاده از اولین دور یک StratifiedGroupKFold پنج‌قسمتی و مقدار تصادفی ثابت ۴۲ ایجاد شده است. از مجموع ۷۲۰ نمونه، ۵۷۲ نمونه در بخش آموزش و ۱۴۸ نمونه در مجموعه آزمون نهایی قرار گرفته‌اند. تعداد گروه‌های مشترک میان دو بخش برابر صفر است.

برای تنظیم ابرپارامترها و انتخاب طبقه‌بند، اعتبارسنجی متقاطع لایه‌بندی شده و گروه‌آگاه سه‌قسمتی فقط روی بخش آموزشی اجرا شده است. معیار اصلی انتخاب مدل، میانگین Macro F1 است تا عملکرد چهار زبان با وزن برابر در انتخاب مدل اثر داشته باشد.

مجموعه آزمون نهایی در تنظیم ابرپارامترها یا انتخاب مدل نقشی نداشته است. پس از اتمام تنظیم هر خانواده، بهترین تنظیم هر چهار طبقه‌بند برای گزارش عملکرد روی آزمون ارزیابی شده است؛ اما مدل منتخب فقط بر اساس بیشترین Macro F1 اعتبارسنجی متقاطع بخش آموزشی تعیین شده است.

خوشه‌بندی به تقسیم آموزش و آزمون وابسته نیست و روی تمام ۷۲۰ نمونه انجام می‌شود. برچسب زبان فقط پس از تشکیل خوشه‌ها برای محاسبه معیارهای خارجی استفاده می‌شود و در برآزش یا انتخاب پارامترهای خوشه‌بندی نقشی ندارد.

۷.۴.۴ آماده‌سازی داده برای الگوریتم‌های یادگیری

جدول پایه ۱۳۳ ویژگی عددی، منبع مشترک مسیرهای طبقه‌بندی و خوشه‌بندی است؛ اما ماتریس نهایی پردازش شده این دو مسیر یکسان نیست.

در مسیر طبقه‌بندی، ۵۷۲ نمونه آموزشی همراه با برچسب زبان برای آموزش و تنظیم مدل‌ها استفاده می‌شوند. پیش‌پردازش داخل خط لوله هر مدل قرار دارد و ۱۴۸ نمونه آزمون فقط برای گزارش عملکرد نهایی به کار می‌روند. بسته مدل منتخب علاوه بر خط لوله برازش‌شده، ترتیب و نام ۱۳۳ ویژگی و رمزگذار برچسب زبان را نیز ذخیره می‌کند.

در مسیر خوشه‌بندی، تمام ۷۲۰ نمونه بدون برچسب وارد جایگزینی میانه، استانداردسازی و PCA می‌شوند و سپس چهار خانواده خوشه‌بندی روی نمایش ۳۰ بعدی اجرا می‌شوند. معیارهای خارجی فقط پس از پایان برازش به نتایج افزوده می‌شوند.

بنابراین، اشتراک دو مسیر به جدول اولیه ویژگی‌ها محدود است و هر مسیر نمایش متناسب با هدف خود را به‌طور مستقل می‌سازد. در نسخه فعلی، ورودی بسته استنتاج گفتار یک ردیف شامل ۱۳۳ ویژگی استخراج‌شده است و فایل صوتی خام مستقیماً به مدل ذخیره‌شده داده نمی‌شود.

۵.۴ طبقه‌بندی گفتار

در این بخش، فرآیند طبقه‌بندی داده‌های گفتاری با هدف شناسایی زبان از روی ویژگی‌های صوتی استخراج‌شده ارائه می‌شود. ورودی مدل‌ها فایل صوتی خام نیست، بلکه ماتریسی شامل ۱۳۳ ویژگی عددی است که فرآیند استخراج آن‌ها در بخش قبل توضیح داده شد.

در این مرحله، برخلاف خوشه‌بندی که بدون استفاده از برچسب زبان انجام می‌شود، نمونه‌های گفتاری همراه با برچسب زبان در اختیار مدل‌ها قرار گرفته‌اند؛ بنابراین مسئله به صورت یادگیری نظارت‌شده پیاده‌سازی شده است.

۱.۵.۴ طراحی فرآیند آموزش مدل طبقه‌بندی گفتار

فرآیند کلی آموزش مدل‌های طبقه‌بندی گفتار به صورت زیر پیاده‌سازی شده است:

Audio Feature Matrix

←

Model-specific Preprocessing

←

Classifier Training and Tuning

←

Prediction

←

Evaluation

مجموعه داده گفتار شامل ۷۲۰ نمونه از چهار زبان است. با استفاده از StratifiedGroupKFold،

تعداد ۵۷۲ نمونه به بخش آموزش و ۱۴۸ نمونه به بخش آزمون مستقل اختصاص یافت. گروه‌های استخراج‌شده از شناسه گوینده یا منبع در دو بخش آموزش و آزمون هم‌پوشانی ندارند؛ در نتیجه، احتمال نشت اطلاعات ناشی از حضور نمونه‌های متعلق به یک گوینده یا منبع در هر دو بخش کاهش یافته است.

انتخاب مدل و تنظیم ابرپارامترها فقط روی بخش آموزش و با اعتبارسنجی متقاطع گروه‌آگاه سه‌بخشی انجام شده است. مجموعه آزمون در انتخاب مدل یا تنظیم ابرپارامترها دخالت نداشته و تنها پس از پایان این مرحله برای ارزیابی نهایی استفاده شده است.

پیش‌پردازش متناسب با نیاز هر مدل درون خط لوله آن قرار گرفته است. جایگزینی مقادیر گمشده با میان برای هر چهار مدل انجام می‌شود. همچنین برای مدل‌های KNN، Logistic Regression و RBF-SVM استانداردسازی ویژگی‌ها با StandardScaler انجام شده است؛ اما مدل Random Forest به استانداردسازی وابسته نیست و در خط لوله آن این مرحله وجود ندارد. قرارگرفتن این عملیات درون خط لوله باعث می‌شود پارامترهای پیش‌پردازش در هر مرحله فقط از داده‌های آموزشی همان مرحله یاد گرفته شوند.

۲.۵.۴ مدل‌های طبقه‌بندی بررسی‌شده

برای مقایسه خانواده‌های الگوریتمی متفاوت، چهار مدل طبقه‌بندی در بخش گفتار پیاده‌سازی و اجرا شده‌اند:

- K-Nearest Neighbours

- Logistic Regression

- Random Forest

- RBF Support Vector Machine

برای هر مدل، جست‌وجوی ابرپارامتر با GridSearchCV انجام شده و معیار مشترک مقایسه، میانگین Macro F1 در اعتبارسنجی متقاطع گروه‌آگاه بوده است.

مدل K-Nearest Neighbours

الگوریتم K-Nearest Neighbours براساس فاصله میان نمونه‌ها در فضای ویژگی تصمیم‌گیری می‌کند. برای هر نمونه جدید، نزدیک‌ترین نمونه‌های موجود در داده آموزشی بررسی شده و برچسب نهایی براساس رأی همسایه‌ها تعیین می‌شود.

در جست‌وجوی ابرپارامتر، مقادیر n_neighbors برابر با ۳، ۷ و ۱۱، مقادیر weights برابر با uniform و distance، و مقادیر p برابر با ۱ و ۲ بررسی شدند. تنظیم منتخب این مدل به صورت زیر بود:

```
n_neighbors=3, weights=uniform, p=1
```

مقدار $p=1$ به معنای استفاده از فاصله منهتن است.

مدل Logistic Regression

مدل Logistic Regression به عنوان یک مدل خطی برای ایجاد مرز تصمیم میان کلاس‌های زبانی استفاده شده است. این مدل پس از جایگزینی مقادیر گمشده و استانداردسازی ویژگی‌ها، احتمال تعلق هر نمونه به کلاس‌های مختلف را محاسبه می‌کند.

در جست‌وجوی ابرپارامتر، مقادیر C برابر با ۰.۱، ۱ و ۱۰ و مقادیر $class_weight$ برابر با None و balanced بررسی شدند. تنظیم منتخب این مدل برابر بود با:

```
C=1.0, class_weight=balanced
```

مدل Random Forest

مدل Random Forest برای بررسی یک روش تجمعی مبتنی بر درخت‌های تصمیم استفاده شده است. این مدل می‌تواند روابط غیرخطی و درهم‌کنش میان ویژگی‌های صوتی را یاد بگیرد و برخلاف مدل‌های مبتنی بر فاصله یا حاشیه، به استانداردسازی ویژگی‌ها نیاز ندارد.

در جست‌وجوی ابرپارامتر، تعداد درخت‌ها برابر با ۲۰۰، عمق بیشینه برابر با None یا ۱۲، مقدار $min_samples_leaf$ برابر با ۱ یا ۲، و مقدار $class_weight$ برابر با None یا balanced بررسی شد. تنظیم منتخب برابر بود با:

```
n_estimators=200, max_depth=None,
min_samples_leaf=1, class_weight=balanced
```

مدل RBF-SVM

مدل RBF Support Vector Machine با استفاده از هسته RBF برای ایجاد مرزهای تصمیم غیرخطی میان کلاس‌ها بررسی شده است. به دلیل حساسیت این مدل به مقیاس ویژگی‌ها، جایگزینی مقادیر گمشده و استانداردسازی درون خط لوله آموزش آن انجام شده است.

در جست‌وجوی ابرپارامتر، مقادیر C برابر با ۱ و ۱۰، مقادیر γ برابر با scale و ۰.۰۱، و مقادیر $class_weight$ برابر با None و balanced بررسی شدند. تنظیم منتخب این مدل برابر بود با:

```
C=1.0, gamma=scale, class_weight=None
```

۳.۵.۴ تنظیم ابرپارامترها و انتخاب مدل نهایی

نتایج اعتبارسنجی متقاطع گروه‌آگاه در جدول ۹.۴ ارائه شده است. معیار اصلی انتخاب مدل، بیشترین میانگین Macro F1 در بخش آموزش بود. در صورت برابری دقیق نتایج نیز ترتیب ازپیش‌تعریف‌شده مدل‌ها به عنوان معیار رفع تساوی در نظر گرفته شده بود.

جدول ۹.۴: نتایج اعتبارسنجی متقاطع مدل‌های طبقه‌بندی گفتار

مدل	میانگین CV Macro F1	انحراف معیار CV Macro F1
KNN	0.96622	0.04436
Logistic Regression	0.96564	0.04860
Random Forest	0.95444	0.06443
RBF-SVM	0.92456	0.08527

مدل K-Nearest Neighbours با مقدار میانگین $CV\ Macro\ F1=0.96622$ براساس قاعده ازپیش‌تعیین‌شده انتخاب مدل، رتبه نخست را به دست آورد و به عنوان مدل نهایی ذخیره شد. اختلاف میانگین این مدل با Logistic Regression حدود ۰.۰۰۰۵۹ است و از انحراف معیار نتایج هر دو مدل کوچک‌تر است؛ بنابراین این انتخاب به معنای برتری قاطع و عمومی KNN نیست، بلکه نتیجه اجرای قاعده انتخاب روی همین داده‌ها و همین تقسیم‌بندی است.

۴.۵.۴ مقایسه عملکرد مدل‌های طبقه‌بندی گفتار

پس از پایان انتخاب مدل، هر چهار مدل روی مجموعه آزمون مستقل ۱۴۸ نمونه‌ای ارزیابی شدند. نتایج در جدول ۱۰.۴ ارائه شده است. مقادیر آزمون فقط برای گزارش عملکرد به کار رفته‌اند و در انتخاب مدل نهایی نقشی نداشته‌اند.

جدول ۱۰.۴: مقایسه عملکرد مدل‌های طبقه‌بندی گفتار روی مجموعه آزمون

مدل	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1
KNN	0.99324	0.98913	0.99405	0.99143	0.99328
Logistic Regression	1.00000	1.00000	1.00000	1.00000	1.00000
Random Forest	1.00000	1.00000	1.00000	1.00000	1.00000
RBF-SVM	1.00000	1.00000	1.00000	1.00000	1.00000

سه مدل Logistic Regression، Random Forest و RBF-SVM در این مجموعه آزمون به امتیاز

کامل دست یافتند. با وجود این، استفاده از این نتایج برای تغییر مدل منتخب باعث نشت اطلاعات از مجموعه آزمون به فرآیند انتخاب می‌شد؛ از این رو KNN مطابق نتیجه اعتبارسنجی متقاطع به عنوان مدل نهایی حفظ شد.

۵.۵.۴ ارزیابی مدل منتخب روی داده آزمون

مدل منتخب K-Nearest Neighbours تعداد ۱۴۷ نمونه از ۱۴۸ نمونه آزمون را به درستی طبقه‌بندی کرد. نتایج کلی این مدل در جدول ۱۱.۴ ارائه شده است.

جدول ۱۱.۴: نتایج کلی مدل منتخب طبقه‌بندی گفتار

مقدار	معیار
0.99324	Accuracy
0.98913	Macro Precision
0.99405	Macro Recall
0.99143	Macro F1
0.99354	Weighted Precision
0.99324	Weighted Recall
0.99328	Weighted F1


گزارش طبقه‌بندی کامل مدل منتخب به تفکیک زبان در جدول ۱۲.۴ نمایش داده شده است.

جدول ۱۲.۴: گزارش طبقه‌بندی مدل KNN به تفکیک زبان

زبان	Precision	Recall	F1-score	تعداد نمونه
de	1.00000	0.97619	0.98795	42
es	1.00000	1.00000	1.00000	30
it	1.00000	1.00000	1.00000	54
ko	0.95652	1.00000	0.97778	22
Macro Average	0.98913	0.99405	0.99143	148
Weighted Average	0.99354	0.99324	0.99328	148

۶.۵.۴ تحلیل ماتریس درهم‌ریختگی

برای بررسی دقیق محل خطاهای مدل منتخب، ماتریس درهم‌ریختگی KNN در شکل ۹.۴ ارائه شده است.



شکل ۹.۴: ماتریس درهم‌ریختگی مدل KNN

مطابق شکل، مدل همه نمونه‌های زبان‌های es، it و ko را به‌درستی طبقه‌بندی کرده است. در زبان de، تعداد ۴۱ نمونه به‌درستی شناسایی شده و فقط یک نمونه به اشتباه ko پیش‌بینی شده است. همین خطا باعث شده مقدار Recall زبان de برابر با ۰.۹۷۶۱۹ و مقدار Precision زبان ko برابر با ۰.۹۵۶۵۲ باشد.

در این آزمایش، علت دقیق این تک‌خطا به صورت جداگانه بررسی نشده است؛ بنابراین نمی‌توان آن را با قطعیت به شباهت آوایی زبان‌ها، ویژگی‌های گوینده یا شرایط ضبط نسبت داد. تعیین علت به تحلیل موردی همان نمونه صوتی و اجرای آزمایش‌های تکمیلی نیاز دارد.

۷.۵.۴ ذخیره‌سازی مدل و فرآیند پیش‌بینی

پس از انتخاب مدل نهایی، بسته کامل مدل ذخیره شده است. این بسته شامل خط لوله آموزش‌دیده، نام و ترتیب ۱۳۳ ویژگی ورودی، نام ستون هدف، رمزگذار برچسب‌ها، شناسه مدل منتخب و قاعده انتخاب مدل است.

مسیر ذخیره مدل:

artifacts/speech/classification/models/best_classifier.joblib

در مرحله پیش‌بینی، یک ردیف شامل هر ۱۳۳ ویژگی صوتی استخراج‌شده وارد همین خط لوله می‌شود و برچسب زبان پیش‌بینی‌شده بازگردانده می‌شود. بنابراین برای پیش‌بینی مستقیم از یک فایل صوتی خام، ابتدا باید همان فرآیند استخراج ویژگی توضیح‌داده‌شده در بخش پیش‌پردازش گفتار اجرا شود. آزمون اولیه بارگذاری و پیش‌بینی بسته ذخیره‌شده نیز با موفقیت انجام شده است.

۸.۵.۴ جمع‌بندی بخش طبقه‌بندی گفتار

در این بخش، چهار خانواده مستقل طبقه‌بندی برای شناسایی زبان گفتار آموزش، تنظیم و ارزیابی شدند. مدل K-Nearest Neighbours براساس بیشترین میانگین Macro F1 در اعتبارسنجی متقاطع گروه‌آگاه به عنوان مدل نهایی انتخاب شد و روی مجموعه آزمون به $Accuracy=0.99324$ و Macro $F1=0.99143$ دست یافت.

این نتایج نشان می‌دهد ۱۳۳ ویژگی صوتی استخراج‌شده در همین مجموعه داده توان تفکیک بالایی میان چهار زبان داشته‌اند. با این حال، نتایج بسیار بالا و حتی امتیاز کامل سه مدل روی یک مجموعه آزمون نباید به عنوان تضمین عملکرد روی گویندگان، منابع ضبط یا مجموعه‌داده‌های جدید تفسیر شود و برای بررسی قابلیت تعمیم، ارزیابی روی داده مستقل بیرونی ضروری است.

۶.۴ خوشه‌بندی گفتار

در این بخش، فرآیند خوشه‌بندی داده‌های گفتاری با استفاده از الگوریتم‌های یادگیری بدون ناظر بررسی می‌شود. هدف این مرحله آن است که مشخص شود آیا ویژگی‌های صوتی استخراج‌شده، بدون استفاده از برچسب زبان، ساختارهای گروهی قابل تشخیصی ایجاد می‌کنند یا خیر.

در برازش مدل‌ها و انتخاب ابرپارامترها فقط از ویژگی‌های صوتی استفاده شده است. برچسب واقعی زبان پس از پایان خوشه‌بندی و فقط برای محاسبه معیارهای خارجی ARI، NMI و Purity و تحلیل ترکیب خوشه‌ها وارد فرآیند شده است. بنابراین این معیارهای خارجی در آموزش، انتخاب پارامترها یا انتخاب مدل نهایی دخالتی نداشته‌اند.

۱.۶.۴ طراحی فرآیند خوشه‌بندی گفتار


خط لوله کلی خوشه‌بندی داده‌های گفتاری به صورت زیر طراحی شده است:

Audio Feature Matrix

←

Median Imputation

←



ابتدا مقادیر گم‌شده احتمالی هر ویژگی با میانه جایگزین و سپس تمام ویژگی‌های عددی با StandardScaler استاندارد شده‌اند. پس از آن، کاهش بُعد بدون ناظر با PCA انجام شده و ۱۳۳ ویژگی ورودی به ۳۰ مؤلفه تبدیل شده‌اند. هیچ برچسب زبانی در برازش این نمایش ۳۰ بعدی استفاده نشده است. هر چهار الگوریتم روی همین نمایش مشترک آموزش دیده‌اند تا مقایسه آن‌ها بر پایه ورودی یکسان انجام شود.

انتخاب پارامتر درون هر خانواده نیز بدون استفاده از برچسب زبان انجام شده است. در K-Means و Agglomerative Clustering بیشترین مقدار Silhouette، در Gaussian Mixture کمترین مقدار BIC، و در DBSCAN بیشترین Silhouette معتبر و سپس نرخ نویز کمتر معیار انتخاب بوده است. در مرحله مقایسه نهایی چهار خانواده، مدلی که بیشترین Silhouette معتبر را داشت به عنوان مدل منتخب خودکار ثبت شد.

برخلاف طبقه‌بندی، در این تحلیل اکتشافی تقسیم آموزش و آزمون انجام نشده و تمام ۷۲۰ نمونه بدون برچسب برای برازش خوشه‌ها استفاده شده‌اند. در نتیجه، معیارهای گزارش شده عملکرد تعمیم به داده جدید را اندازه‌گیری نمی‌کنند و فقط ساختار مشاهده شده در همین مجموعه داده را توصیف می‌کنند.

۲.۶.۴ آماده‌سازی ویژگی‌های صوتی برای خوشه‌بندی

داده ورودی این بخش شامل ویژگی‌های عددی استخراج شده از فایل‌های صوتی است. مشخصات داده و نمایش مورد استفاده در جدول ۱۳.۴ ارائه شده است.

جدول ۱۳.۴: مشخصات داده ورودی خوشه‌بندی گفتار

ویژگی	مقدار
تعداد نمونه‌ها	720
تعداد زبان‌های واقعی برای ارزیابی پس از برازش	4
تعداد ویژگی‌های عددی اولیه	133
تعداد مؤلفه‌های ورودی مدل‌ها پس از PCA	30
استفاده از برچسب در آماده‌سازی و برازش	خیر

استانداردسازی از غالب‌شدن ویژگی‌هایی با دامنه عددی بزرگ‌تر جلوگیری می‌کند و PCA نیز یک نمایش فشرده و مشترک برای چهار الگوریتم فراهم می‌سازد. این تبدیل‌ها بر کل ماتریس بدون برچسب برازش شده‌اند و مدل‌های خوشه‌بندی از نمایش ۳۰ بعدی حاصل استفاده می‌کنند.

۳.۶.۴ پیاده‌سازی الگوریتم‌های خوشه‌بندی

برای بررسی ساختار داده‌های صوتی، چهار خانواده مستقل خوشه‌بندی اجرا شده‌اند:

- K-Means
- DBSCAN
- Agglomerative Clustering
- Gaussian Mixture

الگوریتم K-Means

الگوریتم K-Means داده‌ها را به تعداد از پیش تعیین شده‌ای از خوشه‌ها تقسیم می‌کند. در این پروژه، تعداد خوشه‌ها از ۲ تا ۸ بررسی و برای هر حالت مقدار Silhouette محاسبه شد. تعداد اجرای اولیه الگوریتم نیز برابر با $n_init=20$ در نظر گرفته شد. تنظیم منتخب این خانواده برابر بود با:

$n_clusters=8, n_init=20$

این تنظیم در میان گزینه‌های بررسی شده بیشترین مقدار Silhouette را برای خانواده K-Means ایجاد کرد.

الگوریتم DBSCAN

الگوریتم DBSCAN براساس چگالی نمونه‌ها خوشه تشکیل می‌دهد و نمونه‌هایی را که در ناحیه متراکم قرار ندارند با برچسب 1- به عنوان نویز مشخص می‌کند.

برای تعیین eps، صدک‌های ۰.۷۰، ۰.۸۰، ۰.۹۰ و ۰.۹۵ فاصله تا همسایه kام بررسی شدند و مقدار min_samples نیز برابر با ۵ یا ۱۰ در نظر گرفته شد. تنظیم منتخب براساس بیشترین Silhouette معتبر و سپس نرخ نویز کمتر برابر بود با:

eps=6.888667107237424, min_samples=5

این مدل ۱۳ خوشه غیرنویز ایجاد کرد و ۱۳۰ نمونه از ۷۲۰ نمونه، معادل ۰.۱۸۰۵۶، را به عنوان نویز شناسایی کرد.

الگوریتم Agglomerative Clustering

در الگوریتم Agglomerative Clustering، تعداد خوشه‌ها از ۲ تا ۸ و دو روش پیوند ward و average بررسی شدند. تنظیمی که بیشترین Silhouette را ایجاد کرد عبارت بود از:

n_clusters=2, linkage=average

این مدل با Silhouette=0.47093 براساس قاعده عددی ازپیش‌تعیین‌شده به عنوان مدل منتخب نهایی ثبت شد. با این حال، اندازه دو خوشه آن برابر با ۷۱۹ و ۱ نمونه است؛ بنابراین نتیجه به‌شدت نامتوازن است و نباید به عنوان کشف دو گروه معنادار یا دو ساختار زبانی تفسیر شود. امتیاز بالای این حالت عمده‌تاً با جداسدن یک نمونه دورافتاده از سایر داده‌ها همراه است و یک محدودیت مهم برای قاعده انتخاب صرفاً مبتنی بر Silhouette محسوب می‌شود.

الگوریتم Gaussian Mixture

مدل Gaussian Mixture توزیع داده‌ها را با ترکیبی از مؤلفه‌های احتمالی مدل‌سازی می‌کند. تعداد مؤلفه‌ها از ۲ تا ۸ بررسی شد، نوع کوواریانس برای همه نامزدها diag بود و هر مدل با n_init=3 اجرا شد. برخلاف سه خانواده دیگر، انتخاب تنظیم این خانواده با کمترین مقدار BIC انجام شد. تنظیم منتخب برابر بود با:

n_components=8, covariance_type=diag

مدل برای هر نمونه احتمال تعلق به مؤلفه‌ها را برآورد می‌کند، اما در خروجی‌های ذخیره‌شده هر نمونه به مؤلفه دارای بیشترین احتمال نسبت داده شده و یک انتساب نهایی و قطعی گزارش شده است.

۴.۶.۴ مقایسه نتایج الگوریتم‌های خوشه‌بندی گفتار

معیارهای داخلی با استفاده از نمایش ۳۰ بعدی بدون ناظر محاسبه شده‌اند. در DBSCAN، نمونه‌های نویز از محاسبه Silhouette، Calinski–Harabasz و Davies–Bouldin کنار گذاشته شده‌اند؛ اما در معیارهای خارجی، انتساب 1- نیز در کنار سایر شناسه‌های خوشه حضور دارد. از این‌رو مقایسه مستقیم معیارهای داخلی DBSCAN با الگوریتم‌های فاقد نویز باید با احتیاط انجام شود.

در معیارهای Silhouette، Calinski–Harabasz، ARI، NMI و Purity مقدار بیشتر بهتر است؛ در حالی که برای Davies–Bouldin مقدار کمتر مطلوب‌تر است. نتایج کامل در جدول ۱۴.۴ ارائه شده است.

جدول ۱۴.۴: مقایسه نتایج الگوریتم‌های خوشه‌بندی گفتار

مدل	Silhouette	CH	DBI	ARI	NMI	Purity	تعداد خوشه	نرخ نویز
Agglomerative	0.47093	5.82403	0.40370	0.00000	0.00276	0.25139	2	0.00000
DBSCAN	0.29626	71.84778	1.17048	0.24333	0.46958	0.72917	13	0.18056
K-Means	0.23815	100.80276	1.62139	0.49828	0.67312	0.90278	8	0.00000
Gaussian Mixture	0.14991	67.19423	2.13945	0.33824	0.54021	0.81111	8	0.00000

الگوریتم Agglomerative Clustering بیشترین مقدار عددی Silhouette و کمترین Davies–Bouldin را به دست آورده است، اما تقسیم ۷۱۹ در برابر ۱ نشان می‌دهد این نتیجه یک راه‌حل نامتوازن و از نظر کاربردی ضعیف است. مقدار $ARI=0$ و $NMI=0.00276$ نیز نشان می‌دهد انتساب‌های آن تقریباً هیچ هم‌خوانی قابل توجهی با زبان واقعی ندارند.

در مقابل، K-Means بیشترین مقادیر خارجی $ARI=0.49828$ ، $NMI=0.67312$ و $Purity=0.90278$ را ایجاد کرده است. این معیارها فقط پس از برازش محاسبه شده‌اند و نمی‌توان از آن‌ها برای انتخاب بدون ناظر مدل استفاده کرد. همچنین K-Means هشت خوشه برای چهار زبان ساخته است؛ پس مقدار بالای Purity به معنای برابری یک‌به‌یک خوشه‌ها و زبان‌ها نیست و ممکن است هر زبان در چند زیرخوشه تقسیم شده باشد. به طور کلی، Purity نیز با افزایش تعداد خوشه‌ها می‌تواند بزرگ‌تر شود و باید همراه با سایر معیارها تفسیر شود.


فایل انتساب نمونه‌ها، اندازه و ترکیب زبانی خوشه‌ها، معیارها، نامزدهای پارامتری و مدل یا پیکربندی هر چهار خانواده در مسیر `artifacts/speech/clustering/` ذخیره شده‌اند. نمایش بدون ناظر ۳۰ بعدی نیز برای بازتولید تحلیل ذخیره شده است.

۵.۶.۴ تحلیل نمودارهای خوشه‌بندی

به منظور بررسی بصری ساختار خوشه‌ها، خروجی هر الگوریتم با استفاده از دو مؤلفه نخست نمایش بدون‌ناظر ترسیم شده است. رنگ نقاط نشان‌دهنده شناسه خوشه پیش‌بینی‌شده است و از رنگ برچسب زبان واقعی استفاده نشده است.

نکته مهم آن است که مدل‌ها در فضای ۳۰ بعدی برازش شده‌اند، درحالی‌که نمودارها فقط دو مؤلفه نخست را نمایش می‌دهند. بنابراین هم‌پوشانی یا جدایی نقاط در این تصاویر ممکن است بخشی از اطلاعات ابعاد حذف‌شده را منعکس نکند و نباید به تنهایی مبنای قضاوت درباره کیفیت خوشه‌بندی باشد.

تحلیل نمودار خوشه‌بندی K-Means




شکل ۱۰.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم K-Means در داده‌های گفتاری

مطابق شکل ۱۰.۴، چند ناحیه نسبتاً متمرکز در دو مؤلفه نخست مشاهده می‌شود و برخی خوشه‌ها، به‌ویژه در بخش‌های چپ و پایین نمودار، جدایی بصری بیشتری دارند. با این حال، در ناحیه مرکزی هم‌پوشانی چندین خوشه دیده می‌شود. از آنجاکه خوشه‌بندی در ۳۰ بُعد انجام شده است، این هم‌پوشانی دوبعدی لزوماً به معنای هم‌پوشانی کامل در فضای مورد استفاده مدل نیست.

مقدار $Silhouette=0.23815$ نشان‌دهنده جدایی هندسی محدود خوشه‌هاست، اما مقادیر خارجی $NMI=0.67312$ و $ARI=0.49828$ نشان می‌دهند انتساب‌های این مدل در مقایسه با سه روش دیگر بیشترین هم‌خوانی را با زبان‌ها داشته‌اند. این نتیجه توصیفی است و برچسب‌ها در ایجاد خوشه‌ها نقشی نداشته‌اند.

تحلیل نمودار خوشه‌بندی DBSCAN




شکل ۱۱.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم DBSCAN در داده‌های گفتاری

شکل ۱۱.۴ نشان می‌دهد DBSCAN چند ناحیه متراکم را به صورت خوشه‌های جداگانه شناسایی کرده، اما نقاط نویز در بخش‌های مختلف فضای دوبعدی پراکنده‌اند. این مدل ۱۳ خوشه غیرنویز و ۱۳۰ نمونه نویز ایجاد کرده است؛ بنابراین حدود ۱۸.۰۶ درصد داده‌ها در هیچ خوشه متراکمی قرار نگرفته‌اند.

مقادیر $ARI=0.24333$ و $NMI=0.46958$ بیانگر هم‌خوانی محدود انتساب‌ها با زبان واقعی هستند. این نتیجه به تنهایی ثابت نمی‌کند پراکندگی نمونه‌های نویز ناشی از گوینده، محیط ضبط یا زبان است، زیرا سهم هر عامل در این آزمایش به صورت جداگانه اندازه‌گیری نشده است.

تحلیل نمودار خوشه‌بندی Agglomerative




شکل ۱۲.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم Agglomerative Clustering در داده‌های گفتاری

مطابق شکل ۱۲.۴، تقریباً تمام نقاط با یک رنگ نمایش داده شده‌اند و فقط یک نمونه در خوشه دوم قرار دارد. اندازه دقیق خوشه‌ها ۷۱۹ و ۱ است. بنابراین $Silhouette=0.47093$ در اینجا بیانگر جدایی چهار زبان یا حتی دو گروه متوازن نیست، بلکه با جداسدن یک نمونه دورافتاده همراه است.

مقادیر $ARI=0.00000$ ، $NMI=0.00276$ و $Purity=0.25139$ نیز این نبود هم‌خوانی زبانی را تأیید می‌کنند. در نتیجه، اگرچه این مدل طبق معیار رسمی بیشترین $Silhouette$ را دارد، خروجی آن از نظر تفسیر زبانی مفید نیست و در تحلیل نهایی باید با این محدودیت گزارش شود.

تحلیل نمودار خوشه‌بندی Gaussian Mixture



شکل ۱۳.۴: نمایش خوشه‌های ایجادشده توسط الگوریتم Gaussian Mixture در داده‌های گفتاری

شکل ۱۳.۴ انتساب نهایی نمونه‌ها به هشت مؤلفه را در فضای دوبعدی نمایش می‌دهد. برخی مؤلفه‌ها در بخش‌های چپ و پایین تمرکز مشخص‌تری دارند، اما در ناحیه مرکزی چند مؤلفه هم‌پوشانی قابل توجهی نشان می‌دهند. این تصویر احتمال‌های عضویت را نمایش نمی‌دهد؛ بلکه هر نقطه را با رنگ مؤلفه دارای بیشترین احتمال نشان می‌دهد.

مقادیر $ARI=0.33824$ و $NMI=0.54021$ نشان می‌دهند این مدل بخشی از ساختار مرتبط با زبان را بازتاب داده، اما هم‌خوانی آن از K-Means کمتر بوده است. مقدار $Silhouette=0.14991$ نیز جدایی هندسی ضعیف‌تری را در مقایسه با سه روش دیگر نشان می‌دهد.

۶.۶.۴ تحلیل نهایی خوشه‌بندی گفتار

نتایج این بخش نشان می‌دهد انتخاب مدل در خوشه‌بندی به معیار مورد استفاده وابسته است. Agglomerative Clustering براساس قاعده رسمی بیشترین Silhouette را به دست آورده و به عنوان مدل منتخب خودکار ثبت شده است، اما خروجی ۷۱۹ در برابر ۱ آن یک جواب نامتوازن و فاقد تفسیر زبانی مناسب است. در مقابل، K-Means بیشترین هم‌خوانی پس از برازش را با برجسب‌های زبان نشان داده، ولی هشت خوشه آن با چهار زبان رابطه یک‌به‌یک ندارند و معیارهای خارجی آن برای انتخاب مدل استفاده نشده‌اند.

بنابراین، این آزمایش شواهدی از وجود بخشی از ساختار مرتبط با زبان در ویژگی‌های صوتی فراهم می‌کند، اما نشان نمی‌دهد زبان تنها عامل شکل‌دهنده فضای ویژگی است. برای بهبود انتخاب

کاملاً بدون‌ناظر، می‌توان در کارهای آینده علاوه بر Silhouette، حداقل اندازه خوشه، میزان عدم‌توازن خوشه‌ها و پایداری نتایج در اجراها یا زیرنمونه‌های مختلف را نیز در قاعده انتخاب وارد کرد.

از آنجاکه مجموعه‌های گفتار و متن در این پروژه مستقل‌اند و نمونه‌ها، ساختار و فرآیند تولید یکسانی ندارند، نتایج این بخش نباید به عنوان یک مقایسه کنترل‌شده برای اثبات دشوارتر بودن خوشه‌بندی گفتار نسبت به متن تفسیر شوند.

۷.۴ ارزیابی و مقایسه نتایج

جدول ۱۵.۴ خلاصه مدل منتخب هر مسیر طبقه‌بندی را نشان می‌دهد. این جدول برای ارائه فشرده نتایج است و نباید به عنوان مقایسه کنترل‌شده متن و گفتار تفسیر شود؛ زیرا دو مجموعه داده از نظر نمونه‌ها، زبان‌ها، تعداد کلاس‌ها، اندازه و نوع ویژگی مستقل هستند.

جدول ۱۵.۴: خلاصه طبقه‌بند منتخب در هر مجموعه داده مستقل

داده	مدل منتخب	CV Macro F1	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1
متن	Logistic Regression	0.9906	0.9953	0.9949	0.9944	0.9946	0.9953
گفتار	KNN	0.9662	0.9932	0.9891	0.9940	0.9914	0.9933

در هر دو مجموعه داده، طبقه‌بندی نظارت‌شده عملکرد بالایی داشته است. در متن، نتیجه اعتبارسنجی و آزمون نهایی هر دو برتری Logistic Regression را تأیید می‌کنند. در گفتار، چهار مدل عملکرد آزمون بسیار نزدیک دارند و سه مدل به دقت کامل رسیده‌اند؛ با این حال، انتخاب نهایی براساس اعتبارسنجی گروه آگاه انجام شده و نه براساس مشاهده مجموعه آزمون.

برای خوشه‌بندی، باید میان دو پرسش متفاوت تمایز قائل شد:

- کدام مدل از نظر هندسه داخلی داده خوشه‌های فشرده‌تر و جداتری ایجاد می‌کند؟

- کدام مدل پس از برازش بیشترین تطابق را با برچسب‌های زبان نشان می‌دهد؟

خلاصه این دو دیدگاه در جدول ۱۶.۴ ارائه شده است.

جدول ۱۶.۴: تفاوت انتخاب داخلی و تطابق خارجی در خوشه‌بندی

داده	منتخب بدون برچسب	Silhouette	بیشترین تطابق خارجی	ARI	NMI	Purity
متن	DBSCAN	0.4265	K-Means / Agglomerative	1.0000	1.0000	1.0000
گفتار	Agglomerative	0.4709	K-Means	0.4983	0.6731	0.9028

در بخش متن، ساختار بدون برچسب داده به قدری روشن است که K-Means و Agglomerative Clustering زبان‌ها را به صورت کامل بازایی کرده‌اند. با وجود این، قاعده انتخاب کاملاً بدون برچسب،

DBSCAN را به دلیل Silhouette بالاتر برگزیده است. این تفاوت نشان می‌دهد که معیار داخلی لزوماً هدف معنایی مورد نظر، یعنی زبان، را بهینه نمی‌کند.

در بخش گفتار، این اختلاف شدیدتر است. مدل سلسله‌مراتبی از نظر Silhouette بهترین مقدار را دارد، اما تقریباً تمام نمونه‌ها را در یک خوشه قرار می‌دهد و با زبان واقعی تطابق ندارد. در مقابل، K-Means تطابق خارجی بیشتری ایجاد کرده است، ولی زبان‌ها را به هشت زیرگروه تقسیم می‌کند. در نتیجه، عملکرد بالای طبقه‌بندی گفتار به این معنا نیست که همان ویژگی‌ها باید در یادگیری بدون نظارت نیز چهار خوشه متناظر با زبان ایجاد کنند. مدل نظارت‌شده می‌تواند با استفاده از برچسب، مرزهایی را بیاموزد که در هندسه غالب داده به شکل خوشه‌های طبیعی ظاهر نمی‌شوند.

۸.۴ تحلیل نتایج نهایی

نتایج اجرای نهایی نشان می‌دهند که خط لوله پیشنهادی برای شناسایی زبان در هر دو مسیر طبقه‌بندی قابل استفاده است. مدل منتخب متن، Logistic Regression، با دریافت مستقیم متن خام و اجرای تمام مراحل پیش‌پردازش درون بسته مدل، روی مجموعه آزمون فقط یک خطا داشته است. مدل منتخب گفتار، KNN، نیز با دریافت ۱۳۳ ویژگی عددی روی مجموعه آزمون فقط یک نمونه را اشتباه پیش‌بینی کرده است.

با این حال، مقادیر نزدیک به یک باید در محدوده همین داده‌ها تفسیر شوند. مجموعه متن شامل ۶۰۸ نمونه نسبتاً کوتاه و شش زبان است و نشانه‌های نوشتاری و تفاوت خط میان برخی زبان‌ها جداسازی را آسان می‌کند. مجموعه گفتار نیز شامل ۷۲۰ نمونه متوازن از چهار زبان و ویژگی‌هایی است که از کل فایل صوتی خلاصه شده‌اند. تقسیم گروه‌آگاه احتمال حضور نمونه‌های یک‌گویی یا منبع در دو بخش را کاهش داده است، اما تعمیم نتیجه به گویندگان، شرایط ضبط، طول فایل و مجموعه داده‌های کاملاً متفاوت به آزمایش مستقل نیاز دارد.

وجود یک فایل صوتی با مدت زمان حدود ۱۵۳۴ ثانیه و رفتار خوشه‌بندی سلسله‌مراتبی نشان می‌دهد که نمونه‌های دورافتاده می‌توانند بر ساختار بدون نظارت اثر زیادی داشته باشند. در این پروژه، این نمونه حذف نشده و نتیجه به صورت شفاف گزارش شده است. برای توسعه آینده می‌توان قواعدی مانند حداقل اندازه خوشه، تحلیل حساسیت نسبت به نمونه‌های دورافتاده و مقایسه نتایج با و بدون ویژگی مدت زمان را بررسی کرد؛ این آزمایش‌ها در نتایج فعلی انجام نشده‌اند و نباید نتیجه آن‌ها از پیش فرض شود.

خوشه‌بندی متن نشان داد که جداسازی بدون برچسب برای این مجموعه داده امکان‌پذیر است، اما نتیجه DBSCAN همچنین اهمیت گزارش نرخ نویز و تعداد خوشه‌ها را نشان داد. در گفتار، تضاد میان Silhouette و معیارهای خارجی نشان می‌دهد که اتکا به یک معیار منفرد کافی نیست. بنابراین در گزارش نهایی هر سه گروه اطلاعات زیر کنار هم نگهداری شده‌اند:

- معیارهای داخلی شامل Silhouette، Calinski-Harabasz و Davies-Bouldin؛

- معیارهای خارجی پس از برازش شامل ARI، NMI و Purity؛

• تعداد خوشه‌ها، تعداد نمونه‌های نويز و تركيب زبانی هر خوشه.

در پایان اجرای پروژه، چهار طبقه‌بند و چهار خوشه‌بند برای هر یک از دو مجموعه داده اجرا شده‌اند؛ بنابراین ۱۶ نتیجه مربوط به خانواده‌های مدل در دسترس است. هفت دفترچه پروژه نیز اجرا شده و وضعیت اجرای کامل برابر passed ثبت شده است. مدل منتخب هر دو مسیر طبقه‌بندی ذخیره شده و آزمون استنتاج آن‌ها با موفقیت انجام شده است.

برآیند نتایج این فصل آن است که برای کاربرد اصلی شناسایی زبان، مسیرهای نظارت‌شده قابل اعتمادترین خروجی را در محدوده داده‌های پروژه ارائه می‌کنند. خوشه‌بندی متن شواهد قوی از جدایی طبیعی زبان‌ها نشان می‌دهد، درحالی‌که خوشه‌بندی گفتار بیشتر ساختارهای آکوستیکی چندگانه را آشکار می‌کند و بدون برچسب، معادل مستقیمی برای طبقه‌بندی زبان نیست.

فصل ۵

نتیجه‌گیری و پیشنهادها

در این فصل، دستاوردهای نهایی پروژه شناسایی زبان در داده‌های متنی و گفتاری جمع‌بندی می‌شوند. نتایج نشان دادند که خطوط لوله نظارت‌شده در محدوده مجموعه داده‌های پروژه عملکرد بسیار مناسبی دارند؛ با این حال، نتیجه خوشه‌بندی به نوع داده و معیار انتخاب مدل وابسته است و جدایی طبیعی نمونه‌ها همیشه با برچسب زبان مطابقت ندارد. همچنین محدودیت‌های داده و پیاده‌سازی بیان می‌شوند و مسیرهای قابل بررسی برای توسعه آینده پیشنهاد می‌گردند.

۱.۵ جمع‌بندی پروژه

هدف این پروژه طراحی و ارزیابی یک سامانه شناسایی زبان برای دو نوع داده مستقل، یعنی متن و گفتار، بود. این دو مجموعه داده از نظر تعداد نمونه، زبان‌ها، شناسه‌ها و ساختار فایل با یکدیگر یکسان نیستند؛ از این رو برای هر کدام خط لوله جداگانه‌ای ایجاد شد و نتایج آن‌ها به‌عنوان یک آزمایش جفت‌شده یا مقایسه کنترل‌شده چندوجهی تفسیر نشدند.

در مسیر متن، داده‌های خام کشف و اعتبارسنجی شدند و پس از پاک‌سازی فاصله‌های اضافی، ویژگی‌های کاراکتری و واژگانی TF-IDF استخراج شدند. سپس انتخاب ۵۰ ویژگی برتر با معیار Chi-Square درون خط لوله مدل انجام شد. قرارگرفتن بردارسازی و انتخاب ویژگی درون خط لوله باعث شد این مراحل در هر دور اعتبارسنجی فقط روی داده آموزشی برازش شوند و اطلاعات مجموعه آزمون وارد فرایند آموزش نشود.

در مسیر گفتار، ابتدا فایل‌های صوتی توسط نگارنده پاک‌سازی و تحلیل شدند و خروجی استخراج ویژگی در دو فایل features.csv و metadata.csv ذخیره شد. خط لوله آزمایش نهایی این دو فایل را به‌صورت فقط خواندنی دریافت کرد و آموزش مدل‌ها را از جدول ۱۳۳ ویژگی عددی آغاز نمود. برای مدیریت مقادیر گم‌شده و تفاوت مقیاس ویژگی‌ها، جایگزینی مقادیر و استانداردسازی درون خطوط لوله طبقه‌بندی قرار گرفتند.

برای کاهش نشت اطلاعات، تقسیم آموزش و آزمون در هر دو مسیر به‌صورت گروه‌آگاه انجام شد. تنظیم ابرپارامترها و انتخاب طبقه‌بند فقط بر اساس میانگین Macro F1 در اعتبارسنجی متقاطع بخش آموزشی صورت گرفت و مجموعه آزمون نهایی در انتخاب مدل نقشی نداشت. در بخش خوشه‌بندی نیز برچسب زبان هنگام برازش، کاهش بُعد و انتخاب پارامترها استفاده نشد و معیارهای خارجی تنها پس از تشکیل خوشه‌ها محاسبه شدند.

در مجموع، برای هر یک از دو نوع داده دقیقاً چهار خانواده طبقه‌بندی و چهار خانواده خوشه‌بندی اجرا شد. بنابراین ۱۶ نتیجه مربوط به خانواده‌های مدل تولید گردید. هفت دفترچه پروژه نیز به‌طور کامل اجرا شدند، مدل منتخب طبقه‌بندی هر مسیر ذخیره شد و آزمون استنتاج هر دو بسته مدل با موفقیت انجام گرفت. وضعیت اجرای کامل پروژه در فایل کنترل کیفیت برابر passed ثبت شده است.

۲.۵ مهم‌ترین نتایج

مهم‌ترین یافته‌های حاصل از اجرای نهایی پروژه به شرح زیر هستند:

- **طبقه‌بندی متن:** مدل Logistic Regression بر اساس میانگین Macro F1 برابر با ۰.۹۹۰۶ در اعتبارسنجی متقاطع گروه‌آگاه انتخاب شد. این مدل روی ۲۱۱ نمونه آزمون نهایی به Accuracy برابر با ۰.۹۹۵۳ و Macro F1 برابر با ۰.۹۹۴۶ رسید و فقط یک متن اسپانیایی را پرتغالی تشخیص داد. نتایج نشان می‌دهند که ترکیب ویژگی‌های کاراکتری و واژگانی برای زبان‌های موجود در این مجموعه داده مؤثر بوده است.

• **مقایسه طبقه‌بندهای متن:** مدل‌های KNN، Decision Tree و Multinomial Naive Bayes نیز عملکرد مناسبی داشتند، اما امتیاز اعتبارسنجی آن‌ها از مدل منتخب کمتر بود. دقت آموزشی کامل در درخت تصمیم نشانه‌ای از ظرفیت بالای این مدل برای بیش‌برازش بود. همچنین Multinomial Naive Bayes بیشترین تغییرپذیری میان دوره‌های اعتبارسنجی را نشان داد. در نتیجه، انتخاب Logistic Regression فقط بر دقت آزمون متکی نبود و بر اساس معیار از پیش تعیین‌شده آموزشی انجام شد.

• **طبقه‌بندی گفتار:** مدل KNN با میانگین Macro F1 برابر با ۰.۹۶۶۲ در اعتبارسنجی متقاطع گروه‌آگاه انتخاب شد. این مدل روی ۱۴۸ نمونه آزمون نهایی به Accuracy برابر با ۰.۹۹۳۲ و Macro F1 برابر با ۰.۹۹۱۴ رسید و تنها یک نمونه آلمانی را کره‌ای پیش‌بینی کرد.

• **مقایسه طبقه‌بندهای گفتار:** سه مدل Logistic Regression، Random Forest و RBF SVM روی مجموعه آزمون به دقت ۱.۰۰۰۰ رسیدند. با این حال، این نتیجه برای انتخاب مدل استفاده نشد؛ زیرا آزمون نهایی باید خارج از فرایند انتخاب باقی می‌ماند. اختلاف امتیاز اعتبارسنجی KNN و Logistic Regression حدود ۰.۰۰۰۶ و بسیار کوچک‌تر از انحراف معیار اعتبارسنجی آن‌ها بود. بنابراین نمی‌توان برتری قطعی و عمومی KNN را ادعا کرد؛ این مدل صرفاً مطابق قاعده از پیش تعیین‌شده پروژه انتخاب شده است.

• **خوشه‌بندی متن:** مدل‌های K-Means و Agglomerative Clustering هر شش زبان را در این مجموعه داده به‌طور کامل بازیابی کردند و برای هر سه معیار ARI، NMI و Purity مقدار ۱.۰۰۰۰ به دست آوردند. با وجود این، مدل DBSCAN به دلیل بیشترین معیار داخلی Silhouette برابر با ۰.۴۲۶۵ به‌عنوان مدل منتخب بدون برچسب ثبت شد. این مدل ۱۳ خوشه تشکیل داد و ۱۴۳ نمونه، معادل ۲۳.۵۲ درصد داده‌ها، را نویز تشخیص داد. این نتیجه نشان می‌دهد که بهترین معیار هندسی لزوماً به معنای بهترین بازیابی برچسب معنایی زبان نیست.

• **خوشه‌بندی گفتار:** مدل Agglomerative Clustering با مقدار Silhouette برابر با ۰.۴۷۰۹ طبق معیار داخلی انتخاب شد، اما یک خوشه شامل ۷۱۹ نمونه و خوشه دیگر شامل تنها یک نمونه بود. مقدار ARI آن برابر صفر و NMI برابر با ۰.۰۰۲۸ بود؛ بنابراین مقدار بالای Silhouette در این حالت حاصل جداسازی یک نمونه دورافتاده است و به معنای کشف زبان‌ها نیست. در میان مدل‌های گفتار، K-Means بیشترین انطباق خارجی را با ARI برابر با ۰.۴۹۸۳، NMI برابر با ۰.۶۷۳۱ و Purity برابر با ۰.۹۰۲۸ ایجاد کرد، ولی داده‌ها را به هشت خوشه و نه چهار خوشه متناظر با زبان‌ها تقسیم نمود.

در مجموع، نتایج طبقه‌بندی نشان دادند که زبان نمونه‌های موجود با استفاده از برچسب‌های آموزشی به‌خوبی قابل تشخیص است. در مقابل، نتایج خوشه‌بندی ثابت کردند که ساختار غالب بدون برچسب همیشه همان مفهوم مورد نظر پژوهشگر نیست. این تفاوت در گفتار آشکارتر بود؛ زیرا ویژگی‌های آکوستیکی ممکن است علاوه بر زبان، تحت تأثیر ویژگی‌های گوینده، منبع ضبط، مدت فایل و شرایط صوتی نیز قرار گیرند. بررسی دقیق سهم هر یک از این عوامل در آزمایش فعلی انجام نشده است و این موارد فقط توضیح‌های احتمالی محسوب می‌شوند.

۳.۵ محدودیت‌های پروژه

با وجود عملکرد مناسب مدل‌ها، نتایج باید با توجه به محدودیت‌های زیر تفسیر شوند:

- مجموعه داده متن شامل ۶۰۸ نمونه و شش زبان و مجموعه داده گفتار شامل ۷۲۰ نمونه و چهار زبان است. این اندازه و تنوع برای ارائه یک خط پایه دانشگاهی مناسب است، اما برای نتیجه‌گیری عمومی درباره همه زبان‌ها، گویندگان و شرایط واقعی کافی نیست.
- داده‌های متن و گفتار مستقل هستند و زبان‌ها و نمونه‌های کاملاً یکسانی ندارند. بنابراین نتایج دو مسیر نباید به عنوان مقایسه مستقیم کیفیت متن و گفتار یا به عنوان یک سامانه چندوجهی جفت‌شده تفسیر شوند.
- دقت بسیار بالای متن ممکن است تا حدی ناشی از تفاوت خط، الگوهای واژگانی مشخص و ویژگی‌های منبع داده باشد. تعمیم این عملکرد به متن‌های بسیار کوتاه، دارای غلط املایی، نویسه‌گردانی‌شده، آمیخته با چند زبان یا متعلق به منابع دیگر هنوز ارزیابی نشده است.
- ویژگی‌های گفتار به شکل میانگین و انحراف معیار ویژگی‌های کل فایل ذخیره شده‌اند. این نمایش، ترتیب زمانی و تغییرات محلی سیگنال را حفظ نمی‌کند و ممکن است بخشی از اطلاعات زبانی گفتار را از بین ببرد.
- در داده گفتار یک نمونه با مدت تقریبی ۱۵۳۴ ثانیه وجود دارد. این نمونه حذف نشده است و تحلیل حساسیت با حذف آن یا کنار گذاشتن ویژگی مدت زمان انجام نشده؛ در نتیجه میزان اثر دقیق آن بر مدل‌ها مشخص نیست.
- گروه‌ها از الگوی نام فایل استخراج شده‌اند. این روش برای کاهش هم‌پوشانی منبع میان آموزش و آزمون مفید است، اما در همه موارد معادل شناسه تأییدشده گوینده نیست. بنابراین احتمال باقی ماندن برخی وابستگی‌های ناشناخته میان نمونه‌ها کاملاً منتفی نیست.
- برای ارزیابی نهایی از یک تقسیم گروه‌آگاه آموزش و آزمون استفاده شده است. اعتبارسنجی متقاطع روی بخش آموزشی عدم قطعیت انتخاب مدل را تا حدی نشان می‌دهد، اما ارزیابی روی مجموعه داده خارجی و مستقل همچنان لازم است.
- انتخاب مدل خوشه‌بندی بر اساس یک معیار داخلی می‌تواند در حضور نویز، خوشه‌های بسیار کوچک یا نمونه‌های دورافتاده گمراه‌کننده باشد. نمونه روشن آن، مدل سلسله‌مراتبی گفتار است. پایداری خوشه‌ها در تقسیم‌ها یا نمونه‌گیری‌های مجدد نیز در این پروژه بررسی نشده است.
- بسته استنتاج متن، متن خام را مستقیماً دریافت می‌کند؛ اما بسته فعلی گفتار به یک ردیف شامل همان ۱۳۳ ویژگی استخراج‌شده نیاز دارد و فایل صوتی خام را مستقیماً نمی‌پذیرد.
- مسئله تشخیص زبان ناشناخته، تنظیم اطمینان پیش‌بینی، گفتار یا متن چندزبانه و تغییر توزیع داده در محیط واقعی در محدوده این نسخه قرار نداشته‌اند.

این محدودیت‌ها اعتبار نتایج اجرا شده را از بین نمی‌برند، بلکه دامنه صحیح تفسیر آن‌ها را مشخص می‌کنند. اعداد گزارش شده بیانگر عملکرد مدل‌ها روی تقسیم‌ها و داده‌های همین پروژه هستند و نباید بدون آزمایش تکمیلی به مجموعه داده‌های دیگر تعمیم داده شوند.

۴.۵ پیشنهاد برای توسعه آینده

با توجه به نتایج و محدودیت‌های مشاهده شده، پیشنهادهای توسعه آینده به ترتیب اولویت عبارت‌اند از:

۱. **ارزیابی روی داده‌های بزرگ‌تر و مستقل:** مهم‌ترین گام، آزمایش مدل‌های ذخیره شده روی منابع جدید با گویندگان، موضوع‌ها، لهجه‌ها، ابزارهای ضبط و شرایط نویزی متنوع است. افزودن زبان‌ها و نمونه‌های کوتاه یا دشوار نیز امکان بررسی واقع‌بینانه‌تر تعمیم‌پذیری را فراهم می‌کند.

۲. **بهبود فراداده و تقسیم‌گفتار:** استفاده از شناسه تأیید شده گوینده و منبع ضبط، تقسیم دقیق‌تر گروه‌آگاه را ممکن می‌سازد. همچنین بهتر است یک مجموعه ارزیابی کاملاً مستقل از گوینده و منبع آموزشی نگهداری شود.

۳. **تکمیل مسیر استنتاج صوت خام:** می‌توان مراحل پاک‌سازی و استخراج ویژگی موجود را به صورت یک مسیر اختیاری و بازتولیدپذیر به بسته استنتاج متصل کرد تا کاربر به جای جدول ویژگی، فایل صوتی را مستقیماً وارد کند. در این حالت باید ترتیب، نام و تعریف دقیق هر ۱۳۳ ویژگی با قرارداد مدل ذخیره شده یکسان باقی بماند.

۴. **تحلیل حساسیت ویژگی‌های گفتار:** اثر نمونه بسیار طولانی، ویژگی مدت زمان و روش خلاصه‌سازی کل فایل باید با آزمایش‌های کنترل شده بررسی شود. قطعه‌بندی فایل‌های طولانی و مقایسه نتیجه با و بدون نمونه‌های دورافتاده می‌تواند علت رفتار خوشه‌بندی را روشن‌تر کند.

۵. **بررسی نمایش‌های زمانی گفتار:** در کنار خط پایه کلاسیک، می‌توان دنباله‌های MFCC، مدل‌های CNN/RNN یا تعبیه‌های از پیش آموزش دیده گفتار را ارزیابی کرد. این مدل‌ها ممکن است اطلاعات زمانی بیشتری حفظ کنند، اما هزینه محاسباتی و نیاز داده‌ای آن‌ها باید با خط پایه قابل اجرای پردازنده مرکزی مقایسه شود.

۶. **آزمایش‌های مقاوم‌بودن متن:** مقایسه جداگانه ویژگی‌های کاراکتری و واژگانی، تغییر بازه N-Gram، تغییر تعداد ویژگی‌های منتخب و افزودن نویز مصنوعی مانند غلط املایی یا نویسه‌گردانی می‌تواند وابستگی مدل به نشانه‌های سطحی را مشخص کند.

۷. **تشخیص زبان ناشناخته و کالیبراسیون:** افزودن آستانه اطمینان، کالیبراسیون احتمال و سازوکاری برای رد نمونه‌هایی که متعلق به زبان‌های آموزش دیده نیستند، سامانه را برای استفاده عملی ایمن‌تر می‌کند.

۸. **ارزیابی پایداری خوشه‌بندی:** بهتر است در کنار معیارهای داخلی و خارجی، حداقل اندازه خوشه، پایداری در نمونه‌گیری مجدد و حساسیت به پارامترها نیز سنجیده شود. روش‌های مقاوم‌تر چگالی‌محور مانند HDBSCAN و تحلیل ترکیب خوشه‌ها بر اساس گوینده یا منبع، پس از پایان برازش بدون برچسب، می‌توانند درک بهتری از ساختار داده ارائه دهند.

۹. **بررسی سامانه چندوجهی در صورت تهیه داده جفت‌شده:** اگر در آینده برای هر نمونه صوتی، متن متناظر و برچسب‌های مشترک فراهم شود، می‌توان روش‌های ترکیب متن و گفتار را بررسی کرد. داده‌های مستقل فعلی برای نتیجه‌گیری معتبر درباره ادغام چندوجهی مناسب نیستند.

در نهایت، پروژه حاضر یک خط پایه کامل، بازتولیدپذیر و قابل اجرا روی پردازنده مرکزی برای شناسایی زبان فراهم کرده است. مهم‌ترین دستاورد آن تنها دستیابی به دقت بالا نیست، بلکه رعایت جداسازی داده آزمون، برازش ویژگی‌ها درون خط لوله، انتخاب مدل بر اساس اعتبارسنجی و گزارش شفاف تفاوت میان معیارهای داخلی و خارجی خوشه‌بندی است. بر اساس شواهد فعلی، طبقه‌بندی نظارت‌شده مناسب‌ترین مسیر برای کاربرد اصلی این پروژه است؛ درحالی‌که خوشه‌بندی بیشتر به‌عنوان ابزاری برای کشف و تحلیل ساختار پنهان داده‌ها ارزش دارد. توسعه آینده باید پیش از افزایش پیچیدگی مدل، بر تنوع داده، اعتبارسنجی خارجی و مقاوم‌بودن سامانه تمرکز کند.

فصل ٦

مراجع

[1] T. Jauhiainen, M. Lui, M. Zampieri, T. Baldwin, and K. Lindén, “Automatic Language Identification in Texts: A Survey,” *Journal of Artificial Intelligence Research*, vol. 65, pp. 675–782, 2019. doi: 10.1613/jair.1.11675.

[2] W. B. Cavnar and J. M. Trenkle, “N-Gram-Based Text Categorization,” in *Proceedings of the Third Annual Symposium on Document Analysis and Information Retrieval*, pp. 161–175, 1994.

[3] M. Lui and T. Baldwin, “langid.py: An Off-the-Shelf Language Identification Tool,” in *Proceedings of the ACL 2012 System Demonstrations*, Association for Computational Linguistics, pp. 25–30, 2012.

[4] G. Salton and C. Buckley, “Term-Weighting Approaches in Automatic Text Retrieval,” *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988. doi: 10.1016/0306-4573(88)90021-0.

[5] Y. K. Muthusamy, E. Barnard, and R. A. Cole, “Reviewing Automatic Language Identification,” *IEEE Signal Processing Magazine*, vol. 11, no. 4, pp. 33–41, 1994. doi: 10.1109/79.317925.

[6] M. A. Zissman, “Comparison of Four Approaches to Automatic Language Identification of Telephone Speech,” *IEEE Transactions on Speech and Audio Processing*, vol. 4, no. 1, pp. 31–44, 1996. doi: 10.1109/TSA.1996.481450.

[7] S. B. Davis and P. Mermelstein, “Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, 1980. doi: 10.1109/TASSP.1980.1163420.

[8] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, pp. 226–231, 1996.

[9] P. J. Rousseeuw, “Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis,” *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987. doi: 10.1016/0377-0427(87)90125-7.

[10] F. Pedregosa et al., “Scikit-Learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, no. 85, pp. 2825–2830, 2011.

[11] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and Music Signal Analysis in Python,” in *Proceedings of the 14th Python in Science Conference*, pp. 18–25, 2015. doi: 10.25080/Majora-7b98e3ed-003.



**University of Tehran
College of Farabi
Faculty of Engineering
Department of Computer Engineering**

Language Identification in Multilingual Speech Data

By:

Ava Shahabeddin

Under Supervision of:

Dr. Hossein Aghababa

**A Project Report as a Requirement for the Degree of
Bachelor of Science in Computer Engineering**

September 2026